PEGASO
Università Telematica
D.M. 20 04 2006 G.U. n° 118 del 23 05 2006

Le relazioni statistiche

Le relazioni statistiche

Lo studio delle relazioni esistenti tra due variabili parte dal concetto di indipendenza:

Distinguiamo tre concetti di indipendenza:

1. Indipendenza assoluta
2. Indipendenza in media
3. Indipendenza correlativa

Le relazioni statistiche: indipendenza assoluta

Si ha indipendenza se le distribuzioni relative condizionate della variabile Y sono invarianti al variare delle modalità della variabile X.

Vi è indipendenza se le distribuzioni relative condizionate della variabile X sono invarianti al variare delle modalità della variabile Y.

Le relazioni statistiche: indipendenza assoluta

Esempio

Distribuzioni relative della X condizionata rispetto a Y:

	Y1	Y2	Y3	TOTALE
X1	3	9	6	18
X2	2	6	4	12
X3	5	15	10	30
TOTALE	10	30	20	60

	Y1	Y2	Y3	Tot.
X1	3/10=0,3	9/30=0,3	6/20=0,3	18/60=0,3
X2	2/10=0,2	0,2	0,2	0,2
X3	5/10= 0,5	0,5	0,5	0,5
Tot	1	1	1	1

$$\frac{n_{11}}{n_{.1}} = \frac{n_{12}}{n_{.2}} = \cdots = \frac{n_{1.}}{n}$$

Distribuzioni relative della Y condizionata rispetto a X:

	Y1	Y2	Y3	Tot
X1	3/18=0,17	9/18= 0,5	6/18=0,33	1
X2	2/12=0,17	0,5	0,33	1
X3	5/30=0,17	0,5	0,33	1
Tot.	10/60=0,17	0,5	0,33	1

$$\frac{n_{11}}{n_{1.}} = \frac{n_{21}}{n_{2.}} = \cdots = \frac{n_{.1}}{n}$$

Le relazioni statistiche: indipendenza assoluta

Se si ha indipendenza assoluta tra due variabili statistiche allora solo si verifica la seguente relazione:

frequenze osservate = frequenze teoriche

$$n_{ij} = \frac{n_{i\bullet} \times n_{\bullet j}}{n}$$

Se c'è dipendenza le variabili si dicono connesse.

Si dirà che la variabile Y sia connessa a X, nel caso in cui la distribuzione relativa della Y varia al variare delle modalità della X, o equivalentemente:

$$n_{ij} \neq \frac{n_{i\bullet} \times n_{\bullet j}}{n}$$

Le relazioni statistiche: indipendenza assoluta

Data una distribuzione doppia

	y_1	y_2	y_j	y_c	
x_1	n_{11}	n_{12}	n_{1j}	n_{1c}	$n_{1.}$
x_2	n_{21}	n_{22}	n_{2j}	n_{2c}	$n_{2.}$
x_i	n_{i1}	n_{i2}	n_{ij}	n_{ic}	$n_{i.}$
x_r	n_{r1}	n_{r2}	n_{rj}	n_{rc}	$n_{r.}$
	$n_{.1}$	$n_{.2}$	$n_{.j}$	$n_{.c}$	n

Se tra le due variabili non esiste connessione nulla, si è interessati a conoscere il grado di connessione fra le due variabili.

Le relazioni statistiche: indipendenza assoluta

Si è detto che X è indipendente da Y se:

$$n_{ij} = \frac{n_{i\bullet} \times n_{\bullet j}}{n}$$

Per ogni coppia di valori i e j (i=1,….,r e j=1,…..,c)

Supponendo che non esista una connessione tra X e Y, indichiamo:

$$n^{*}_{ij} = \frac{n_{i\bullet} \times n_{\bullet j}}{n}$$

Le frequenze teoriche

Le relazioni statistiche: indipendenza assoluta

Possiamo costruire la tabella di indipendenza:

	y_1	y_j	y_c	
x_1	$\frac{(n_1. \times n._1)}{n}$	$\frac{(n_1. \times n._j)}{n}$	$\frac{(n_1. \times n._1)}{n}$	$n_1.$
x_i	$\frac{(ni. \times n._1)}{n}$	$\frac{(n_i. \times n._j)}{n}$	$\frac{(n_i. \times n._c)}{n}$	$n_i.$
x_r	$\frac{(n_r. \times n._1)}{n}$	$\frac{(n_r. \times n._j)}{n}$	$\frac{(n_r. \times n._c)}{n}$	$n_r.$
	$n._1$	$n._j$	$n._c$	n

Da notare che le frequenze marginali della distribuzione doppia e della tabella di indipendenza sono uguali.

Le relazioni statistiche: indipendenza assoluta

Si chiamano **contingenze** la differenza fra le frequenze osservate e quelle teoriche:

$$C_{ij} = n_{ij} - n_{ij}^{*}$$

La somma delle contingenze di ciascuna riga e di ciascuna colonna sono nulle:

$$\sum_{i=1}^{r} C_{ij} = \sum_{j=1}^{c} C_{ij} = 0$$

Le relazioni statistiche: indice di connessione chi-quadrato

Un indice assoluto di connessione è il chi-quadro di Pearson, detto indice quadratico di contingenza:

$$\chi^2 = \sum_{i=1}^{r}\sum_{j=1}^{c}\frac{C_{ij}^2}{n_{ij}^*} = \sum_{i=1}^{r}\sum_{j=1}^{c}\frac{\left(n_{ij} - n_{ij}^*\right)^2}{n_{ij}^*}$$

Esso si annulla nel caso di connessione nulla, ossia quando le variabili sono perfettamente indipendenti.

$$\max\left(\chi^2\right) = n\left[\min\left(r-1; c-1\right)\right]$$

Le relazioni statistiche: indice di connessione chi-quadrato

Tale indice rappresenta l'allontanamento dei dati dall'ipotesi di indipendenza, ma non può costituire un misura di associazione in quando dipende da n

È facile verificare che se si raddoppia la numerosità il valore dell'indice chi-quadro raddoppia

Per ovviare a tale problema, Pearson ha proposto l'indice di contingenza quadratico medio

$$\phi^2 = \frac{\chi^2}{n}$$

$$\max\left(\phi^2\right) = \min\left(r-1; c-1\right)$$

Le relazioni statistiche: indice di connessione chi-quadrato

Un indice relativo di connessione è l'indice di Cramer

$$\varphi^2 = \frac{\phi^2}{\min(r-1; c-1)}$$

Varia tra 0 e 1

Le relazioni statistiche: indice di connessione chi-quadrato

INDIPENDENZA ASSOLUTA → l'**indice di connessione di Pearson** (X^2).

- Tabella di contingenza (due variabile qualitative),
- Tabella mista (una variabile qualitativa e una variabile quantitativa)
- Tabella di correlazione (due variabili entrambe quantitative)

Le relazioni statistiche: esempio chi-quadrato

Esempio indice chi-quadrato

X	Y			
	Y1	Y2	Y3	TOTALE
X1	2	5	15	22
X2	4	14	10	28
X3	7	6	12	25
TOTALE	13	25	37	75

Tabella delle frequenze teoriche

(22*13)/75 =3,813	(22*25)/75= 7,333	(22*37)/75= 10,853	22
4,853	9,333	13,813	28
4,333	8,333	12,333	25
13	25	37	75

Le relazioni statistiche: esempio chi-quadrato

2-3,813 = -1,813	5-7,333 = -2,333	15-10,853 = 4,147	0
-0,853	4,667	-3,813	0
2,667	-2,333	-0,333	0
0	0	0	

Dalla tabella di contingenza si evince che la somma algebrica delle contingenze di una riga o di una colonna è nulla

Le relazioni statistiche: esempio chi-quadrato

$$\chi^2 = \sum_{i=1}^{r}\sum_{j=1}^{c}\frac{C_{ij}^2}{n_{ij}^*} = \sum_{i=1}^{r}\sum_{j=1}^{c}\frac{\left(n_{ij}-n_{ij}^*\right)^2}{n_{ij}^*}$$

$$\chi^2 = \frac{(-1{,}813)^2}{3{,}813} + \frac{(-2{,}333)^2}{7{,}333} + \frac{(4{,}147)^2}{10{,}853} + \frac{(-0{,}853)^2}{4{,}853} + \frac{(-4{,}667)^2}{9{,}333} + \frac{(-3{,}813)^2}{13{,}813}$$

$$+ \frac{(2{,}667)^2}{4{,}333} + \frac{(-2{,}333)^2}{8{,}333} + \frac{(-0{,}333)^2}{12{,}333} = 9{,}029$$

$$\phi^2 = \frac{\chi^2}{n} = 9{,}029/75 = 0{,}12 \qquad \varphi^2 = \frac{\phi^2}{\min(r-1;c-1)} = 0{,}12/2 = 0{,}06$$

Si evince una bassa connessione tra i due caratteri