PEGASO
Università Telematica
D.M. 20 04 2006 G.U. n° 118 del 23 05 2006

La regressione lineare semplice

L'ANALISI DI REGRESSIONE

La regressione è volta alla ricerca di un modello atto a descrivere la relazione esistente tra una variabile Dipendente e una variabile indipendente (regressione semplice) o più variabili (regressione multipla) indipendenti o esplicative.

La scelta dell'una o dell'altra variabile come indipendente non è arbitraria ma è legata alla natura del fenomeno: si sceglie come indipendente la variabile che sia logicamente antecedente rispetto all'altra.
In un modello di regressione, le variabili esplicative spiegano, prevedono, simulano, controllano la variabile dipendente.

La retta di regressione

X : Variabile indipendente
Y: Variabile dipendente

L'espressione analitica della retta di regressione è:

$$\hat{y}_i = b_0 + b_1 x_i$$ Valori teorici della Y

b_o e b_1 Sono i coefficienti di regressione

b_0 L'intercetta, il punto in cui la retta interseca l'asse delle ordinate

b_1 Coefficiente angolare, indica la pendenza della retta

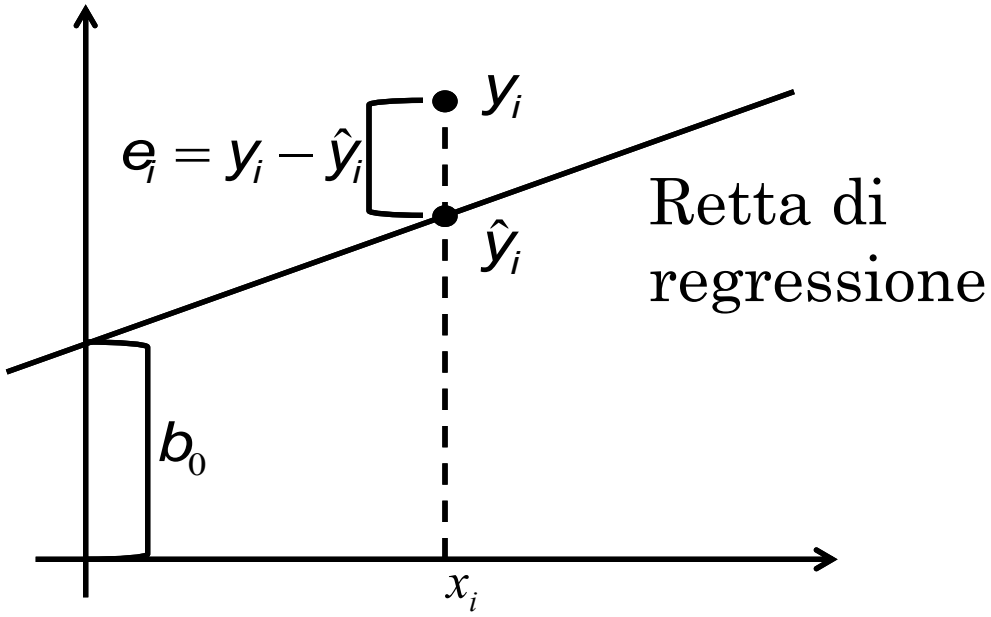
La retta di regressione

Per buon adattamento della curva ai dati si intende trovare tra le infinite rette

$$\hat{y}_i = b_0 + b_1 x_i$$

Quella che rende quanto più piccola i residui (al quadrato):

$$e_i = y_i - \hat{y}_i$$



La retta di regressione

Mediante il metodo dei minimi quadrati, si trova la retta migliore con coefficienti:

$$b_1 = \frac{COD(X,Y)}{DEV(X)} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2} \quad \text{OPPURE} \quad b_1 = \frac{\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^{n} x_i^2 - n\bar{x}^2}$$

$$b_0 = \bar{y} - b_1 \bar{x}$$

La retta di regressione

La codevianza determina il segno del coefficiente di regressione:

$Cod(X,Y) > 0 \Rightarrow b_1 > 0$ La retta di regressione è crescente

$Cod(X,Y) < 0 \Rightarrow b_1 < 0$ La retta di regressione è decrescente

$Cod(X,Y) = 0 \Rightarrow b_1 = 0$ La retta di regressione è parallela all'asse delle x

La retta di regressione

Proprietà della retta dei minimi quadrati:

- È l'unica retta che minimizza la somma dei quadrati dei residui
- La retta passa per il punto (media di x; media di y) come centro di gravità
- La somma dei residui è uguale a 0
- La somma dei valori osservati è uguale alla somma dei valori teorici, quindi i valori osservati e i valori teorici presentano la stessa media
- Il coefficiente angolare indica la variazione di Y in corrispondenza di una variazione unitaria di X

GRADO DI ADATTAMENTO

Una volta calcolata la retta di regressione bisogna determinare il grado di adattamento che esiste tra i valori osservati e i valori teorici

La devianza della variabile Y: $$Dev(Y) = \sum_{i=1}^{n} (y_i - \bar{y})^2$$

$$Dev(Y) = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 + \sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2$$

DEV (Y)= DEVIANZA DI RESIDUA + DEVIANZA DI REGRESSIONE

GRADO DI ADATTAMENTO

La **devianza di residua**: misura il grado di dispersione dei punti osservati intorno alla retta di regressione; è nulla in cui non vi è dispersione, cioè se i punti osservati sono allineati sulla retta di regressione e tutta la variabilità di Y è attribuibile alla dipendenza lineare della X.

La **devianza di regressione**: è quella parte delle variabilità della Y che viene spiegata dalla relazione lineare, è nulla se i valori teorici coincidono con la media della Y

GRADO DI ADATTAMENTO

Il grado di adattamento è definito dal coefficiente di determinazione lineare:

$$R^2 = \frac{Dev(\mathrm{Re}\, g)}{Dev(Y)} = \frac{\sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

Misura quanta parte della variabilità totale è spiegata dalla regressione

OPPURE

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

GRADO DI ADATTAMENTO

$$0 \leq R^2 \leq 1$$

$R^2 = 0$

La devianza di regressione è nulla, i valori teorici sono tutti costanti e pari al valore medio della Y.

$R^2 = 1$

La devianza residua è nulla, per cui la variabilità della Y è spiegata totalmente dalla variabile X, i valori osservati coincidono con i valori teorici

Analisi della interdipendenza

Due variabili sono interdipendenti quando non si può individuare un carattere antecedente all'altro che è conseguente

La correlazione misura il grado di concordanza e discordanza tra due variabili

Analisi della interdipendenza

Il coefficiente di correlazione lineare di Bravis-Pearson che fornice una misura del grado di correlazione lineare reciproca che esiste tra le due variabili X e Y

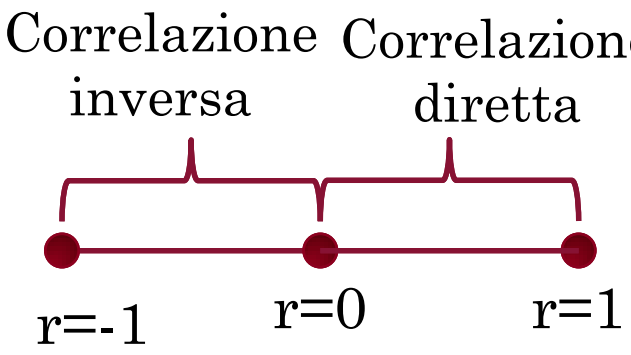
$$r = \frac{Cod(X,Y)}{\sqrt{Dev(X)\,Dev(Y)}}$$

Analisi della interdipendenza

Il coefficiente di correlazione è un numero puro, che varia tra -1 e 1 ed ha il segno algebrico della codevianza

(r = -1) Vi è perfetta correlazione lineare, vi è discordanza le due rette di regressione coincidono

(-1 < r < 0) Vi è discordanza



(r = 0) non vi è correlazione lineare, le variabili sono incorrelate, non vi è né concordanza, né discordanza

(0 < r < 1) Vi è concordanza

(r = 1) Vi è perfetta correlazione lineare, vi è concordanza le due rette di regressione coincidono

Analisi della interdipendenza

Si dimostra che il coefficiente di determinazione lineare è equivalente al quadrato del coefficiente di correlazione lineare:

$$R^2 = r^2$$

$$\mathbf{R^2 = r^2 = \frac{[Cod\ (X, Y)]^2}{Dev(X) * Dev(Y)}}$$

ESEMPIO

Si calcoli la retta di regressione ed il grado di adattamento

Prezzo (X)	Q. Domandata (Y)
24,3	850
12,7	1350
16,4	1120
20,4	650
18,1	980
13,7	1200

ESEMPIO

$$b_1 = \frac{COD(X,Y)}{DEV(X)} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2} \qquad b_0 = \bar{y} - b_1\bar{x}$$

X-M	Y-M
6,7	-175
-4,9	325
-1,2	95
2,8	-375
0,5	-45
-3,9	175

(X-Media)²	(Y-Media)²	(X-Media)(Y-Media)
44,89	30625	-1172,5
24,01	105625	-1592,5
1,44	9025	-114
7,84	140625	-1050
0,25	2025	-22,5
15,21	30625	-682,5
93,64	**318550**	**-4634**

MEDIA (X) = 17,6

MEDIA(Y) = 1025

ESEMPIO

$$b_1 = \frac{COD(X,Y)}{DEV(X)} = \frac{-4634}{93{,}64} = -49{,}4874$$

$$b_0 = 1025 - (-49{,}4874) \times 17{,}6 = 1895{,}978$$

DEV.(X)= **93,64**
DEV.(Y)= **318550**

COD. (X,Y)	**- 4634**

EQUAZIONE DELLA RETTA

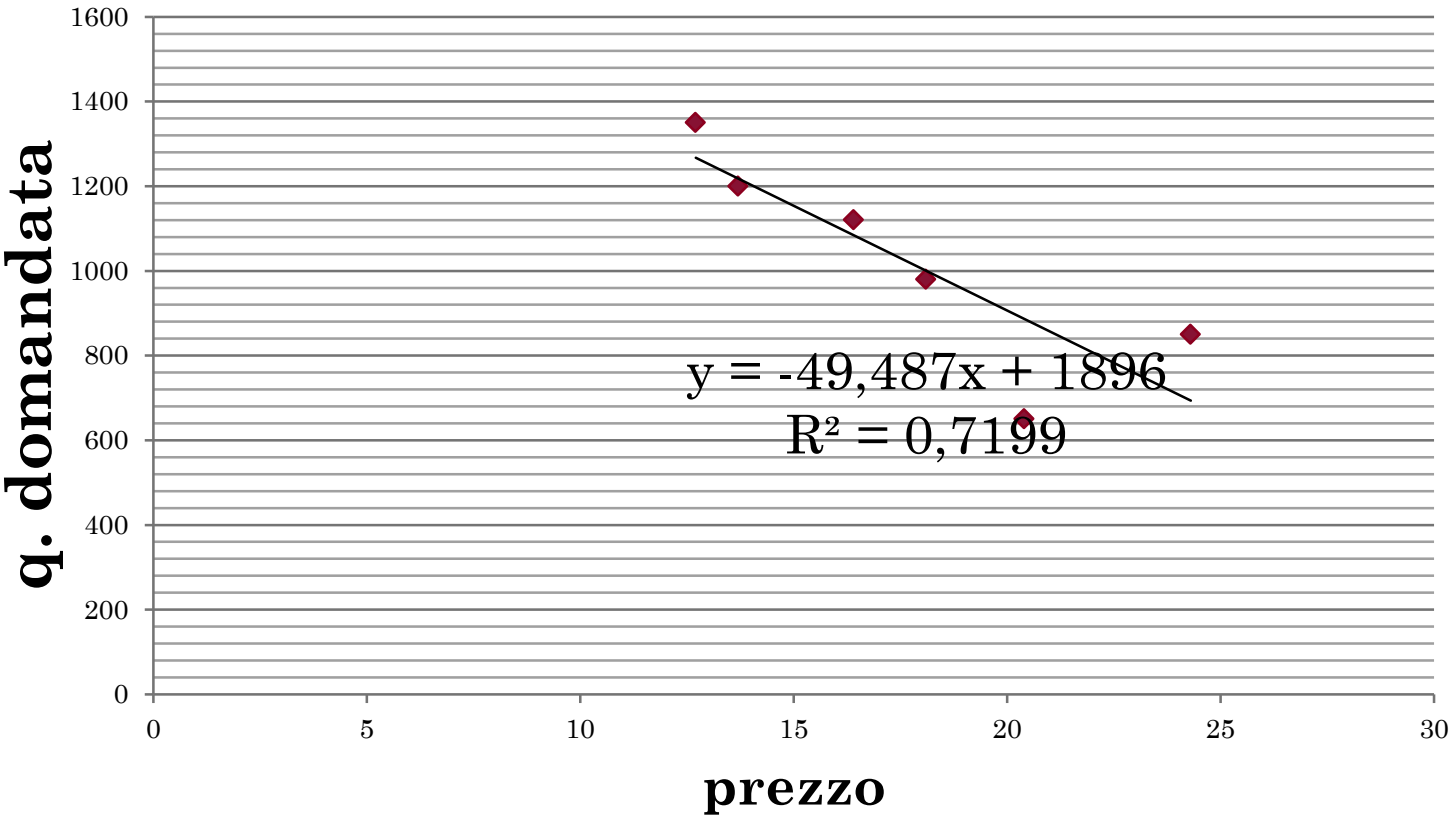
$$\hat{y}_i = 1895{,}978 - 49{,}4874x$$

ESEMPIO

$$R^2 = \frac{Dev(\mathrm{Re}\, g)}{Dev(Y)} = \frac{\sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} = \frac{229324,6}{318550} = 0,7199$$

$\hat{y}_i$	$(\hat{y}_i - \bar{y})^2$
693,4344 = 1895,978-49,4874*(24,3)	109935,7
1267,488	58800,55
1084,385	3526,564
886,4353	19200,18
1000,256	612,2507
1218,001	37249,33
	229324,6

ESEMPIO


1600
1400
1200
1000
800
600
400
200
0
0
5
10
15
20
25
30
q. domandata
prezzo
y = -49,487x + 1896
R² = 0,7199