PEGASO
Università Telematica
D.M. 20 04 2006 G.U. n° 118 del 23 05 2006

# Campionamento e distribuzioni campionarie

# Definizione di popolazione e di campione casuale

**Statistica Inferenziale:** procedimento logico- induttivo mediante il quale si perviene alla stima dei parametri incogniti della popolazione considerando le informazioni fornite dai valori campionari.

**Definizione di popolazione:**

Insieme delle unità statistiche sulle quali è presente o sono presenti la caratteristica o le caratteristiche oggetto di studio.

*La popolazione è assimilabile al concetto di v.c X.*

# Definizione di popolazione e di campione casuale

## DEFINIZIONE DI CAMPIONE CASUALE

**Campione:** Si intende un sottoinsieme ritenuto rappresentativo di una definita popolazione (universo), in modo che risultino accurate le informazioni sulle caratteristiche della popolazione che si traggono dal campione. Se nella scelta degli elementi da includere nel campione si rispettano alcune regole, è possibile valutare tali informazioni in termini probabilistici

# Definizione di popolazione e di campione casuale

**Campione casuale**: n-pla di v.c $X_1, X_2 ..., X_n$ i.i.d (condizioni verificate esattamente se l'estrazione è con ripetizione e da popolazione infinita). Ovviamente utilizzando un campione s' introduce una fonte di errore che con opportuni accorgimenti può essere minimizzato entro il limite di confidenza accettato

# Campionamento: estrazione con ripetizione e senza ripetizione

L'operazione di estrazione del campione da una popolazione può essere effettuata con ripetizione(bernoulliana) e senza ripetizione.

**Con ripetizione**: l'unità estratta è reinserita nella popolazione e può , quindi, comparire più volte. Ogni unità ha la stessa probabilità pari a 1/N di essere selezionata.

**Senza ripetizione**: l'unità estratta non viene più reinserita, per cui la probabilità di selezione di una unità varia ad ogni estrazione;1/N al primo tentativo; 1/(N-1) al secondo tentativo; 1/(N-2) al terzo e così via.

# Campionamento: estrazione con ripetizione e senza ripetizione

**Nota:** Quando la popolazione è teoricamente infinita CON O SENZA reintroduzione è ininfluente. (La probabilità che in un campione figuri più volte lo stesso elemento è del tutto trascurabile)

# Campionamento: estrazione con ripetizione e senza ripetizione

**Estrazione con Ripetizione (Estrazione Bernoulliana):**
Per esempio, con una popolazione di 500 elementi, ogni elemento che viene estratto ha P=1/500 e si dice che i relativi risultati delle estrazioni **SONO indipendenti.**

**Estrazione senza Ripetizione**
Stesso esempio di una popolazione di 500 elementi:
P1=1/500 (prob. che ha il 1°elemento di essere estratto)
P2=1/499 (prob. che ha il 2°elemento di essere estratto)
P3=1/498 (prob. che ha il 3°elemento di essere estratto)
e così via……

# Campionamento: estrazione con ripetizione e senza ripetizione

**Estrazione senza Ripetizione**

I risultati di queste estrazioni, **NON sono indipendenti.**

**La probabilità che un elemento della popolazione entri a far parte del campione è influenzata dal risultato delle estrazioni precedenti**

# Campionamento: estrazione con ripetizione e senza ripetizione

Esempio:

Da una popolazione composta da 5 unità statistiche ( A, B, C, D, E ) si voglia estrarre un campione casuale di numerosità 2.

**Schema con ripetizione (bernoulliano)**
Ciascuna unità campionata viene riposta nella popolazione e può essere estratta nuovamente

# Campionamento: estrazione con ripetizione e senza ripetizione

**Lo spazio campionario, ovvero l'insieme di tutti i possibili campioni è:**

AA AB AC AD AE
BA BB BC BD BE
CA CB CC CD CE
DA DB DC DD DE
EA EB EC ED EE

Vi sono in tutto 5^2 =25 campioni, dati dalle disposizioni con ripetizione di 5 elementi a 2 a 2.

# Campionamento: estrazione con ripetizione e senza ripetizione

**Schema senza ripetizione con estrazione di un elemento alla volta**

Ciascuna unità campionata viene tolta dalla popolazione e non può essere estratta nuovamente

**Lo spazio campionario, ovvero l'insieme di tutti i possibili campioni è:**

~~AA~~ AB AC AD AE
BA ~~BB~~ BC BD BE
CA CB ~~CC~~ CD CE
DA DB DC ~~DD~~ DE
EA EB EC ED ~~EE~~

Vi sono in tutto = 20 campioni, dati dalle disposizioni semplici

# STATISTICA E MOMENTI CAMPIONARI: MEDIA E VARIANZA CAMPIONARIA

Data una v.c X, che caratterizza la distribuzione di probabilità della popolazione; si suppone di estrarre da questa popolazione, in maniera casuale, campioni di ampiezza n. In generale, le osservazioni campionarie ottenute sono utilizzate attraverso una funzione nota (statistica) che esprime una sintesi delle stesse. Le caratteristiche di questi campioni saranno sintetizzate da uno o più valori; così per analizzare la tendenza centrale si utilizzerà la media campionaria; per analizzare la dispersione dei valori campionari si utilizzerà la varianza campionaria, o altri indici di variabilità

# STATISTICA E MOMENTI CAMPIONARI: MEDIA E VARIANZA CAMPIONARIA

- Se da una popolazione X si estraggono tutti i possibili campioni di ampiezza n e per ogni campione si calcola la statistica di interesse (media, mediana, varianza) definita come funzioni delle sole osservazioni campionarie e non dipendente da nessun parametro incognito si ottiene un insieme di valori ognuno dei quali è deputato ad essere una stima del parametro incognito della popolazione.
- Il modo in cui la statistica varierà da un campione ad un altro determina la distribuzione di probabilità della statistica (distribuzione campionaria della statistica)

# Statistica e momenti campionari: media e varianza campionaria

**Osservazione:**
A seconda della specificazione della statistica possiamo avere la distribuzione campionaria della media, della mediana, della varianza, ecc., ciascuna caratterizzata da una propria distribuzione campionaria.

# STATISTICA E MOMENTI CAMPIONARI: MEDIA E VARIANZA CAMPIONARIA

Teorema: Sia X1, X2 ,., Xn un campione casuale di n osservazioni estratto dalla popolazione X. Esso è formato da n v.c indipendenti ed identicamente distribuite con media μ e varianza $\sigma^2$. Si ha allora:

$$E(\bar{X}) = \mu \qquad VAR(\bar{X}) = \frac{\sigma^2}{n}$$

Campionamento con ripetizione

$$\sqrt{VAR(\bar{X})} = \frac{\sigma}{\sqrt{n}}$$

Errore standard della media

Rappresenta una misura di variabilità delle medie campionarie attorno alla media della popolazione

# STATISTICA E MOMENTI CAMPIONARI: MEDIA E VARIANZA CAMPIONARIA

Considerando tutte le medie campionarie ed associando ad ogni media distinta la sua probabilità, si ottiene la distribuzione di probabilità della media campionaria

La **distribuzione campionaria** rappresenta la probabilità che la media calcolata su un campione assume valore $\bar{x}$

Se $X_1, X_2 ..., X_n$ è un campione casuale generato da $X \approx N(\mu, \sigma^2)$

Si ha che $$\bar{X} \approx N(\mu, \frac{\sigma^2}{n})$$

e pertanto la v.c $Z$

$$Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \approx N(0,1)$$

# Distribuzione della media. popolazione finita

Media campionaria. Campionamento senza ripetizione

Se si considera, invece, una popolazione finita in cui viene estratto un campione senza ripetizione allora:

$$E(\bar{X}) = \mu$$

$$Var(\bar{X}) = \frac{\sigma^2}{n}\frac{(N-n)}{(N-1)}$$

Fattore di correzione per popolazioni finite

# Confronto tra i due schemi di campionamento

Per n=N $Var(\overline{X}) = 0$ in tal caso il campione coincide con la popolazione.

Se n< N e quindi $\frac{N-n}{N-1} < 1$ si ha che la $Var(\overline{X})$ in uno schema di campionamento senza ripetizione è più piccola di quella che si avrebbe in un campionamento con ripetizione

Facendo tendere N all'infinito la quantità $\frac{N-n}{N-1}$

tende ad assumere valore 1

Quindi quando la popolazione è infinita i due schemi di campionamento coincidono.

# Confronto tra i due schemi di campionamento

NOTA: una popolazione finita nel quale si compie un campionamento con ripetizione può essere considerata infinita, dato che si può estrarre  un numero qualsiasi di campioni senza esaurire la popolazione. Per scopi pratici il campionamento da una popolazione finita  molto grande può essere considerato come un campionamento da popolazione infinita.

# Esempio di universo campionario e distribuzione campionaria della media

PEGASO
Università Telematica
D.M. 20 04 2006 G.U. n° 118 del 23 05 2006

ESEMPIO: Data una v.c X (popolazione) che assume valori: 6,8,10,12 ognuno con probabilità pari a 1/4 (distribuzione uniforme discreta). La media di X è pari a 9 mentre la varianza è pari a 5. Si estraggono da X campioni (X1, X2) di ampiezza 2 con reimmissione.



# Esempio di universo campionario e distribuzione campionaria della media

| Campioni | | Media Campionaria | Media Campionaria (valori distinti) | Funzione di Prob. |
|---|---|---|---|---|
| X1 | X2 | | | |
| 6 | 6 | 6 | 6 | 1/16 |
| 6 | 8 | 7 | 7 | 2/16 |
| 6 | 10 | 8 | 8 | 3/16 |
| 6 | 12 | 9 | 9 | 4/16 |
| 8 | 6 | 7 | 10 | 3/16 |
| 8 | 8 | 8 | 11 | 2/16 |
| 8 | 10 | 9 | 12 | 1/16 |
| 8 | 12 | 10 | | |
| 10 | 6 | 8 | | |
| 10 | 8 | 9 | | |
| 10 | 10 | 10 | | |
| 10 | 12 | 11 | | |
| 12 | 6 | 9 | | |
| 12 | 8 | 10 | | |
| 12 | 10 | 11 | | |
| 12 | 12 | 12 | | |

parametro

$$E(\bar{X}) = \mu = 9$$

$$Var(\bar{X}) = 5/2$$

Statistica osservata

# Esempio di universo campionario e distribuzione campionaria della media

La v.c $X_1$ e la v.c $X_2$ hanno media pari a 9 e varianza pari a 5 come la v.c X e seguono la stessa distribuzione di probabilità della popolazione; inoltre le due v.c sono tra loro indipendenti, in quanto la probabilità congiunta di ogni coppia (X1 e X1) è data dalla probabilità marginale di X1 per la probabilità marginale di X2

$$f(x_1, x_2) = f(x_1) f(x_2) = 1/16$$

$$f(8,12) = f(8) f(12) = 1/16$$

$$f(8,12) = f(1/4) f(1/4) = 1/16$$

# Teorema centrale della statistica: teorema limite centrale

Teorema centrale della statistica: teorema del limite centrale (Lindeberg-Lèvy 1922)

Date n v.c. $X_1,\ldots,X_n$ estratte da una popolazione X con media $\mu$ e varianza $\sigma^2$ indipendenti e identicamente distribuite e tali che

$$E(X_i)=\mu \qquad Var(X_i)=\sigma^2 \qquad i=1,\ldots,n$$

e sia:

$$Z_n=\frac{\overline{X}_n-E(\overline{X}_n)}{\sqrt{Var(\overline{X}_n)}}=\frac{\overline{X}_n-\mu}{\sigma/\sqrt{n}} \qquad \overline{X}_n=\sum_{i=1}^{n}X_i/n$$

# Teorema centrale della statistica: teorema limite centrale

Allora la distribuzione di $Z_n$ converge alla normale standardizzata per $n \to \infty$

Il teorema del limite centrale stabilisce che, al crescere di n,

la forma della distribuzione della media campionaria si approssima alla forma normale.

In pratica si ritiene che l'approssimazione sia accettabile per $n > 30$

# TEOREMA DI DE MOIVRE- LAPLACE

**Teorema di De Moivre-Laplace (Applicazione del teorema del limite centrale)**

Date n v.c. $X_1,\ldots X_n$ indipendenti generate da $X \approx B(1,p)$ la variabile (numeri di successi in n prove indipendenti)

$$S_n = \sum_{i=1}^{n} X_i$$

segue una distribuzione binomiale con

$$E(S_n) = np \quad Var(S_n) = npq$$

# TEOREMA DI DE MOIVRE- LAPLACE

**Teorema di De Moivre-Laplace (Applicazione del teorema del limite centrale)**

Se si pone:

$$Y_n = \frac{S_n - E(S_n)}{\sqrt{npq}} = \frac{S_n - np}{\sqrt{npq}}$$

Al tendere di n all'infinito la distribuzione $Y_n$ tende alla distribuzione normale standardizzata.

# TEOREMA DI DE MOIVRE- LAPLACE

- La rapidità con la quale la distribuzione binomiale converge a quella normale dipende dal valore di p, nel senso che la migliore condizione di convergenza si ha quando la distribuzione binomiale è simmetrica cioè quando p = q = 0,5.

- Agli effetti pratici l'approssimazione è ritenuta accettabile se np e nq sono entrambi maggiori o uguali a 5. L'approssimazione si può comunque migliorare ricorrendo alla cosiddetta correzione per continuità. Poiché la binomiale è discreta e la gaussiana è continua, ai fini del calcolo approssimato si considera ogni valore intero x come centro dell'intervallo ( x-0,5; x+0,5 ).

# TEOREMA DI DE MOIVRE- LAPLACE

- Esempio

Una moneta viene lanciata 500 volte. Trovare la probabilità che il numero di teste sia compreso tra 220 e 280

$$\mu = np = 500 \cdot 1/2 = 250 \qquad \sigma = \sqrt{npq} = \sqrt{500 \cdot 1/2 \cdot 1/2} = 11{,}18$$

Considerando i dati continui , tra 219.5 e 280.5

219.5 in unità standard vale (219.5- 250)/11.18= -2.73

280.5 in unità standard vale (280.5-250)/11.18= 2,73

Probabilità richiesta = (doppio dell'area compresa tra z=0 e z=-2.73)=2(0.4968)=0.9936