PEGASO
Università Telematica
D.M. 20 04 2006 G.U. n° 118 del 23 05 2006

VERIFICA DELLE IPOTESI NON PARAMETRICHE

INTRODUZIONE

Nella verifica delle ipotesi parametriche abbiamo ipotizzando che la variabile X, che descrive la popolazione, avesse una certa distribuzione di probabilità, generalmente quella normale.

Qui, invece, affronteremo ipotesi di tipo non parametrico e si supporrà di non conoscere ne la forma della distribuzione di probabilità del fenomeno osservato, ne il valore dei parametri di questa legge.

INTRODUZIONE

Sarà la natura, la conoscenza del fenomeno, e la distribuzione osservata che permetteranno di scegliere tra le distribuzioni di probabilità teoriche quella più appropriata a descrivere il fenomeno

INTRODUZIONE

Ipotesi non parametrica:

- attinente alla funzione che descrive la distribuzione di probabilità della popolazione (ipotesi funzionale)
- attinente all'indipendenza stocastica tra due variabili

Infine, opereremo sulle frequenze invece di fare il confronto tra paramenti ipotizzati sotto H_0 e H_1 e funzioni dei parametri stimati sul campione

VERIFICA DELL'IPOTESI DI INDIPENDENZA

Data una popolazione le cui unità sono classificate secondo due variabili A e B rispettivamente con r e c modalità e sia p_{ij} la probabilità che le unità presentino congiuntamente le modalità A_i e B_j (i=1,…,r e j=1,…,c)
Sia n_{ij} il numero delle unità osservate in un campione di ampiezza n che presentano le stesse modalità A_i e B_j.

VERIFICA DELL'IPOTESI DI INDIPENDENZA

PEGASO Università Telematica

Tabella delle probabilità

	B_1	…	B_j	…	B_c	
A_1	p_{11}	…	p_{1j}	…	p_{1c}	$p_{1\cdot}$
.	.		.		.	
A_i	p_{i1}	…	p_{ij}	…	p_{ic}	$p_{i\cdot}$
.	.		.		.	
A_r	p_{r1}	…	p_{rj}	…	p_{rc}	$p_{r\cdot}$
	$p_{\cdot 1}$		$p_{\cdot j}$		$p_{\cdot c}$	1

Tabella delle frequenze assolute

	B_1	…	B_j	…	B_c	
A_1	n_{11}	…	n_{1j}	…	n_{1c}	$n_{1\cdot}$
.	.		.		.	
A_i	n_{i1}	…	n_{ij}	…	n_{ic}	$n_{i\cdot}$
.	.		.		.	
A_r	n_{r1}	…	n_{rj}	…	n_{rc}	$n_{r\cdot}$
	$n_{\cdot 1}$		$n_{\cdot j}$		$n_{\cdot c}$	n

$$0 \le n_{ij} \le n \quad \sum_{i=1}^{r}\sum_{j=1}^{c} n_{ij} = n \quad n_{i\bullet} = \sum_{j=1}^{c} n_{ij} \quad n_{\bullet j} = \sum_{i=1}^{r} n_{ij}$$

VERIFICA DELL'IPOTESI DI INDIPENDENZA

L'ipotesi che si formula è quella dell'indipendenza delle righe e delle colonne che si traduce nella seguente:

$$P(A_i, B_j) = P(A_i)P(B_j)$$

Le due variabili sono stocasticamente indipendenti

L'ipotesi nulla da verificare è pertanto:

Ipotesi nulla

$$H_0 : p_{ij} = p_{i\bullet}p_{\bullet j}$$

Per ogni coppia (i,j)

contro,

Ipotesi alternativa

$$H_1 : p_{ij} \neq p_{i\bullet}p_{\bullet j}$$

Per almeno una coppia (i,j)

VERIFICA DELL'IPOTESI DI INDIPENDENZA

PEGASO
Università Telematica

Se le probabilità $p_{i\cdot}$ e $p_{\cdot j}$ sono note, l'adattamento tra la distribuzione osservata e quella teorica può essere verificata utilizzando la seguente quantità:

$$X^2 = \sum_{i=1}^{r}\sum_{j=1}^{c} \frac{\left(n_{ij} - np_{i\bullet}p_{\bullet j}\right)^2}{np_{i\bullet}p_{\bullet j}}$$

Tale v.c. X^2 per n sufficientemente grande segue sotto l'ipotesi H_0 approssimativamente una legge χ^2

VERIFICA DELL'IPOTESI DI INDIPENDENZA

Di solito non si conoscono le $p_{i\bullet}$ e $p_{\bullet j}$ ed è necessario stimarle con i dati disponibili.

Le quantità $p_{i\bullet}$ e $p_{\bullet j}$ sono stimate nel seguente modo:

$$\hat{p}_{i\bullet} = \frac{n_{i\bullet}}{n} \qquad \hat{p}_{\bullet j} = \frac{n_{\bullet j}}{n}$$

Se si osservano le disuguaglianze: $n_{ij} \neq \hat{n}_{ij} = \frac{n_{i\bullet} n_{\bullet j}}{n}$

e queste tendono a crescere al crescere di n, si può ritenere che i due caratteri siano statisticamente connessi.

VERIFICA DELL'IPOTESI DI INDIPENDENZA

La connessione statistica riguarda l'allontanamento dall'ipotesi di indipendenza stocastica, quindi appare naturale mettere a confronto le frequenze n_{ij} con quelle teoriche.

Quindi la statistica test è:

$$\chi^2 = \sum_{i=1}^{r}\sum_{j=1}^{c} \frac{\left(n_{ij} - n\hat{p}_{i\bullet}\hat{p}_{\bullet j}\right)^2}{n\hat{p}_{i\bullet}\hat{p}_{\bullet j}}$$

VERIFICA DELL'IPOTESI DI INDIPENDENZA

I gradi di libertà sono: $(r-1)(c-1)$

La regola di decisione sarà del seguente tipo:

Se $\chi^2 < \chi^2_{\alpha;(r-1)(c-1)}$ Si accetta H_0 (indipendenza) altrimenti H_1

ESEMPIO

Esempio:
Si vuole effettuare un'indagine per stabilire se esiste o meno una relazione tra zona di residenza (A,B,C) e preferenza di auto. Furono scelti casualmente 160 proprietari da grossi centri (A), 140 proprietari da zone periferiche (B) e 100 proprietari dalle campagne (C) e risulto la seguente tabella di contingenza:

	Auto italiane	Auto europee	Auto extra-europee	
A	120	20	20	160
B	50	30	60	140
C	50	10	40	100
	220	60	120	400

ESEMPIO

$H_0 : p_{ij} = p_{i\bullet} p_{\bullet j}$ $\quad H_0$: Zona di residenza e preferenza sono indip.

$H_1 : p_{ij} \neq p_{i\bullet} p_{\bullet j}$ $\quad H_1$: Zona di residenza e preferenza non sono indip.

$$\alpha = 0{,}05$$

$$g.l = (r-1)\cdot(c-1) = (3-1)\cdot(3-1) = 4$$

ESEMPIO

Frequenze teoriche

88	24	48
77	21	42
55	15	30

$$\frac{n_{i.} \cdot n_{.j}}{n} = \frac{160 \cdot 220}{400} = 88$$

$$\frac{(120-88)^2}{88} = 11{,}64$$

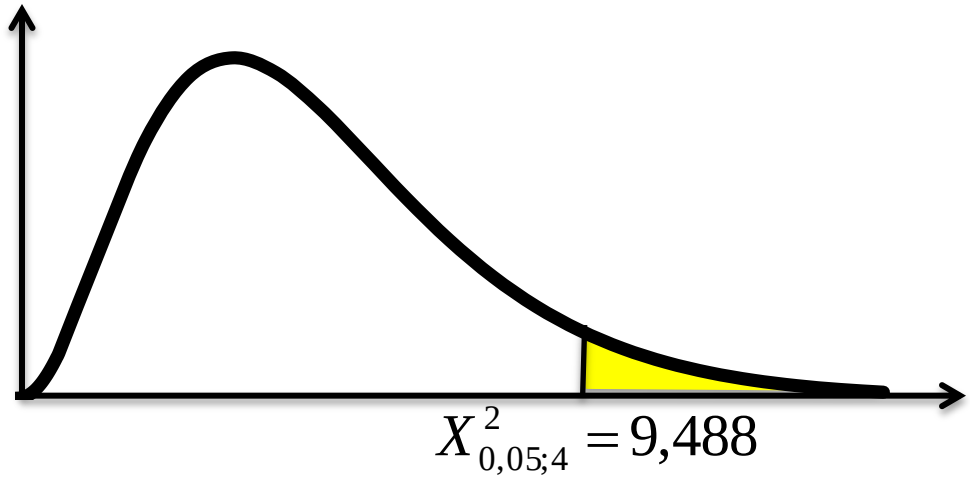
Cont. al q / fr teor.

11,64	0,67	16,33	28,64
9,47	3,86	7,71	21,04
0,45	1,67	3,33	5,45

$\chi^2 \longrightarrow 55{,}13$

Esempio

$$55{,}13 > 9{,}488$$



Si rifiuta H_0 (quindi non esiste indipendenza tra zona di residenza e preferenza)

Esempio

Lettura della tavola chi-quadrato

	α					
n	0,25	0,1	0,05	0,025	0,01	0,005
1	1,323	2,706	3,841	5,024	6,435	7,879
2	2,773	4,605	5,991	7,378	9,210	10,597
3	4,108	6,251	7,815	9,348	11,345	12,838
4	5,385	7,779	9,488	11,143	13,277	14,860
…	…	…	…	…	…	…
20	23,828	28,412	31,410	34,170	37,566	39,991
…	…	…	…	…	…	…
…	…	…	…	…	…	…
100	109,141	118,498	124,342	129,561	135,807	140,169