PEGASO
Università Telematica
D.M. 20 04 2006 G.U. n° 118 del 23 05 2006

Il modello di regressione lineare semplice

INTRODUZIONE

In molti problemi economici, demografici, biologici e sociali i fenomeni appaiono legati ad una rete di rapporti che si influenzano in modo reciproco.

A volte è possibile individuare un carattere esplicativo rispetto ad un altro carattere (dipendente) e si pone il problema di studiare come le modalità del carattere quantitativo dipendente variano al variare delle modalità del carattere esplicativo (regressione semplice) o di più caratteri (regressione multipla).

INTRODUZIONE

L'analisi di regressione consiste nello sviluppo di un modello statistico che possa essere adottato per analizzare i valori della variabile dipendente (Y) sulla base dei valori di almeno una variabile esplicativa (X) o indipendente

IPOTESI ALLA BASE DEL MODELLO

Ipotesi di linearità: Il modello di regressione è lineare nei parametri

$$E(Y_i / x_i) = \beta_0 + \beta_1 x_i$$

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \quad E(\varepsilon_i) = 0$$

Nota: Concetto di linearità

Linearità nei parametri: una funzione è lineare nei parametri se ß1 appare con un "power" pari a 1 e non è moltiplicato per un qualsiasi altro parametro (es.ß1ß2; ß1/ß2)

IPOTESI ALLA BASE DEL MODELLO

Linearità nelle variabili: si ha linearità nella variabili se X appare con un indice di 1, e non è moltiplicata o divisa per un'altra variabile XZ. Se Y è linearmente legata a X, il tasso di cambiamento di Y rispetto a X (cioè, lo slope, o derivata,di Y rispetto a X, dY/dX) è indipendente dal valore di X. Se $Y=4X$ $dY/dX=4$ ma se $Y=4X^2$ allora $dY/dX=8X$.

IPOTESI ALLA BASE DEL MODELLO

Ipotesi di varianza costante: Omoschedasticità

La varianza della v.c Y_i rimane costante al variare di x_i e dunque non dipende da x_i. Ciò significa che le Y_i variano nello modo sia che X assume un valore basso sia che assuma un valore alto.

$$Var(Y_i) = E[Y_i - E(Y_i)]^2 = \sigma_i^2 = \sigma^2$$

$$Var(Y_i) = E[Y_i - E(Y_i)]^2 = E(\varepsilon_i^2) = E[\varepsilon_i - E(\varepsilon_i)]^2 = Var(\varepsilon_i)$$

IPOTESI ALLA BASE DEL MODELLO

Ipotesi di Normalità (ipotesi forte):

$$Y_i \approx N\left(\beta_0 + \beta_1 x_i; \sigma^2\right) \qquad \varepsilon_i \approx N\left(0; \sigma^2\right)$$

Gli errori hanno una distribuzione normale
La variabile Y ha una distribuzione normale

Ipotesi di indipendenza:

$$Cov\left(Y_i, Y_j\right) = Cov\left(\varepsilon_i, \varepsilon_j\right) = 0$$

Questa condizione stabilisce che ogni dato statistico non è influenzato dall'altro. Ogni valore della variabile dipendente è statisticamente indipendente da ogni altro valore della variabile dipendente.

IPOTESI ALLA BASE DEL MODELLO

Ipotesi sulla variabile esplicativa (ipotesi debole)

La variabile Y è considerata una v.c., mentre le modalità distinte della variabile X sono di natura deterministica, cioè fissate dal ricercatore.

Stima dei parametri: metodo dei minimi quadrati

Con l'analisi di regressione si vogliono stimare i coefficienti di regressione β_0, β_1, sulla base di n osservazioni campionarie (x_i, y_i)

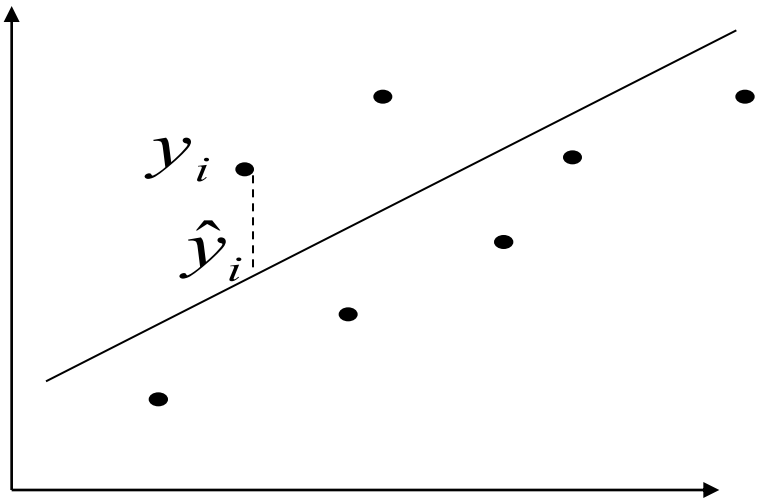
Estratto un campione casuale si consideri il modello lineare:

$$y_i = b_0 + b_1 x_i + e_i = \hat{y}_i + e_i$$

STIMA DEI PARAMETRI: METODO DEI MINIMI QUADRATI

L'analisi di regressione lineare si pone l'obiettivo di trovare la retta che meglio si adatta ai dati disponibili. Trovare il miglior adattamento significa individuare la retta che rende minima la differenza tra i valori effettivi y_i ed i valori teorici $\hat{y}_i$. Una tecnica matematica per individuare tale retta è il **metodo dei minimi quadrati**.

Si minimizza la somma dei quadrati degli scarti tra i valori osservati e i valori teorici



Stima dei parametri: metodo dei minimi quadrati

$$S(b_0, b_1) = \sum_{i=1}^{n} e_i^2 = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \sum_{i=1}^{n} (y_i - b_0 - b_1 x_i)^2$$

Uguagliando a zero le derivate parziali rispetto ai coefficienti b_0 e b_1 si ha:

$$\frac{\partial S}{\partial b_0} = -2 \sum_{i=1}^{n} [y_i - b_0 - b_1 x_i] = 0$$

$$\frac{\partial S}{\partial b_1} = -2 \sum_{i=1}^{n} [(y_i - \bar{y}) - b_1 (x_i - \bar{x})](x_i - \bar{x}) = 0$$

risolvendo rispetto a b_0 e b_1 si ha:

Stima dei parametri: metodo dei minimi quadrati

PEGASO
Università Telematica
D.M. 20 04 2006 G.U. n° 118 del 23 05 2006

$$b_0 = \bar{y} - b_1 \bar{x}$$

$$b_1 = \frac{\frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{n}}{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n}} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2} = \frac{\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^{n} x_i^2 - n\bar{x}^2}$$

PROPRIETA' RETTA MINIMI QUADRATI

- È l'unica retta che minimizza la somma dei quadrati dei residui
- La retta passa per il punto (media di x; media di y) come centro di gravità
- La somma dei residui è uguale a 0
- La somma dei valori osservati è uguale alla somma dei valori teorici, quindi i valori osservati e i valori teorici presentano la stessa media
- Il coefficiente angolare indica la variazione di Y in corrispondenza di una variazione unitaria di X

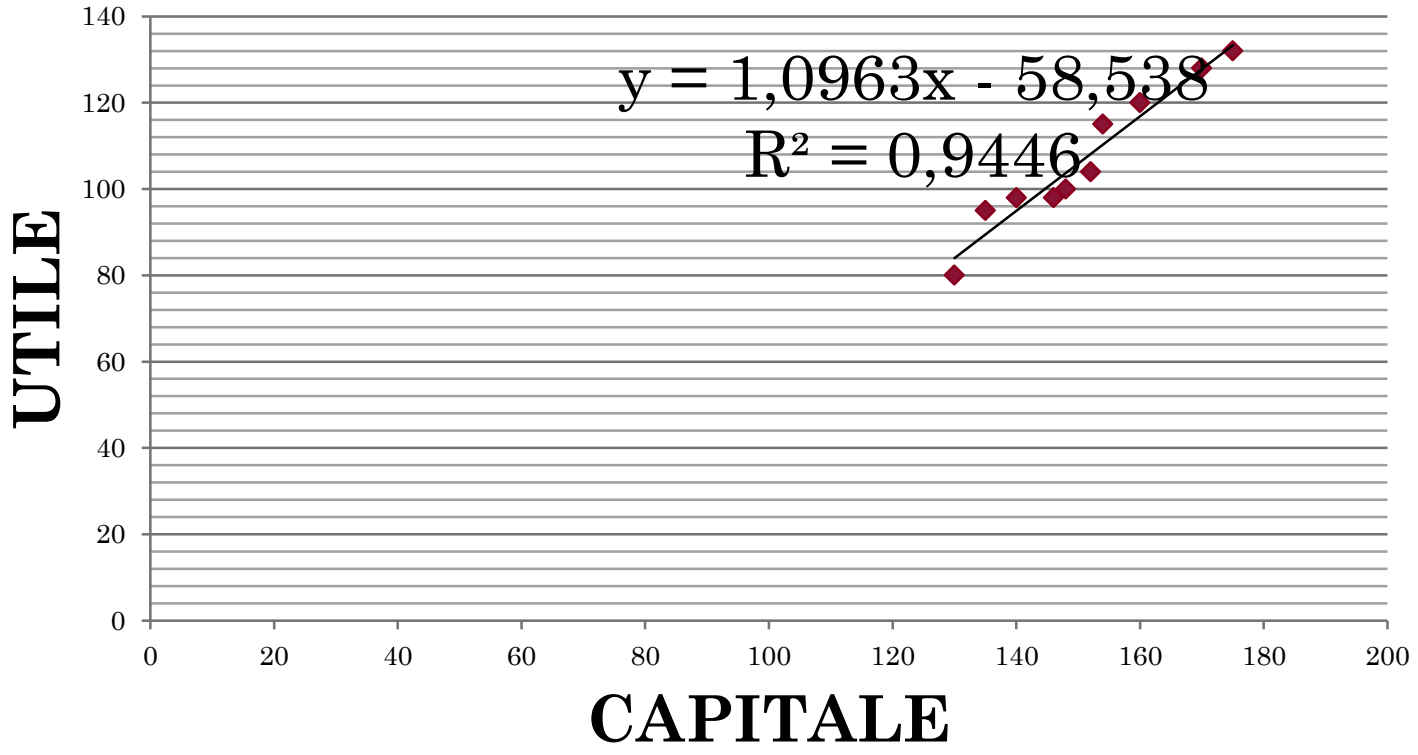
ESEMPIO

Si vuole studiare la relazione tra utili e capitale:

Capitale (X)	Utile(Y)
130	80
135	95
140	98
146	98
148	100
152	104
154	115
160	120
170	128
175	132

ESEMPIO

Si vuole studiare la relazione tra utili e capitale:



PROPRIETA' DEGLI STIMATORI DEI MINIMI QUADRATI

Al variare del campione b_0 e b_1 descrivono due v.c. B_0 e B_1 , che possono essere considerati come stimatori naturali di β_0 e β_1

PROPRIETA' DEGLI STIMATORI DEI MINIMI QUADRATI

Analizziamo le principali caratteristiche di questi stimatori:

Valore atteso:

$$E(B_1) = \beta_1$$

$$E(B_0) = \beta_0$$

Stimatori corretti

Varianza:

$$Var(B_1) = \frac{\sigma^2}{S_{xx}}$$

$$S_{xx} = \sum_{i=1}^{n} (x_i - \bar{x})^2$$

$$Var(B_0) = \frac{\sigma^2}{n} \frac{\sum_{i=1}^{n} x_i^2}{S_{xx}}$$

PROPRIETA' DEGLI STIMATORI DEI MINIMI QUADRATI

Stima del parametro σ^2: si consideri la differenza tra il valore osservato e quello teorico:

$$e_i = y_i - \hat{y}_i$$

La somma dei quadrati dei residui è data da:

$$SSE = \sum_{i=1}^{n} e_i^2 = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

Un modo per calcolare SSE senza passare per i valori teorici è il seguente:

$$SSE = S_{yy} - b_1 S_{xy} = S_{yy} - b_1^2 S_{xx}$$

PROPRIETA' DEGLI STIMATORI DEI MINIMI QUADRATI

Teorema: al variare del campione SSE varia e descrive una v.c. SSE* il cui valore atteso è:

$$E\left(SSE^*\right) = (n-2)\sigma^2$$

Uno stimatore corretto di σ^2, con le ipotesi di varianza costante e dell'indipendenza degli errori, è pertanto:

$$MSE^* = \frac{SSE^*}{n-2} \qquad E\left(MSE^*\right) = \sigma^2$$

PROPRIETA' DEGLI STIMATORI DEI MINIMI QUADRATI

Proprietà dell'efficienza degli stimatori dei minimi quadrati. Teorema di Gauss-Markov

Si può dimostrare che, nella classe degli stimatori lineari e corretti, gli stimatori dei minimi quadrati sono i più efficienti, cioè, con varianza minima (BLUE).