PEGASO
Università Telematica
D.M. 20 04 2006 G.U. n° 118 del 23 05 2006

Lezione
“ Il coefficiente di correlazione e la covarianza”

PEGASO

La Covarianza

La "covarianza" tra le componenti della variabile statistica (X, Y) è la media dei prodotti degli scarti delle variabili X e Y dalle rispettive medie aritmetiche $M(X)$ e $M(Y)$.

PEGASO

$$Cov(X,Y) = \bar{m}_{11} = M\{(X - m_{10})(Y - m_{01})\}$$
$$= \frac{1}{n}\sum_{k=1}^{n}\big(x_k - M(X)\big)\big(y_k - M(Y)\big)$$

PEGASO

Covarianza

La Covarianza può essere:

- *POSITIVA*: quando X e Y variano tendenzialmente nella stessa direzione, cioè al crescere della X tende a crescere anche Y e al diminuire della X tende a diminuire anche Y.

- *NEGATIVA*: quando le due variabili variano tendenzialmente in direzione opposta, cioè quando al crescere di una variabile l'altra variabile tende a diminuire (e viceversa).

- *NULLA*: quando non vi è alcuna tendenza delle 2 variabili a variare nella stessa direzione o in direzione opposta. Quando Cov(X,Y) = 0 si dice anche che X ed Y sono non correlate o linearmente indipendenti.

Il coefficiente di correlazione r di Pearson

La correlazione indica il grado della relazione tra variabili, e per mezzo di essa si cerca di determinare quanto bene un'equazione lineare o un'altra equazione qualsiasi descrivano o spieghino tale relazione tra variabili. Se tutti i valori delle variabili soddisfano esattamente ad un'equazione, si dice che le variabili sono *perfettamente correlate*.

PEGASO

Correlazione

- Un modalità più rigorosa che consente di studiare il ***grado di intensità*** del legame lineare tra coppie di variabili.

$$r_{xy} = \frac{Cov(X,Y)}{\sqrt{(VarX)(VarY)}}$$

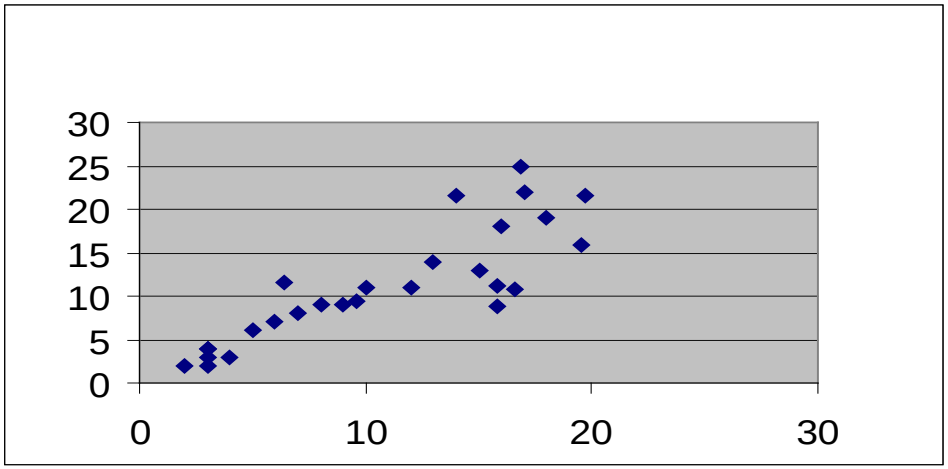
Il **r** viene utilizzato per misurare la relazione lineare tra due variabili su scale ad intervalli o a rapporti.

Il coefficiente di correlazione:
✓ varia da –1 a 1 (se uguale a 1 o a -1: perfettamente correlate)
✓ è positivo quando i valori delle variabili crescono insieme
✓è negativo quando i valori di una variabile crescono al decrescere dei valori dell'altra
✓ non è influenzato dalle unità di misura

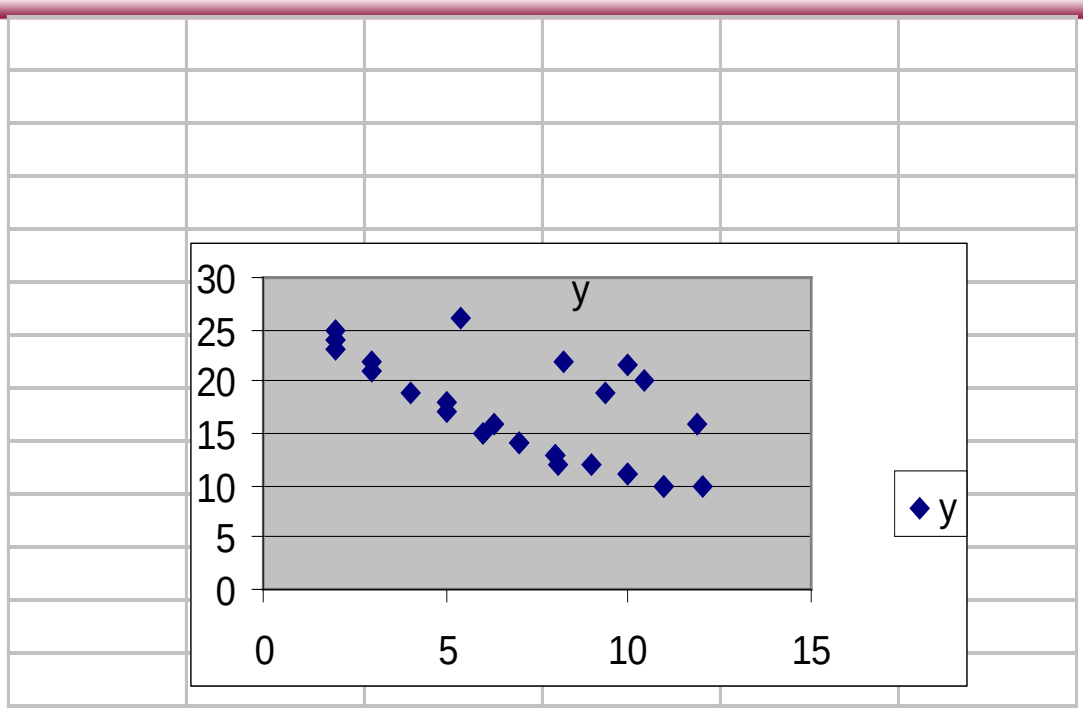
PEGASO

Se X e Y indicano le due variabili considerate (si può ad esempio ipotizzare che X è l'altezza dei genitori ed Y quella dei figli), si può costruire in un sistema di coordinate cartesiane un *diagramma a dispersione*.

Se tutti i punti del diagramma sembrano giacere intorno ad una retta (che, se minimizza la somma dei quadrati degli scarti tra i valori osservati e quelli relativi ai punti della retta stessa, si può definire *di regressione)* **la correlazione è detta lineare.**



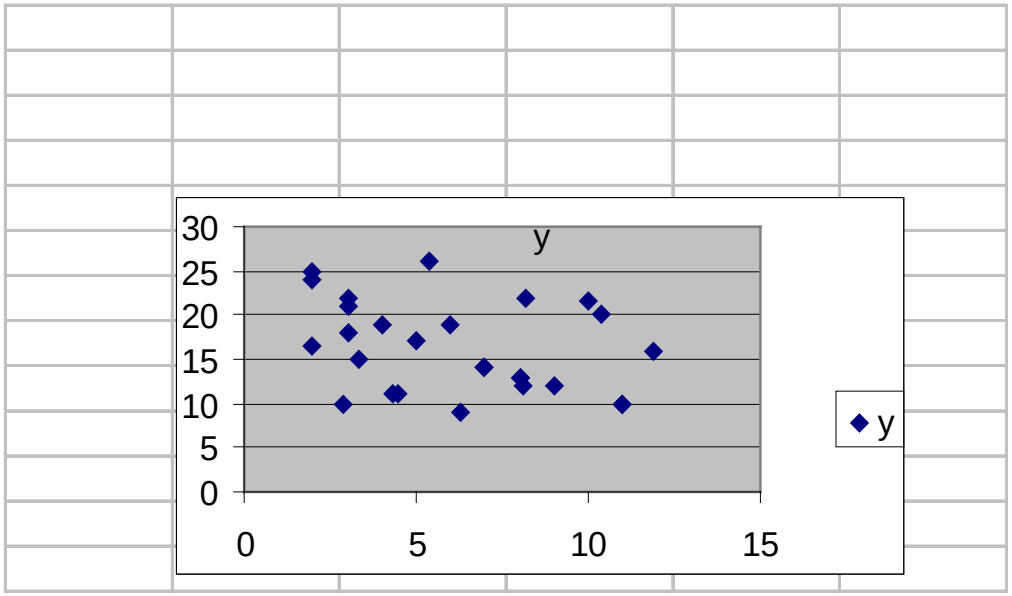
Correlazione lineare negativa



Un esempio di correlazione negativa è quella tra il peso X e la speranza di vita Y

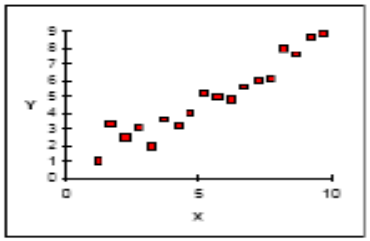
Assenza di correlazione

In tale caso non vi è relazione tra le variabili



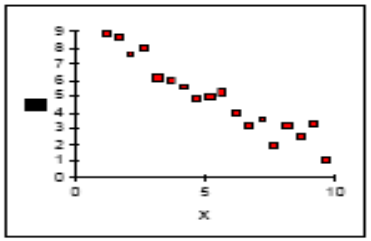
PEGASO

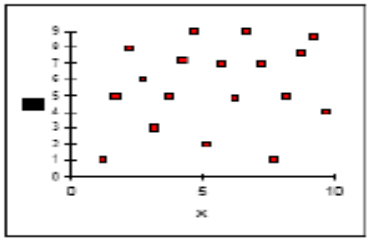
Coefficiente di correlazione - esempi



r=0,96

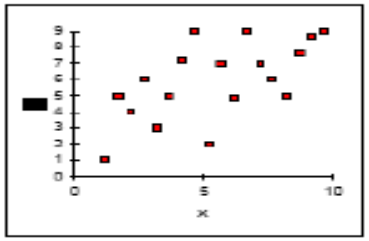
r=-0,96





r=0,12

r=0,62



r=1: punti perfettamente allineati su una retta con pendenza positiva

r=-1: punti perfettamente allineati su una retta con pendenza negativa

La correlazione spuria

Correlazione: rischi nell'interpretazione

- Un'elevata correlazione fra due variabili NON implica una relazione causa-effetto
- La correlazione non è equivalente alla dipendenza
- La correlazione è molto sensibile agli outliers: due o tre outliers possono portare il coefficiente di corrrelazione a livelli molto bassi

Funzioni excel utili

- RQ(<Y>;<X>) calcola l'indice di determinazione R^2

Tale valore esprime la dispersione dei valori osservati intorno alla retta di regressione.