PEGASO
Università Telematica
D.M. 20 04 2006 G.U. n° 118 del 23 05 2006

Lezione
"Correlazione illusoria e spuria""

PEGASO

La correlazione: come valutarla?

Non sempre ad un valore elevato di r corrisponde un effettivo legame tra i due caratteri quantitativi considerati.

Un primo caso di correlazione non reale si ha quando uno dei caratteri comprende l'altro, cioè quando si misura la correlazione tra la misura di una parte ed il tutto, ad esempio tra mortalità infantile e mortalità generale, tra prezzo dei pneumatici e prezzo dell'autovettura, tra studenti universitari in complesso e di Economia.

PEGASO

In questo primo caso è facile comprendere che tale correlazione è mal posta se calcolata sulle cifre assolute, entrambe influenzate da circostanze comuni, come, per l'esempio degli studenti universitari: l'aumento della popolazione, l'aumento o la diminuzione della propensione allo studio, le possibilità finanziarie delle famiglie.

PEGASO

Un **seconda** tipologia di correlazione «mal posta» si ha quando altri fattori variabili influiscono più o meno fortemente su quelli presi in considerazione: in tali casi la correlazione tra X ed Y è in gran parte dovuta a quella esistente tra ciascuna variabile ed una o più altre variabili.

PEGASO

Ad esempio, in questa seconda tipologia si può considerare il caso della correlazione positiva tra la produzione nel tempo di varie coppie di prodotti agricoli (ad es. olio e vino) che può essere dovuta all’influenza che le condizioni meteorologiche hanno su entrambe.

PEGASO

Un altro caso, conosciuto in letteratura, è quello tra il numero di malati di mente e radio-abbonati in Gran Bretagna (il caso risale a decine di anni fa): il coefficiente *r* era pari a 0.99

Quindi, sembrerebbe altissimo!

PEGASO

Attenzione: tra i malati di mente e gli abbonati non vi è alcun legame reale!

PEGASO

E allora da cosa dipende il valore così elevato del coefficiente di correlazione? Si tratta di fenomeni relativi ad uno stesso periodo di tempo, che hanno quindi un *substrato storico-sociale comune*, nel quale è da ricercarsi la causa della correlazione osservata.

In quest’ultimo caso si parla di *correlazione illusoria o priva di senso*!

Che fare per avere una reale correlazione

Per ottenere un valore di *r* che esprima correttamente il legame di interdipendenza, bisogna eliminare dai due caratteri l'influenza che su essi esercitano altri fattori.

Un caso semplice

Eliminiamo l’influenza della popolazione su due caratteri, ad esempio numero dei nati e dei morti, potendo utilizzare i rispettivi rapporti alla popolazione, e quindi calcolando *r* tra i rispettivi quozienti di natalità e mortalità.

PEGASO

Osserviamo che l'uso dei rapporti X/Z , Y/Z (dove Z è il carattere di cui si vuole eliminare l'influenza) non è indicato quando Z non è correlato con X ed Y in quanto potrebbe condurre a ***correlazioni spurie***, che sono indotte dal tipo di elaborazioni dei dati, ma assenti nei dati originari.

PEGASO

Correlazione: rischi nell'interpretazione

- Un'elevata correlazione fra due variabili NON implica una relazione causa-effetto
- La correlazione non è equivalente alla dipendenza
- La correlazione è molto sensibile agli outliers: due o tre outliers possono portare il coefficiente di corrrelazione a livelli molto bassi

Funzioni Excel utili

- RQ(<Y>;<X>) calcola l'indice di determinazione R^2, che è il quadrato del coefficiente *r* di correlazione e varia tra 0 (caso di indipendenza in media) ed 1 (altissimo legame funzionale tra i due caratteri)

Se le celle con le variabili X e Y vanno rispettivamente da A2 ad A16 e da B2 a B16 scrivi:

=CORRELAZIONE(A2:A16;B2:B16)

=COVARIANZA(A2;A16;B2:B16)

Tale valore esprime la dispersione dei valori osservati intorno alla retta di regressione.

PEGASO

- E’ il bravo statistico, che attraverso analisi descrittiva, inferenziale (campionaria) e comprensione del fenomeno in oggetto che distingue la vera correlazione da quella illusoria o spuria.