PEGASO
Università Telematica
D.M. 20 04 2006 G.U. n° 118 del 23 05 2006

Lezione

“L’Inferenza ed il Campionamento”

PEGASO

L’inferenza statistica

Diciamo *inferenza statistica* quel processo logico e operativo mediante il quale, sulla base di un gruppo di osservazioni o di esperimenti (*campione*), si perviene a certe conclusioni la cui validità per un collettivo più ampio (*popolazione*) è espressa in termini probabilistici

PEGASO

La Stima dei parametri e la Convergenza

Sulla base delle osservazioni condotte su una parte delle unità di un collettivo, può essere necessario valutare un parametro incognito. Questa valutazione si realizza attraverso una funzione delle n osservazioni campionarie, detta *stimatore* del parametro θ, che possiamo indicare con

$$\hat{\theta} = h(X_1, X_2, ..., X_n)$$

dove le variabili casuali X_1, $X_{2,...}X_n$, si riferiscono alle n osservazioni campionarie.

Sostituendo i valori osservati x_1, x_2,.... X_n alle variabili casuali X_1, X_2,...X_n,, si ha un valore $\hat{\theta}$ detto *stima* del parametro θ, e quindi

$$\hat{\theta} = h(x_1, x_2, ..., x_n)$$

PEGASO

Uno stimatore adeguato, dovrebbe rispettare almeno le seguenti condizioni:

- essere *corretto*, o *centrato*, o *non tendenzioso (unbiased),* nel senso che il suo valore medio deve essere uguale al valore del parametro della popolazione, al variare dei campioni

PEGASO

- essere *consistente (o convergente in probabilità)*, quindi, al crescere della numerosità campionaria, le stime devono convergere con probabilità tendente alla certezza verso il valore vero del parametro:

$$\lim_{n\to\infty} \Pr(\left|\hat{\theta} - \theta\right| < \in) = 1,$$

tale espressione si può anche indicare con

$$\text{plim}\ \hat{\theta} = \theta$$

- Lo stimatore deve essere *efficiente,* nel senso che la sua varianza, a parità di altre condizioni, deve essere minore di quella ottenibile con altri stimatori.

PEGASO

Si dovranno quindi *stimare* i parametri della popolazione. Lo stimatore dovrà avere la più bassa varianza possibile.

Si ricordi che:

se il campione è casuale ed abbastanza grande possiamo stabilire con un grado di fiducia del 95% che

$$\pi = P \pm 1.96\sqrt{\frac{P(1-P)}{n}}$$

in cui π e P sono le proporzioni della popolazione e campionaria ed n è la dimensione del campione

PEGASO

Quindi, ad esempio, si supponga di aver compiuto una rilevazione campionaria su 1000 pazienti e che 600 siano risultati sensibili ad un determinato farmaco. Con questa proporzione campionaria di 0.6 si può definire che

$$\pi = 0.6 \pm 1.96\sqrt{\frac{0.6(1-0.6)}{1000}} = 0.6 \pm 0.03$$

PEGASO

Quindi, con un grado di fiducia del 95%, stimiamo che la proporzione della popolazione sensibile al farmaco deve essere compresa tra lo 0.57 e lo 0.63

Il campionamento

La teoria dei campioni è il settore della statistica che si occupa dell'estrazione del campione da popolazioni finite (non illimitate, quindi, come viene ipotizzato spesso nella teoria matematico-statistica).

Vi sono *campioni non probabilistici*:

- *campioni a scelta ragionata*, **quando le unità statistiche vengono individuate mediante criteri logici di rappresentatività, autorevolezza, conoscenza specialistica del problema. In particolare si parla di** *campioni per testimoni privilegiati;*

PEGASO

- *campioni per quota,* **quando le unità vengono scelte dal rilevatore in modo che il campione complessivo rispetti delle proporzioni predefinite da chi ha pianificato l'indagine;**

- *campioni volontari,* **quando le unità decidono autonomamente se far parte del campione (come spesso avviene nei sondaggi internet sulle abitudini delle persone);**

- *campioni a valanga,* **quando poche unità con una certa caratteristica (generalmente rara o di difficile accertamento) vengono usate per individuare, a catena, altre unità con la stessa caratteristica.**

PEGASO

Vi sono poi i campioni probabilistici perché per essi si può determinare la probabilità di estrarre una unità statistica, come il *campionamento casuale semplice con ripetizione* (in esso l'unità estratta casualmente viene rimessa nell'ipotetico paniere da cui estrarre dopo l'estrazione) e *senza ripetizione*.

I campioni probabilistici rispondono alle nozioni della inferenza statistica e sono consigliabili, ma spesso il campionamento non probabilistico può offrire risposte accessorie.

PEGASO

Si effettuano indagini campionarie per le seguenti motivazioni:

- presenza di vincoli di tempo e/o problemi di costo;
- la popolazione di interesse può essere infinita e virtuale;
- la rilevazione potrebbe distruggere le unità statistiche o essere potenzialmente dannosa (ad esempio nel controllo di qualità oppure nelle sperimentazioni mediche);
- la precisione dei risultati nelle rilevazioni censuarie potrebbe non essere adeguata.

Esempio. Si vuole studiare la distribuzione dei redditi delle famiglie italiane, mediante un'indagine campionaria. L'insieme delle famiglie italiane costituisce la popolazione reale (finita), mentre l'insieme ristretto delle famiglie su cui viene condotto lo studio è il campione.

Esempio. Per effettuare un controllo di qualità si analizzano le caratteristiche di un determinato gruppo di oggetti prodotti da un certo macchinario. Il gruppo di oggetti analizzati è il campione, mentre la popolazione virtuale (potenzialmente infinita) è costituita da tutti i pezzi che il macchinario può produrre, nelle stesse condizioni. ⟨

PEGASO

In un campione casuale semplice le unità vengono selezionate dalla popolazione di riferimento di modo che ognuna abbia la stessa possibilità di far parte del campione (estrazioni, con reinserimento, da un'urna).

Per popolazioni virtuali (infinite) o reali (finite) molto numerose, campionare con reinserimento o senza reinserimento (in blocco) non porta a differenze sostanziali.

PEGASO

Alla luce di quanto detto, i dati osservati $x = (x_1, \ldots, x_n)$, $n \geq 1$, sono riferiti a caratteristiche di interesse, rilevate sulle n unità statistiche che costituiscono il campione; in particolare, x_i, $i = 1, \ldots, n$, indica l'osservazione effettuata sulla i-esima unità statistica.

PEGASO

L'ipotesi fondamentale su cui poggia l'inferenza statistica è che i dati campionari x sono una realizzazione di un vettore casuale $X = (X_1, \ldots, X_n)$.

La distribuzione di probabilità di X è, almeno in parte, ignota e si utilizza l'informazione ricavabile dai dati per ottenerne una ricostruzione.