PEGASO
Università Telematica
D.M. 20 04 2006 G.U. n° 118 del 23 05 2006

Lezione
"Analisi della dipendenza"

Funzione di regressione

Con il termine regressione ci si riferisce allo studio di come varia in media il carattere dipendente Y al variare di quello indipendente X.
In statistica descrittiva lo studio della regressione consiste nel calcolare una funzione $y^* = a + bx$ che descriva nella maniera migliore il legame tra il carattere indipendente (cioè antecedente) X e quello conseguente (e quindi dipendente) in media; molto spesso si sceglie la retta di regressione, che è la funzione più semplice e di facile interpretazione.

PEGASO

Il calcolo dei parametri della funzione di regressione
$y^* = a + bx$ si effettua in genere col metodo dei minimi quadrati: si sceglie la retta per la quale la somma dei quadrati degli scostamenti tra valori teorici (cioè quelli della retta di regressione che interpola le osservazioni rappresentate dal grafico di cui sopra) ed osservati del carattere Y sia minima.

Uguagliando a zero le derivate parziali rispetto ai parametri a e b si perviene ad un sistema a due equazioni che fornisce le seguenti soluzioni:

$$b = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{ii=1}^{N}(x_i - \bar{x})^2} = \frac{Codev(X,Y)}{Dev(X)}$$

$$a = \bar{y} - b\,\bar{x}$$

dove Codev(X,Y) rappresenta la codevianza tra X ed Y, Dev (X) la devianza della X, $\bar{y}$ e $\bar{x}$ rappresentano le medie delle rispettive variabili.

PEGASO

Il parametro b, il coefficiente di regressione, esprime di quanto varia in media la Y al variare della X: se $b > 0$ la Y aumenta in media all'aumentare della X; se $b < 0$ la Y diminuisce in media all'aumentare della X; se $b = 0$ la Y è indipendente in media dalla X.

La devianza

Si consideri la *devianza totale* = $\sum_{i=1}^{N}(y_i - \bar{y})^2$; essa

è data dalla somma della *devianza di regressione e di quella dell'errore (o residua),* e quindi:

Dev(Y) = Dev(R) + Dev(E) = $\sum_{i=1}^{N}(y_i^* - \bar{y})^2{}_i + \sum_{i=1}^{N}(y_i - y_i^*)^2$

con y* rappresentante i valori della retta di regressione, y quelli osservati e $\bar{y}$ quelli medi.

La devianza di regressione esprime la dispersione dei valori teorici della retta di regressione intorno a quelli medi, mentre la devianza residua indica la dispersione dei valori osservati di Y intorno ai valori teorici della retta di regressione. La devianza totale indica quindi la dispersione dei valori osservati intorno ai valori medi della Y.

PEGASO

Una dispersione elevata indica una limitata possibilità di realistiche previsioni in base alla retta di regressione; il contrario accadrà con bassa dispersione.

Il rapporto

$R^2 = \frac{Dev(R)}{Dev(Y)}$ si denomina *indice di determinazione* ed indica la bontà di accostamento della retta di regressione ai dati campionari; tale indice varia tra 0 ed 1, ed assume valore 0 in caso di indipendenza in media, mentre assume valore 1 nel caso in cui tutti i punti (x,y) giacciono sulla retta di regressione.

Per quanto riguarda invece la regressione multipla, tra la Y e più variabili indipendenti X, vi sono due modi di affrontare questa situazione in statistica descrittiva (si ipotizzino due variabili indipendenti X_1 e X_2):

1) la regressione tra Y e X_1 prescinde da X_2 (così come quella tra Y e X_2 trascura X_1): con questo metodo si calcolano dei coefficienti di regressione denominati totali;

2) il secondo metodo (che porta al calcolo di coefficienti di regressione denominati parziali) tiene conto di X_1 e di X_2 ma, volendo esaminare l'influenza, ad esempio, della sola X_1, occorrerà fissare un valore di X_2; si dovrà dunque analizzare la regressione tra Y e X_1 solo per quel particolare valore di X_2.

Anche nel caso della regressione multipla si potrà calcolare l'indice di determinazione, che si chiamerà *indice di correlazione doppia*, e sarà uguale sempre al rapporto tra devianza di regressione e devianza totale.

Con più variabili esplicative, se ne suppongano tre, si suole in genere calcolare il coefficiente di correlazione parziale tra X_1 e X_2 a pari valore X_3, cioè:

$$r_{12,3}=\sqrt{b_{12,3}b_{21,3}}$$

nella quale $b_{12,3}$ è il coefficiente di regressione parziale di X_1 rispetto a X_2 fissato X_3, e $b_{21,3}$ è il coefficiente di X_2 rispetto a X_1 fissato X_3.

Parole Chiave

1) Devianza residua
2) Devianza dell'errore
3) Devianza totale
4) Codevianza
5) Indice di correlazione doppia