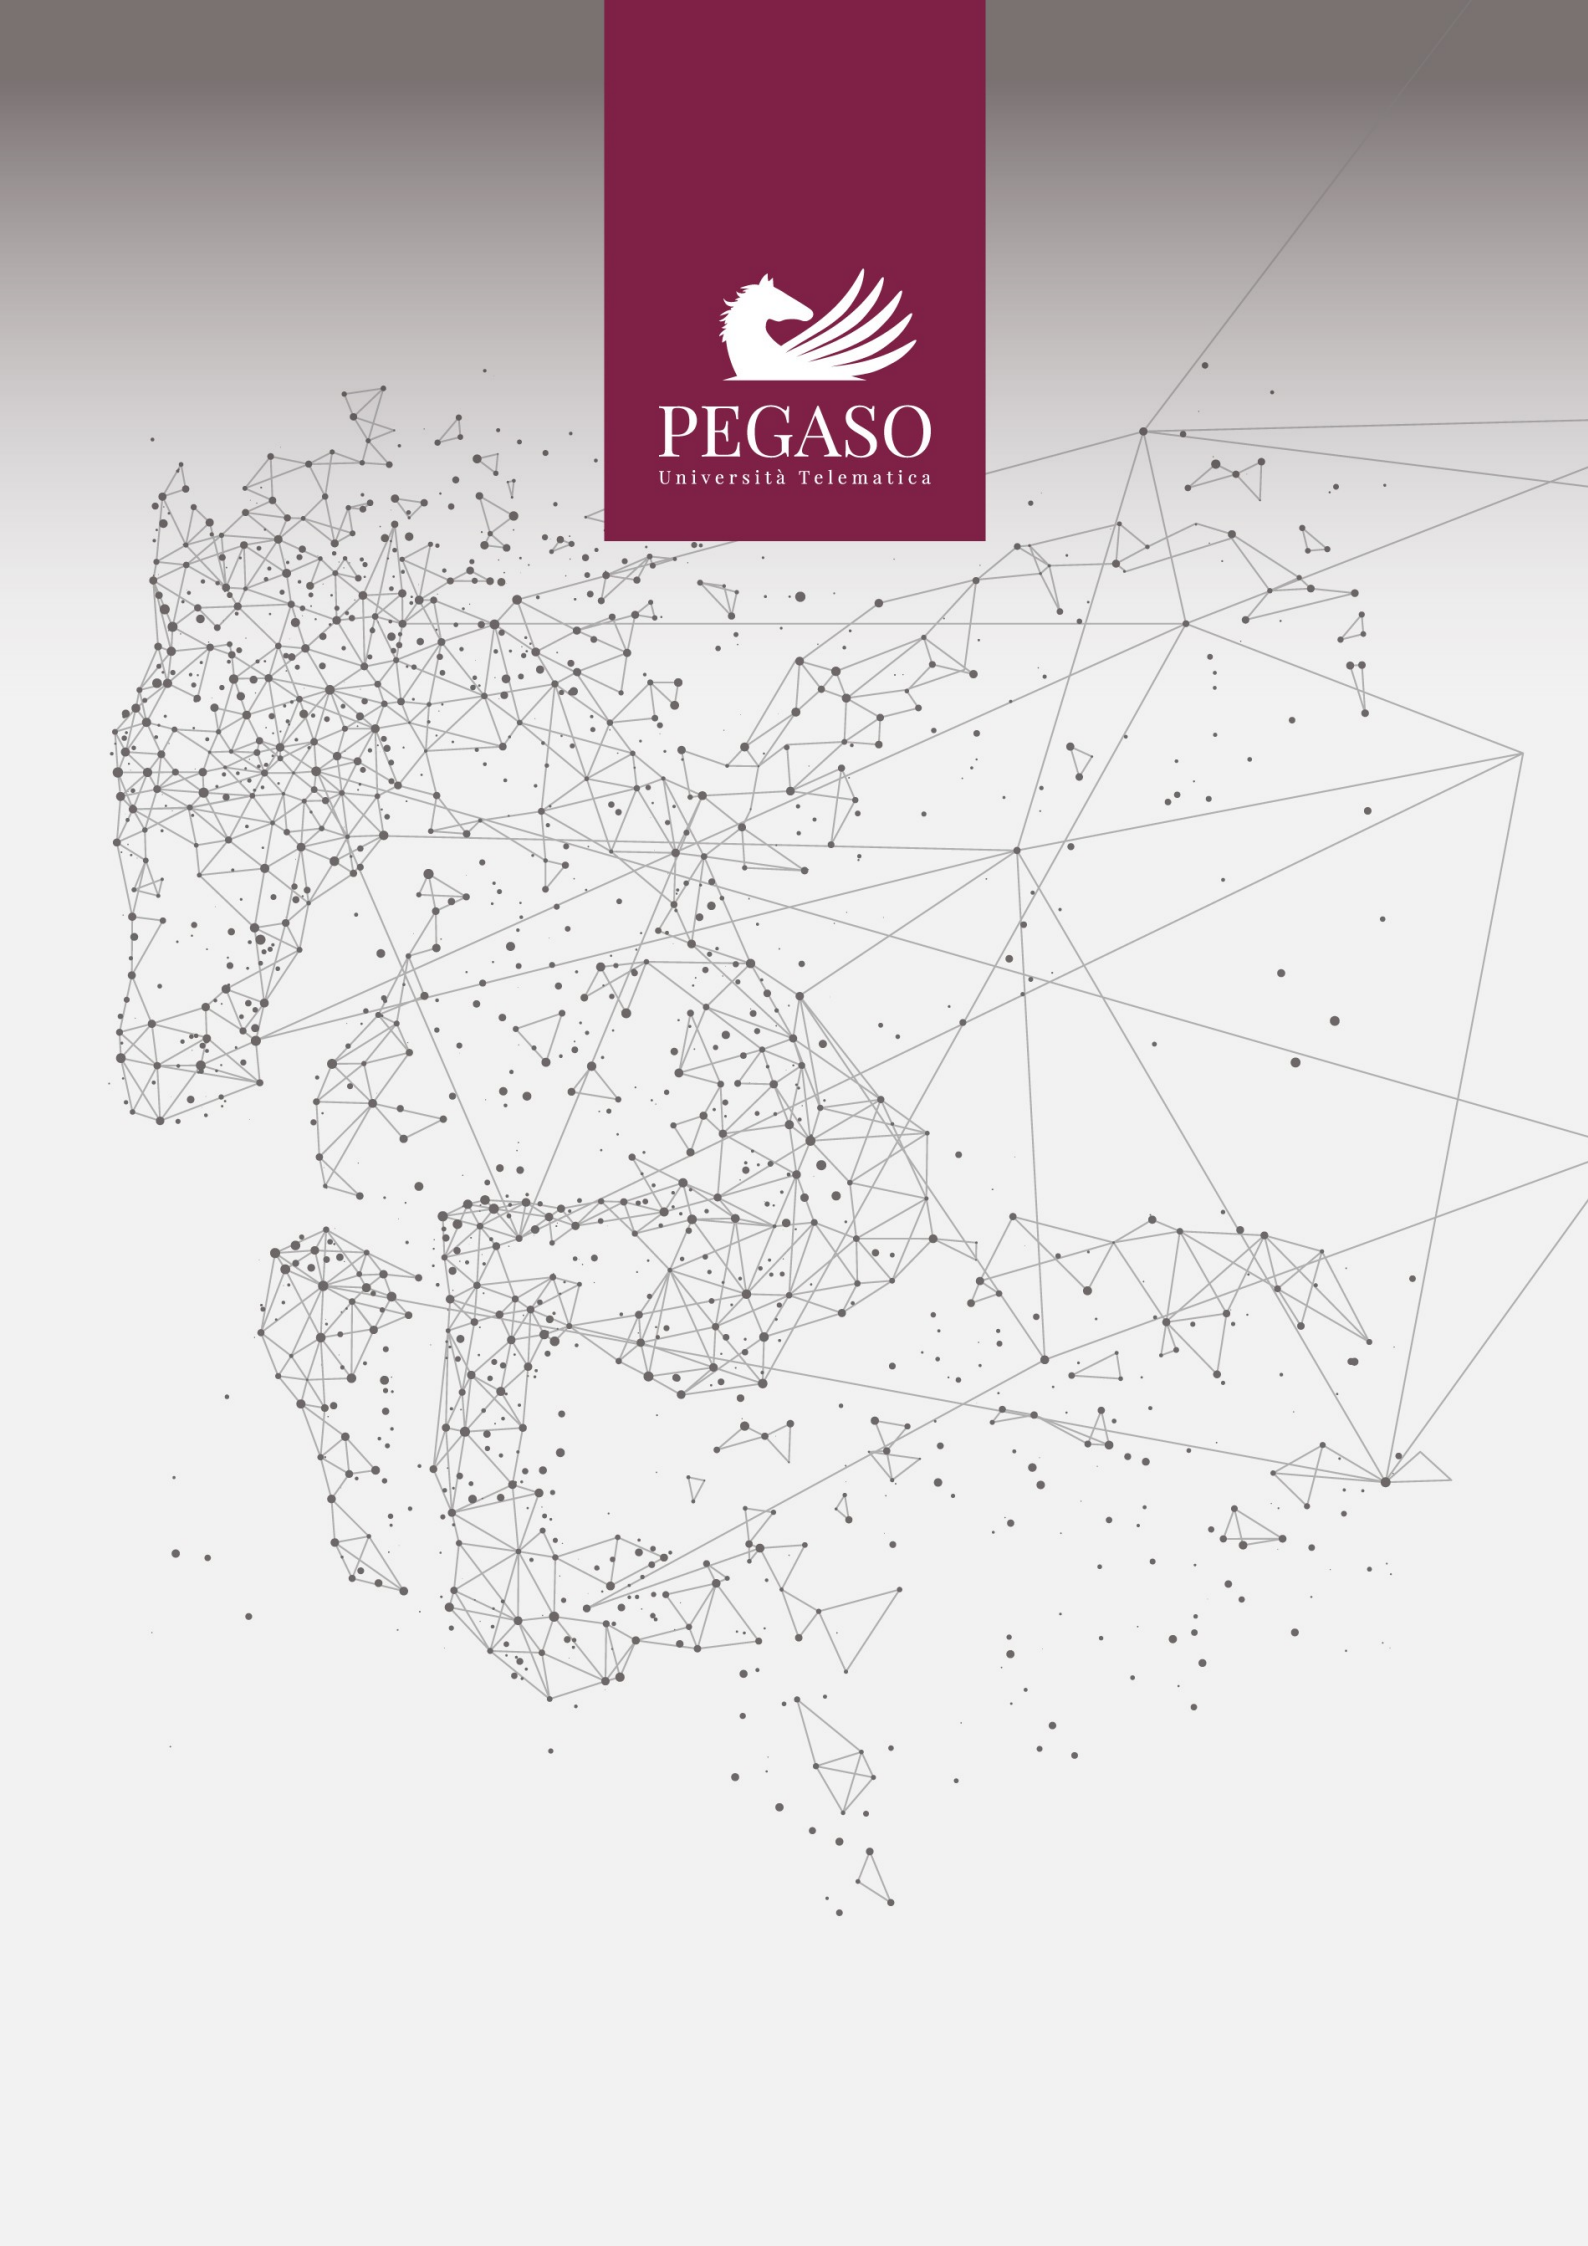

PEGASO
Università Telematica

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Indice

1. INTRODUZIONE 3
2. INTRODUZIONE AI GRAFI 4
3. STRUTTURA DI UN GRAFO 9
4. CENTRALITÀ 14
BIBLIOGRAFIA 17

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

1. Introduzione

In questa dispensa di accompagnamento alla video-lezione, si presenta il modello alla base dell'analisi delle reti, il grafo. Viene, quindi, introdotta la definizione del modello e vengono presentate le principali proprietà. Vengono, poi, approfonditi gli aspetti principali riguardanti la struttura dei grafi quali il concetto di percorso, di componente connesso, di comunità di rete e di vicinato. Infine, si presentano le principali misure di centralità di un nodo al fine di valutarne l'importanza per l'intera rete. Infine, vengono introdotte la centralità locale, la centralità globale, la centralità globale dei flussi e la centralità ad autovettore.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

2. Introduzione ai grafi

L'**analisi dei dati di rete** è un'area recente dell'analisi dei dati. La **scienza delle reti** ha tratto i suoi metodi teorici di analisi in parte dalla matematica (in particolare dalla teoria dei grafi), in parte delle scienze sociali e in parte dalla sociologia. Alcuni, poi, sono soliti chiamare l'analisi dei dati di rete con la formula più attuale: **analisi delle reti sociali.**

Dal punto di vista della scienza dei dati, una **rete** è semplicemente una **collezione di oggetti interconnessi.** In pratica, è possibile trattare tutti i tipi di oggetti numerici e non numerici (es. testuali) come se fossero organizzati in reti (sempre che esista un qualsiasi modo per interconnetterli).

Solitamente, esistono diversi nomi per chiamare sia gli **oggetti di una rete** come ad esempio *nodi, vertici* e *attori*, sia le **connessioni tra essi** come ad esempio *archi, spigoli, collegamenti* e *cammini*.

La rappresentazione delle reti in modo grafico e matematico avviene solitamente sotto forma di **grafo.** Molto importante è, dunque:

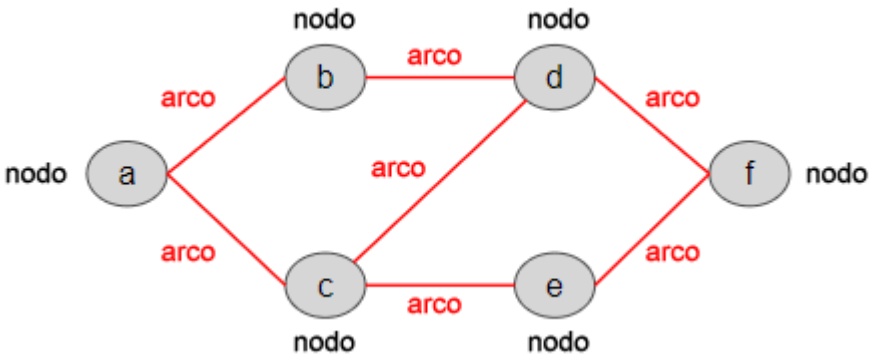
- la **capacità di creare reti** a partire da dati di rete (ma anche da dati non provenienti da reti);
- le **misurazioni** relative alle reti;
- l'**analisi delle reti**, in particolare, calcolando e interpretando le centralità di nodi di una rete e la struttura comunitaria.

Python mette a disposizione dell'analisi delle reti il modulo standard di Anaconda ***networkx*** e il modulo ***community.***

Introduciamo, ora, dal punto di vista matematico, il concetto di **grafo** e alcune proprietà ad esso relative. Un **grafo** è un *insieme* di elementi detti **nodi** (o *vertici*) che possono essere collegati tra loro mediante **archi** (o *lati* o *spigoli*) come è possibile osservare nella figura seguente che mostra un grafo di esempio.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).



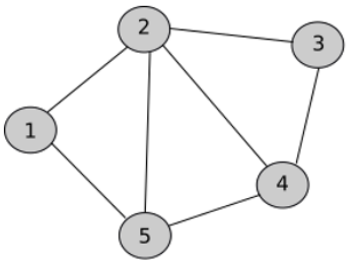
Dal punto di vista formale, un grafo è una coppia ordinata *G = (V, E)* di insiemi con:

- **V** insieme dei nodi;
- **E** insieme degli archi;

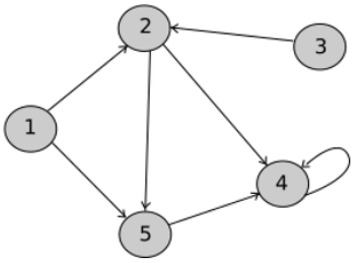
tali che gli elementi di E siano coppie di elementi di V.

Due vertici *u,v* connessi da un arco *e* prendono il nome di estremi dell'arco. L'arco *e* viene identificato anche con la coppia formata dai suoi estremi (*u,v*).

Se l'insieme degli archi E è una **relazione simmetrica**, allora si dice che il grafo è **non orientato** (o *indiretto*), altrimenti si dice che è **orientato** (o *diretto*). In altre parole, un grafo è **orientato** se almeno un arco del grafo connette il nodo A al nodo B, ma non viceversa. Di seguito, si riportano due esempi di grafo orientato e non orientato.



Grafo non orientato

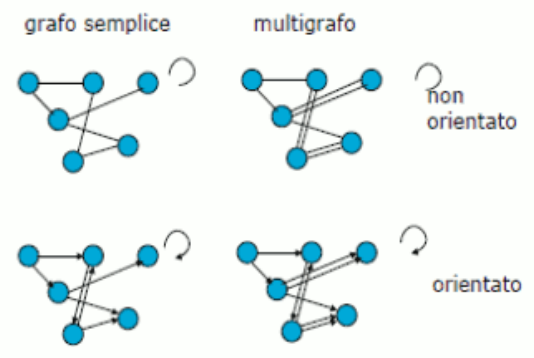


Grafo orientato

Se in un grafo vi sono **archi paralleli** (cioè il nodo A può essere connesso al nodo B da più di un arco), il grafo è chiamato **multigrafo.** Un arco che ha due *estremi coincidenti* (collega un nodo a sé stesso) si dice **cappio** o **ciclo** o **loop.** Un grafo senza cicli e archi paralleli è chiamato **grafo semplice**. Nella figura seguente, si riportano esempi relativi alla casistica di grafi appena illustrata.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

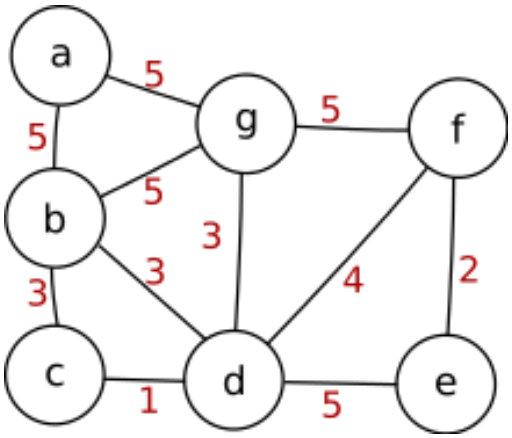


Agli archi di un grafo possono essere assegnati dei **pesi**. Un **peso** è, normalmente, espresso attraverso ***numeri reali***, ma possono essere ristretti all'insieme dei razionali o degli interi. Alcuni algoritmi, ad esempio, funzionano propriamente solo con *pesi positivi*. Talvolta il peso fra due vertici non connessi da un arco è indicato con valore **infinito**.

Un grafo con archi pesati è chiamato **grafo pesato.** I **pesi** degli archi possono avere una doppia valenza:

1. possono ad esempio indicare la *distanza* tra due nodi come, ad esempio, in un grafo alla base di un navigatore stradale. In questo caso solitamente si cercano percorsi con peso inferiore;
2. possono ad esempio indicare la *connessione* fra i nodi. In questo caso maggiore è il peso, più intensa la connessione fra i nodi.

Nella figura seguente si riporta un esempio di grafico pesato, con i pesi riportati come etichette degli archi.



Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Un'altra importante definizione riguardante i grafi è quella di **grado di un nodo** definito come il *numero di archi connessi* (*incidenti*) al nodo. Per i grafi *orientati* si distingue fra:

- **grado in ingresso** - numero di archi in ingresso verso il nodo;
- **grado in uscita** - numero di archi che fuoriescono dal nodo.

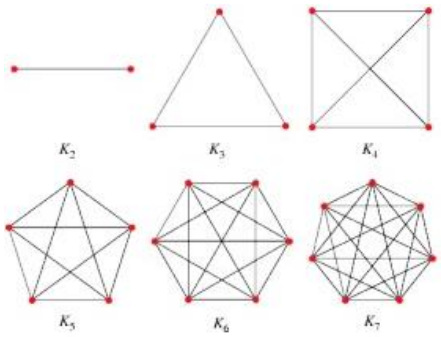
Nella figura seguente, si riporta l'esempio di un nodo di un grafo non orientato di grado 5 (a sinistra) e l'esempio di un nodo di un grafo orientato di grado in ingresso pari a 3 e grado di uscita pari a 2 (a destra).



La **densità del grafo** indica quanto il grafo si avvicini ad un **grafo completo**. Un *grafo completo* si può definire alternativamente come:

- un grafo che contiene tutti gli archi possibili, oppure
- un grafo in cui due qualsiasi dei suoi vertici sono *adiacenti* (cioè se c'è un arco che li connette).

Nella figura seguente vengono riportati degli esempi di grafi completi al variare del numero di nodi da 2 (K_2) a 7 (K_7).



La **densità del grafo** è un numero compreso tra 0 e 1. Per esempio, per un grafo orientato con *e* archi e *n* nodi si ha una densità pari a:

$$d = \frac{e}{n(n-1)}$$

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Per un grafo non orientato, invece, la densità è pari a:

$$d = \frac{2e}{n(n-1)}$$

Si considerano, inoltre, il **grado massimo** e il **grado minimo del grafo G** come, rispettivamente:

- il **grado del vertice** del grafo G con il maggior numero di archi incidenti;
- il **grado del vertice** del grafo G che ha meno archi incidenti.

Se il grado massimo e il grado minimo coincidono con un numero *k*, si è in presenza di un grafo *k-regolare* o **grafo regolare.**

Altre importanti definizioni relative ai grafi sono:

- l'**ordine** di un grafo, cioè il numero dei vertici del grafo (pari, quindi, alla cardinalità dell'insieme V dei nodi);
- la **dimensione** di un grafo, cioè il numero di archi del grafo (pari alla cardinalità dell'insieme E degli archi);
- un **grafo nullo** è un grafo privo di archi.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

3. Struttura di un grafo

I grafi e le reti che essi generano sono oggetti interessanti, diversificati e ricchi di sfaccettature. Per comprenderli al meglio è necessario conoscere la **terminologia** inerente alla **struttura dei grafi**.

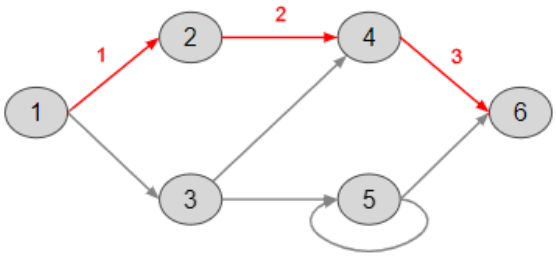
Il concetto di **connettività fra i nodi** può essere espanso osservando i **cammini** di un grafo. Un **cammino** è una *qualsiasi sequenza di archi* tale per cui la *fine di un arco è l'inizio di un altro arco*.

Il **percorso** (o path) è un cammino che **non si interseca mai** (cioè non include lo stesso nodo due volte ad eccezione del primo o dell'ultimo nodo).

Un **percorso** di lunghezza *n* nel grafo *g* è dato, quindi:

- dalla **sequenza di vertici** $v_0,v_1,\ldots,v_n$ e
- da una **sequenza di archi** che li collegano (v_0,v_1), (v_1,v_2), $\ldots,(v_{n-1}, v_n)$.

Nella figura seguente si riporta un esempio di grafo con un percorso evidenziato in rosso.

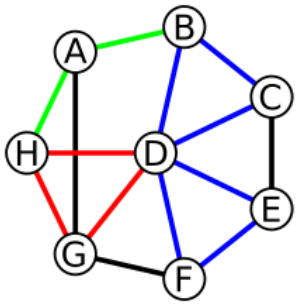


Un percorso chiuso (nodo finale è anche il nodo iniziale) prende il nome di **ciclo**.

Nella figura seguente si riporta:

- il percorso H-A-B (in verde);
- un ciclo senza vertici o archi ripetuti H-D-G-H (in rosso);
- un cammino con vertici ripetuti B-D-E-F-D-C-B (in blu).

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).



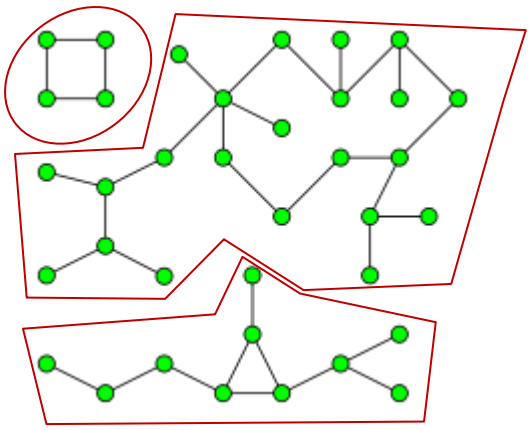
Così com'è possibile misurare la distanza tra due oggetti nella vita reale, è possibile misurare la **distanza fra due nodi** qualsiasi del grafo. Si tratta, in particolare, del **più piccolo numero di archi** (chiamati anche «hop») di ogni **percorso** di connessione fra i nodi.

La definizione appena vista non funziona nel caso dei **grafi pesati**, ma talvolta è possibile immaginare che il grafo non sia pesato e contare semplicemente gli archi.

In un grafo orientato, la distanza da A a B **non è sempre uguale** la distanza da B ad A. In un grafo orientato, potremmo addirittura essere in grado di andare da A a B, ma non di tornare indietro.

Il **diametro D del grafo** è pari alla **massima distanza fra due nodi qualsiasi** di un grafo.

Un **componente connesso** è un *insieme* di tutti i nodi di un grafo tali per cui esiste un percorso da ogni nodo dell'insieme a ogni altro nodo dell'insieme stesso. Ad esempio, nella figura seguente si riporta un grafo con tre componenti connessi.

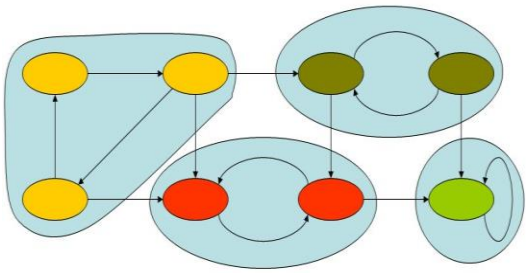


PEGASO
Università Telematica

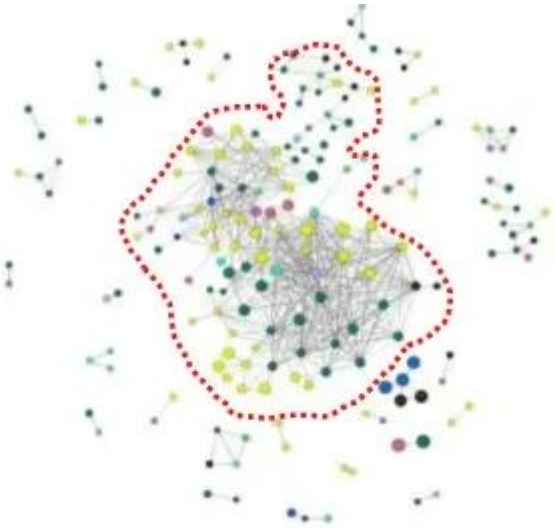
Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

In un grafo orientato si distingue fra:

- **componenti fortemente connessi** (connessi da effettivi percorsi);
- **componenti debolmente connessi** (connessi da percorsi in cui gli archi sono stati convertiti in archi non orientati).



Se un grafo ha più componenti, il *componente più grande* viene chiamato **GCC Giant Connected Component**. Un esempio di GCC viene riportato nella figura seguente indicato all'interno della linea tratteggiata di colore rosso.

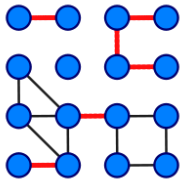


Molto spesso le dimensioni di un GCC sono notevoli. In tal caso è meglio lavorare con il solo GCC piuttosto che con l'intero grafo per evitare problemi di mancata connettività.

Talvolta due parti di un grafo sono **connesse**, ma la connessione così debole che la **rimozione di un singolo arco spezza il grafo**. In tale caso *l'arco* è chiamato **ponte**. Nell'esempio riportato ci sono sei ponti marcati in rosso.

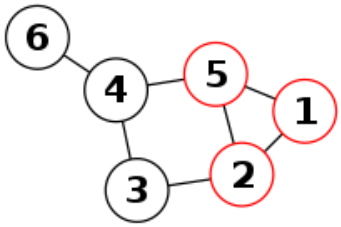
PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).



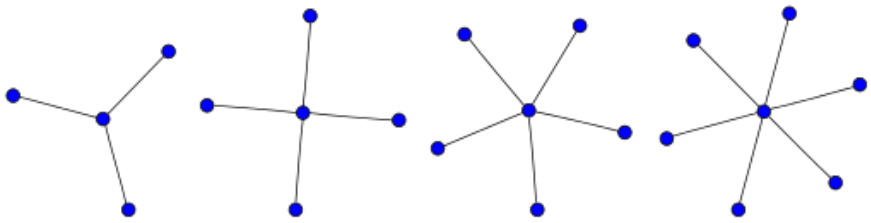
Una **cricca** è un insieme di nodi di un grafo non orientato tale per cui **ogni nodo è connesso direttamente a ogni altro nodo dell'insieme**. La cricca più grande di un grafo si chiama **cricca massima** (evidenziata in rosso nella figura seguente).

Se una cricca non può essere estesa aggiungendole un altro nodo è chiamata **cricca massimale** (coppie {2,3}, {3,4}, {4,5}, {4,6}).



La **cricca massima** è sempre anche una **cricca massimale**, ma non sempre vale il contrario. Un **grafo completo**, quindi, è una **cricca massimale**.

Una **stella** è un insieme di nodi tale per cui un nodo è *connesso a tutti gli altri nodi* dell'insieme, mentre gli *altri nodi non sono connessi* fra loro. Le stelle si ritrovano comunemente nei sistemi gerarchici multilivello (per esempio nelle aziende, nelle istituzioni militari e in Internet). Nella figura seguente si riportano diversi esempi di stella con numero di nodi crescente da 3 a 7.



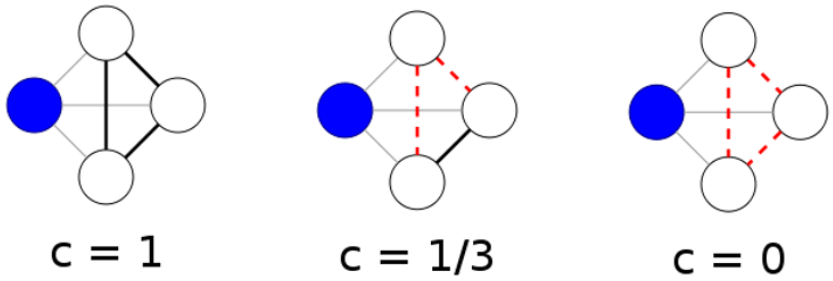
L'*insieme di nodi direttamente connessi al nodo A* forma il **vicinato** di A anche indicato come **G(A)**. Questo concetto è un elemento chiave nella tecnica **snowballing**, una tecnica di acquisizione dei dati in cui gli archi di un *nodo seme* selezionato casualmente sono seguiti da quelli dei suoi vicini, poi dai vicini dei vicini (vicinato di secondo livello) e così via.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

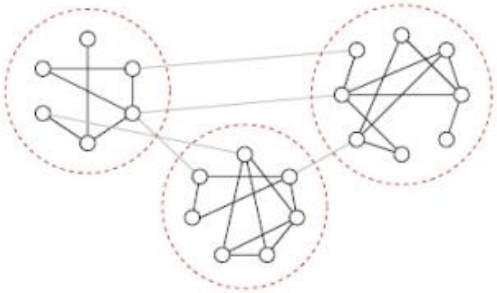
Il **coefficiente di clustering locale** del nodo A è il numero *CC(A)* di archi nel vicinato di A (escludendo gli archi direttamente connessi ad A) diviso per il massimo numero possibile di archi. In altre parole, tale coefficiente è la **densità del vicinato** di A escluso il solo nodo A.

Per meglio comprendere il concetto di coefficiente di clustering, nella figura seguente si riportano tre esempi di valore del coefficiente sulla base del numero di archi effettivamente presenti che collegano i vicini del nodo in questione.



Il *coefficiente di clustering* di un nodo qualsiasi di una *stella* è pari a zero, mentre il coefficiente di clustering di un nodo qualsiasi di un *grafo completo* è pari a uno. CC(A) può essere usato per **misurare la probabilità** che G(A) sia una stella o un grafo completo.

Una **comunità di rete** è un insieme di nodi tale per cui il numero di archi che interconnettono tali nodi è molto maggiore del numero di archi che attraversano i confini della comunità. Ad esempio, nella figura seguente si individuano tre comunità.



La **modularità** m ∈ [-1/2,1] misura la *qualità della struttura comunitaria*. La modularità è definita come la *frazione degli archi che rientrano nella comunità* individuate in paragone al valore atteso di tale densità. Un'*elevata modularità* (*m ≈ 1*) è sintomo di una rete con comunità dense chiaramente visibili.

Identificare tali comunità è forse il **risultato più importante dell'analisi dei dati di rete**.

PEGASO
Università Telematica

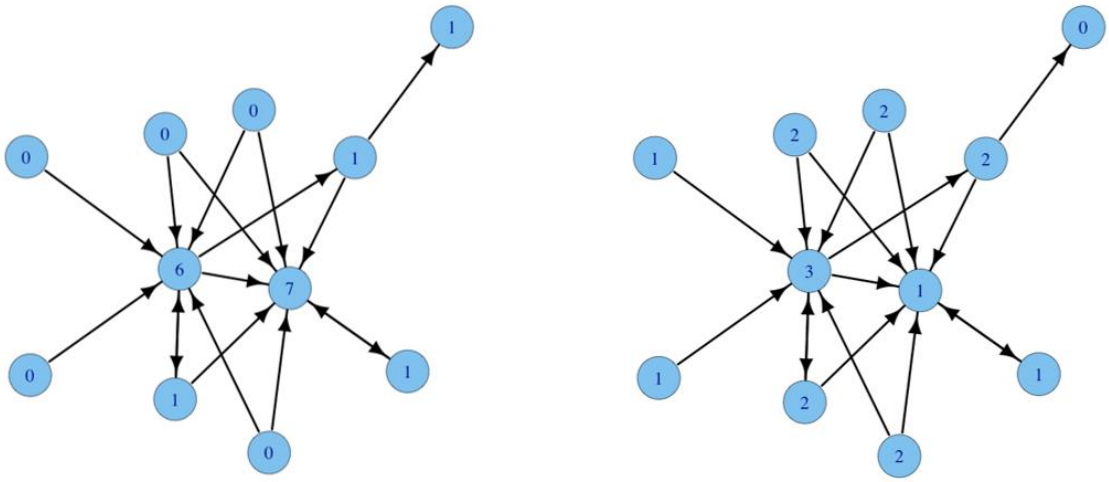
Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

4. Centralità

La **centralità** misura l'importanza di un nodo in una rete. Esistono vari tipi di *misure di centralità* che valutano vari aspetti importanti. Per comodità, le centralità sono spesso riportate l'intervallo fra zero (un *nodo trascurabile, periferico*) e uno (un *nodo importante, centrale*).

La **centralità locale** di A (*degree centrality*) è il numero di nodi adiacenti di A ovvero è il **grado** di A o la **dimensione di G(A)**. È possibile **normalizzarla** dividendola per il massimo numero possibile di nodi adiacenti di A, ovvero *n -1*.

Nella figura seguente, si riporta un esempio di grafo orientato in cui il nodo è etichettato con il *valore di centralità locale*. Essendo un grafo orientato, riportiamo a sinistra la centralità locale *entrante* e a destra quella *uscente*.



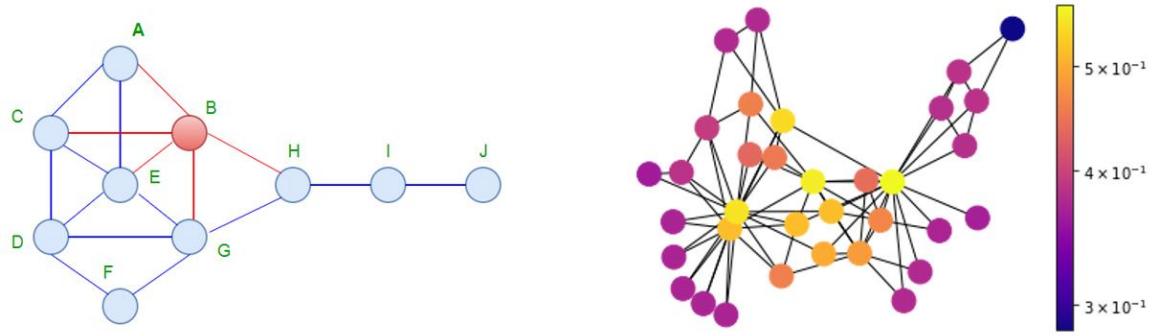
La **centralità globale** di A (*closeness centrality*) è il reciproco della media del più breve percorso L_{BA} da tutti gli altri nodi ad A. Essa rappresenta una misura della *facilità di accesso di un nodo agli altri nodi*. Il calcolo della centralità globale segue la seguente formula:

$$cc_A = \frac{n-1}{\sum_{B \neq A} L_{BA}}$$

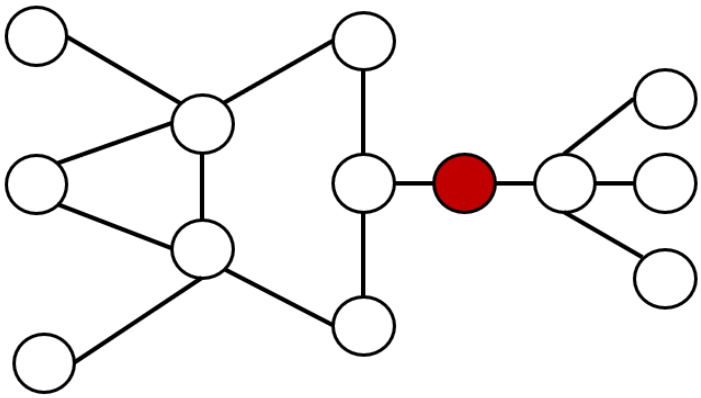
Nelle figure seguenti, si riportano due grafi in cui si evidenzia un nodo con il valore massimo di centralità globale (a sinistra) e il valore (in codice colore) della centralità globale di tutti i nodi.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).



La **centralità globale dei flussi** di A (*betweenness centrality*) è la frazione di tutti i percorsi più brevi fra tutte le coppie di nodi della rete, escluso solo A, che contengono A. Tale misura, quindi, quantifica *l'importanza di un nodo nel flusso informativo*. Nella figura seguente, si riporta in rosso il nodo con più alta centralità globale di flussi del grafo.



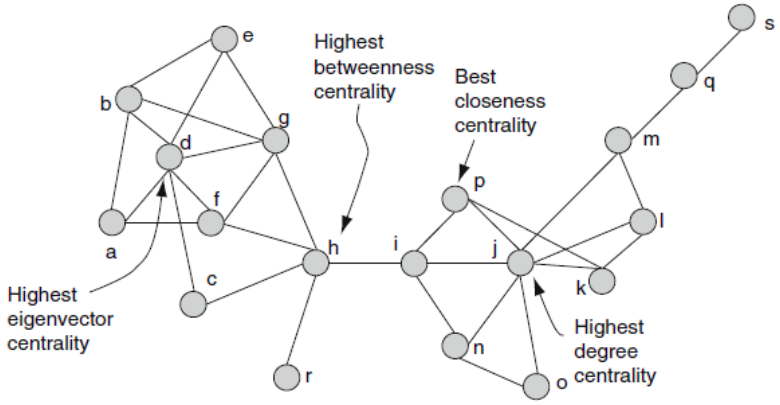
La **centralità ad autovettore** di A (*eigenvector centrality*) è definita ricorsivamente come la somma scalare delle centralità ad autovettore di tutti i nodi adiacenti di A. Essa prende in considerazione la *connettività con i vicini a livello globale*. I punteggi relativi vengono assegnati a tutti i nodi della rete in base al concetto che le **connessioni ai nodi con punteggio elevato** contribuiscono maggiormente al punteggio del nodo in questione rispetto alle stesse connessioni, ma a nodi con punteggio basso. La centralità ad autovettore è, quindi, una misura dell'**influenza di un nodo** nella rete.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Le ultime due misure di centralità, *centralità globale dei flussi* e *centralità ad autovettore*, sono costose dal punto di vista computazionale e può essere poco pratico calcolarle per reti di grandi dimensioni.

Per concludere, di seguito si riporta un esempio di grafico con l'indicazione (da sinistra a destra) del nodo con più alta centralità ad autovettore (eigenvector), più alta centralità globale dei flussi (betweenness), migliore centralità globale (closeness) e più alta centralità locale (degree).



Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Bibliografia

- Zinoviev D. (2017). Data science con Python. Apogeo.

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).