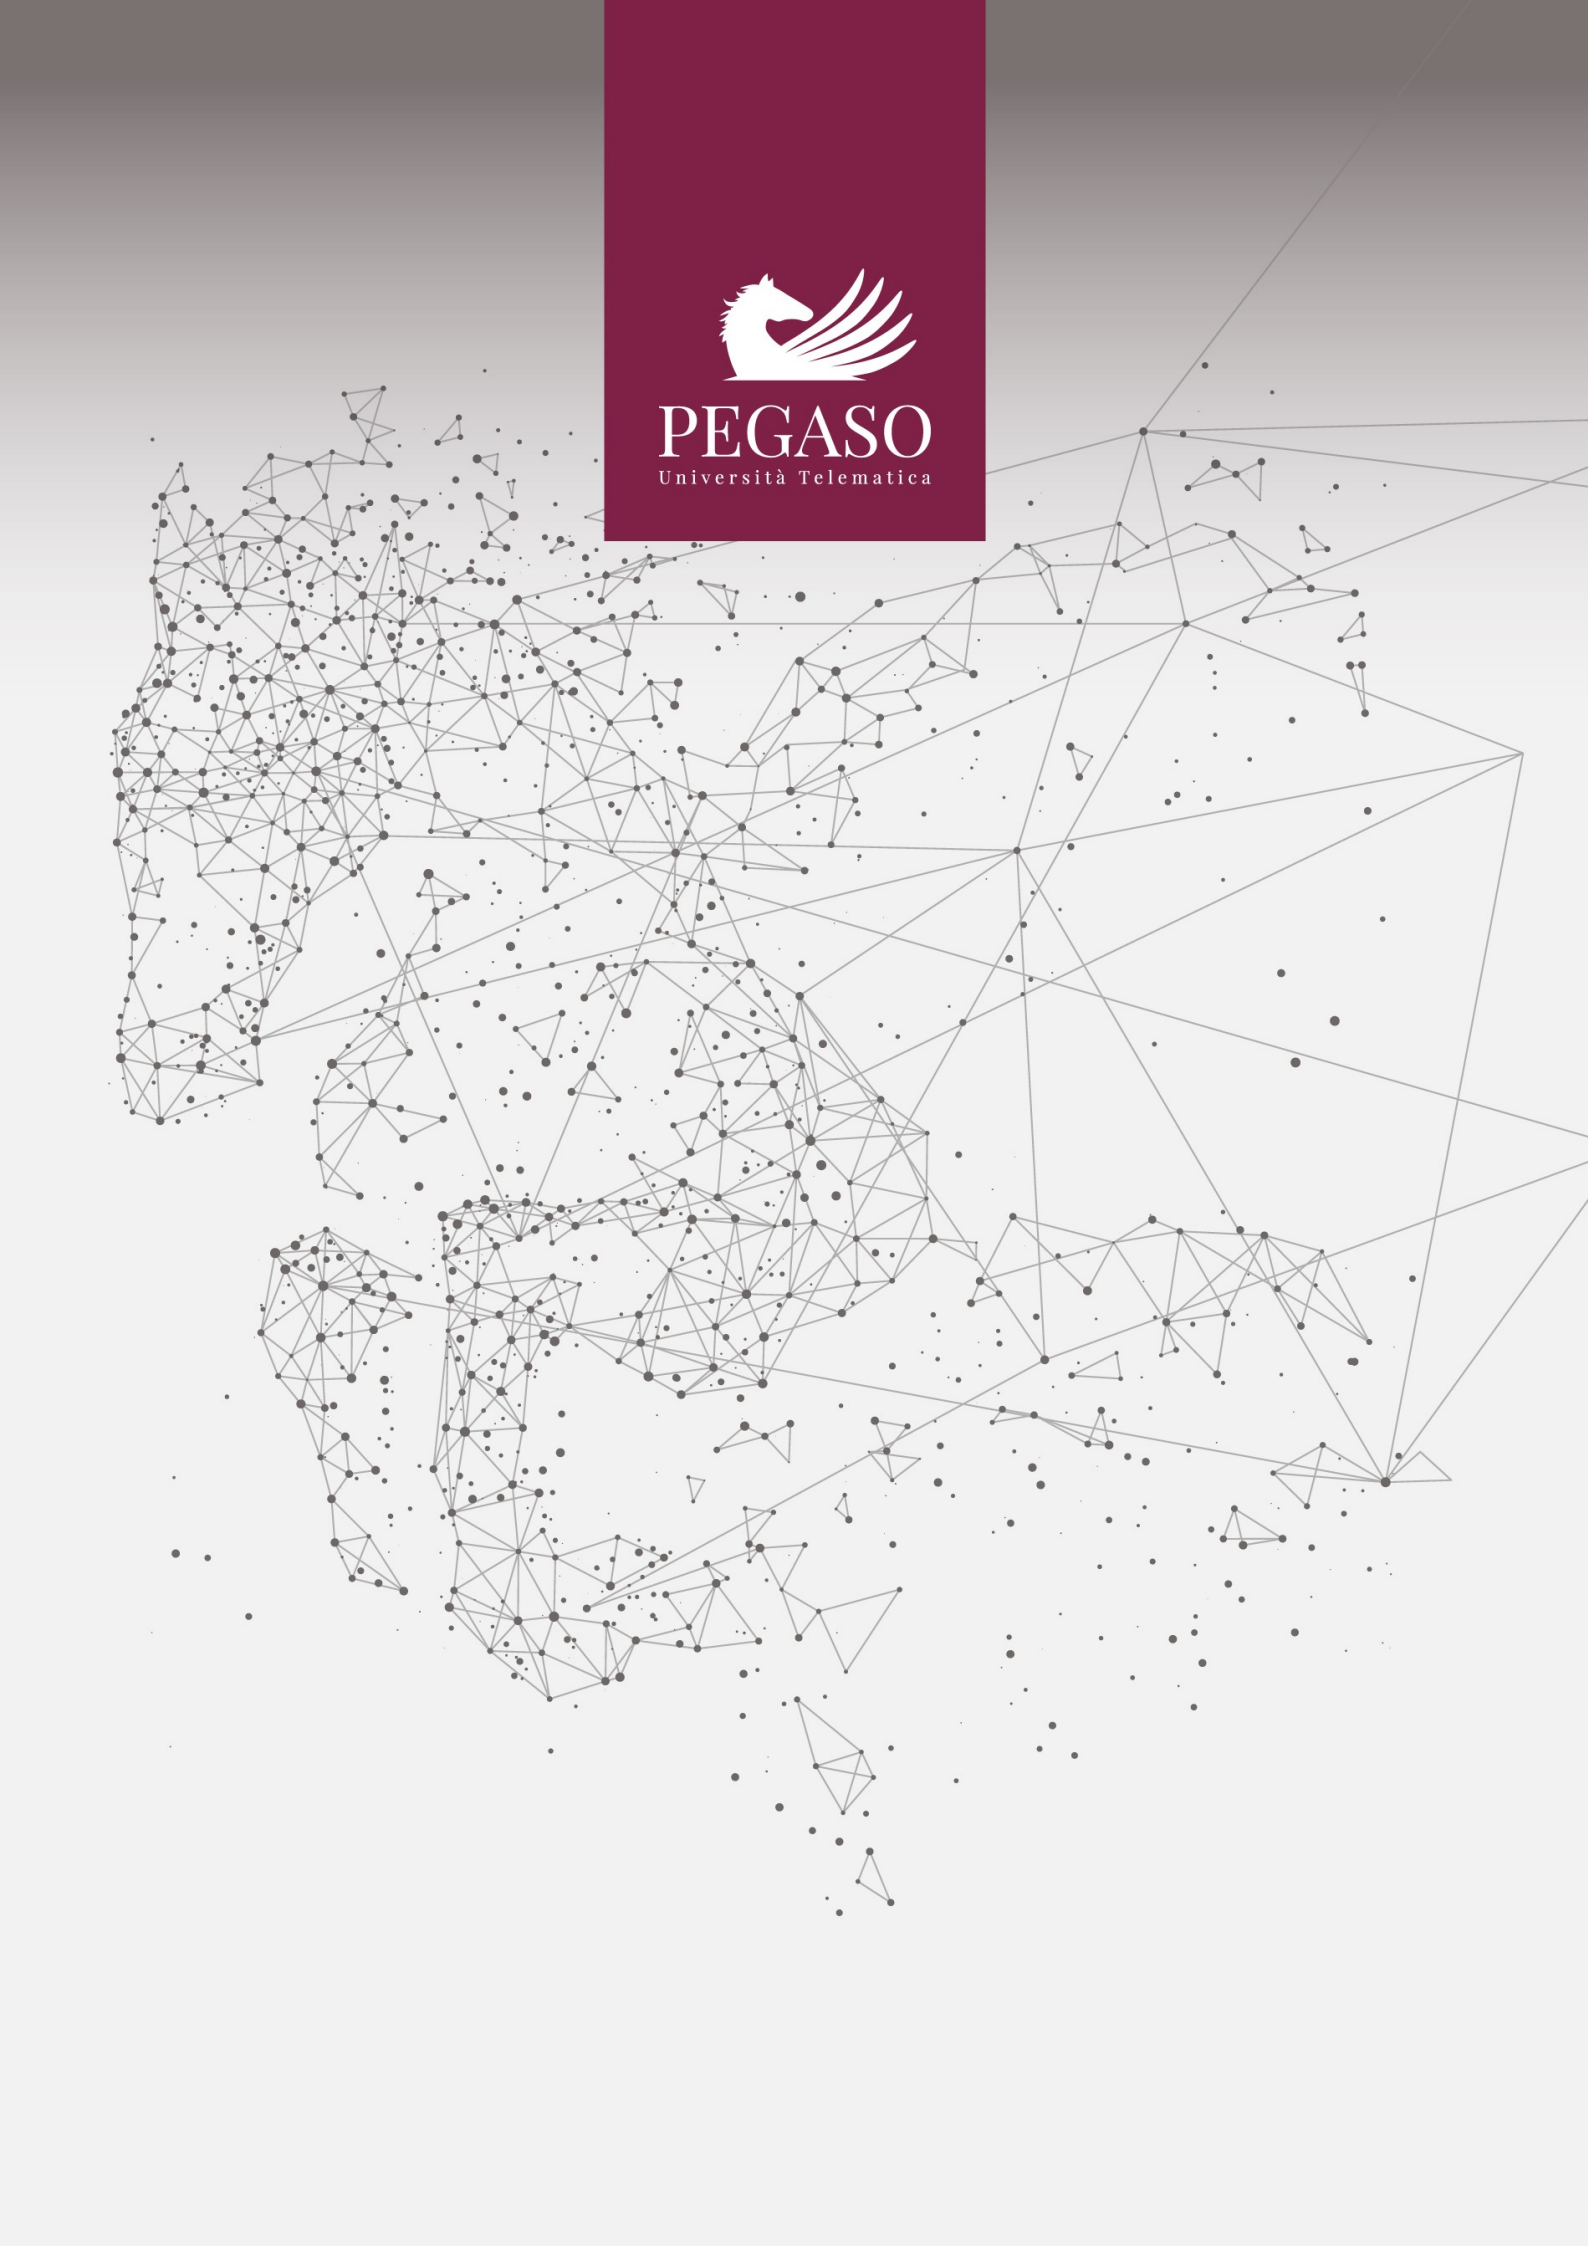

PEGASO
Università Telematica

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Indice

1. INTRODUZIONE 3
2. OPERAZIONI CON I VETTORI 4
3. OPERAZIONI CON LE MATRICI 8
4. RAPPRESENTAZIONE GRAFICA 10
4.1 GRAFICO A DISPERSIONE 11
4.2 GRAFICO A BARRE 16
4.3 ISTOGRAMMA 18
4.4 BOXPLOT 21
4.5 CORRELOGRAMMA 23
BIBLIOGRAFIA 25

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

1. Introduzione

In questa dispensa di accompagnamento alla video-lezione, si presentano le principali operazioni sui vettori e sulle matrici, oltre che le funzioni per la rappresentazione grafica in R. In particolare, si illustrano le operazioni algebriche tra vettori, le operazioni per i vettori booleani e le operazioni algebriche tra matrici, incluso il prodotto tra matrici. Per quanto riguarda la rappresentazione grafica, si introducono alcuni dataframe disponibili nel pacchetto MASS di R e si illustrano le funzioni e le personalizzazioni per ottenere i seguenti tipi di grafico: grafico a dispersione, grafico a barre, istogramma, boxplot e correlogramma.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

2. Operazioni con i vettori

R permette l'esecuzione di **operazioni algebriche tra vettori**. La prima operazione che andremo ad analizzare è l'*addizione di una costante ad un vettore* ottenibile nel seguente modo:

```
> c(1,2,3,4,5)+10
[1] 11 12 13 14 15
```

La seconda è una *sottrazione tra due vettori*. Per eseguire tale operazione, i due vettori devono avere la ***stessa lunghezza*** in quanto la sottrazione avviene per elementi corrispondenti:

```
> c(1,2,3) - c(4,5,6)
[1] -3 -3 -3
```

La moltiplicazione di una costante ad un vettore si ottiene nel seguente modo:

```
> c(1,2,3,4,5)*10
[1] 10 20 30 40 50
```

Il *prodotto interno*, cioè la moltiplicazione di due vettori (aventi stessa lunghezza), è il prodotto di elementi corrispondenti nei due vettori:

```
> c(1,2,3) * c(4,5,6)
[1]  4 10 18
```

In generale, per **elevare a potenza** un numero, esistono due possibilità in R. La prima è con il simbolo **^**, mentre il secondo è con il simbolo ******.

```
> 2^3
[1] 8
> 2**3
[1] 8
```

Per eseguire un **elevamento a potenza di un vettore con un altro vettore** (sempre per elementi corrispondenti) si procede nel seguente modo:

```
> c(2,3)**c(4,3)
[1] 16 27
```

In generale, il *quoziente di un rapporto con valori decimali* si ottiene nel seguente modo:

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

```
> rep(ore_lavoro, times = 4)
   Lunedì   Martedì Mercoledì   Giovedì   Venerdì     Lunedì   Martedì Mercoledì   Giovedì   Venerdì     Lunedì   Martedì
        8         8         8         4         8         8         8         8         4         8         8         8
Mercoledì   Giovedì   Venerdì     Lunedì   Martedì Mercoledì   Giovedì   Venerdì
        8         4         8         8         8         8         4         8
```

```
> 22/3
[1] 7.333333
```

Per ottenere il *quoziente della divisione intera senza resto*, invece, è necessario utilizzare il ***simbolo %/%*** come mostrato nel seguente esempio:

```
> 22 %/% 3
[1] 7
```

Il *modulo della divisione* (***resto***) si ottiene, invece, con il ***simbolo %%***

```
> 22%%3
[1] 1
```

Per creare una ***sequenza di numeri***, ad esempio da 1 a 10 con passo 1, si utilizza la seguente simbologia:

```
> 1:10
 [1]  1  2  3  4  5  6  7  8  9 10
```

Per creare una *sequenza di numeri* specificando il passo si utilizza la ***funzione seq***():

```
> seq(from = 0, to = 10, by = 2)
[1]  0  2  4  6  8 10
```

È possibile creare una *sequenza* anche senza specificare ogni volta gli argomenti ***from, to*** e ***by***, purché si mantengano nell'ordine prestabilito:

```
> seq(0,10,2)
[1]  0  2  4  6  8 10
```

R offre anche la possibilità di **ripetere un oggetto** (numero o vettore) un determinato numero di volte. Nel caso seguente, si ripeterà il numero 12 per tre volte.

```
> rep(12, times = 3)
[1] 12 12 12
```

Nel caso seguente, invece, si ripeterà il vettore etichettato *ore_lavoro* per quattro volte.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Si può creare anche un vettore dove ogni elemento di esso è *ripetuto un determinato numero di volte:*

```
> rep(c(1,2,3), each = 2, times =3)
 [1] 1 1 2 2 3 3 1 1 2 2 3 3 1 1 2 2 3 3
```

Per controllare la lunghezza di un vettore si usa la ***funzione length***() che restituisce il numero di elementi del vettore stesso:

```
> length(c(1,2,3,4,5))
[1] 5
```

È importante sottolineare che la funzione ***length***() applicata ad un **dataframe** non restituisce il numero di righe, ma di ***colonne***. Ad esempio, con il dataframe test che ha 3 righe e 6 colonne:

```
> test
      anni sposato  regione     risultato ID ID_2
Anna    30    TRUE Piemonte        Ottimo  1   10
Paolo   27   FALSE    Lazio Insufficiente  2   20
Luca    24   FALSE  Liguria   Sufficiente  3   30
```

Si ottiene come risultato della funzione length() applicata a test il numero delle colonne (6), mentre come risultato della funzione nrow() applicata a test il numero delle righe (3).

```
> length(test)
[1] 6
> nrow(test)
[1] 3
```

In R si può, inoltre, ***comporre un nuovo vettore*** utilizzando vettori già preesistenti. Ad esempio, si vuole inserire il numero 6 al centro del vettore composto dagli elementi 1,2,3,4,5. Si procede, quindi, con il seguente codice:

```
> numeri = c(1,2,3,4,5)
> nuovi_numeri = c(numeri[1:3],6, numeri[4:5])
> nuovi_numeri
[1] 1 2 3 6 4 5
```

Per ***incollare gli elementi di un vettore in una stringa*** separati da un carattere (es. //) si utilizza la ***funzione paste***() come nell'esempio seguente in cui i numeri del vettore *nuovi_numeri* vengono separati da //.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

```
> paste(nuovi_numeri, collapse = "//")
[1] "1//2//3//6//4//5"
```

Ovviamente, R mette a disposizione operazioni anche per i *vettori logical* (***booleani***). Si ipotizzi di avere il seguente vettore:

```
> valori = c(TRUE, FALSE, TRUE)
```

Per ***invertire i valori logici*** di tutti gli elementi è sufficiente anteporre il simbolo punto esclamativo ! al vettore.

```
> !valori
[1] FALSE  TRUE FALSE
```

Inoltre, dato che il valore TRUE corrisponde ad 1 e FALSE a 0, è possibile ***sommare tutti gli elementi*** ed ottenere il numero degli elementi a TRUE come visibile nell'esempio seguente.

```
> valori = c(TRUE, FALSE, TRUE)

> valori %>% sum()
[1] 2
```

È possibile *anche trasformare un vettore logical in vettore numerico e viceversa* (funzioni di casting):

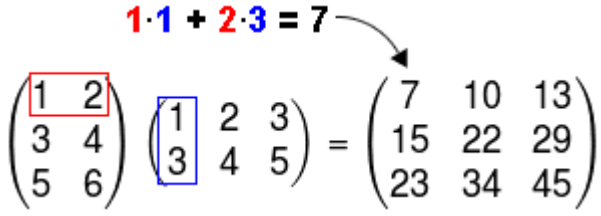
```
> as.numeric(valori)
[1] 1 0 1
> as.logical(c(0,1,1,1,0))
[1] FALSE  TRUE  TRUE  TRUE FALSE
```

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

3. Operazioni con le matrici

Le ***operazioni algebriche tra matrici*** seguono la stessa logica delle operazioni tra vettori, ma, ovviamente, seguono le regole del *calcolo matriciale*. Ad ogni modo, si sottolinea che per moltiplicare due matrici è necessario che il *numero di colonne della prima matrice sia uguale al numero di righe della seconda.* Inoltre, si ricorda che la moltiplicazione tra matrici **non è commutativa**. Lo schema che permette di riassumere la procedura di calcolo della moltiplicazione tra matrici è riportato nella figura seguente.



Si ipotizzi, ora, di avere a disposizione le seguenti due matrici:

```
> matrice_1 = matrix(c(1,2,3,4), byrow = FALSE, nrow = 2)
> matrice_2 = matrix(c(1,2,3,4), byrow = TRUE, nrow = 2)
> matrice_1
     [,1] [,2]
[1,]    1    3
[2,]    2    4
> matrice_2
     [,1] [,2]
[1,]    1    2
[2,]    3    4
```

Il *risultato* del **prodotto matriciale** tra matrice_1 e matrice_2 è il seguente:

```
> matrice_3 = matrice_1 %*% matrice_2
> matrice_3
     [,1] [,2]
[1,]   10   14
[2,]   14   20
```

Le restanti operazioni ricalcano le operazioni algebriche tra vettori. Ad esempio, per sommare due matrici si opererà come indicato di seguito:

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

```
> matrice_1 + matrice_2
     [,1] [,2]
[1,]    2    5
[2,]    5    8
```

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

4. Rappresentazione grafica

Per realizzare **grafici** su R e RStudio è possibile ricorrere ad alcune funzioni presenti nel pacchetto base. I grafici che si ottengono con il pacchetto base possono migliorare utilizzando il *pacchetto ggplot2* (che non verrà, però, trattato in questa lezione).

Nella trattazione verranno utilizzati dei database di esempio presenti nell'ambiente R nel pacchetto MASS che dovrà essere installato e caricato. Tra questi, il *dataframe whiteside* di MASS contiene il consumo settimanale di gas e la temperatura esterna media registrati nel sud-est dell'Inghilterra per due stagioni di riscaldamento una per ciascuna delle 26 settimane prima e una per ciascuna delle 30 settimane dopo l'installazione dell'isolamento delle pareti interrate. La registrazione di tali informazioni viene effettuata per valutare l'effetto dell'isolamento sul consumo di gas.

La struttura del database whiteside è la seguente:

```
> str(whiteside)
'data.frame':   56 obs. of  3 variables:
 $ Insul: Factor w/ 2 levels "Before","After": 1 1 1 1 1 1 1 1 1 1 ...
 $ Temp : num  -0.8 -0.7 0.4 2.5 2.9 3.2 3.6 3.9 4.2 4.3 ...
 $ Gas  : num  7.2 6.9 6.4 6 5.8 5.8 5.6 4.7 5.8 5.2 ...
```

Il dataframe ha 56 righe (osservazioni) e 3 colonne (variabili):

1. ***Insul*** - un fattore con due livelli prima e dopo l'isolamento (BEFORE e AFTER);
2. ***Temp*** - presumibilmente la temperatura esterna media in gradi Celsius. Questi valori sono troppo bassi per qualsiasi periodo di 56 settimane negli anni '60 nel sud-est dell'Inghilterra. Molto probabilmente, il valore registrato come Temp potrebbe essere la media settimanale dei minimi giornalieri;
3. ***Gas*** - il consumo settimanale di gas in migliaia di piedi cubi.

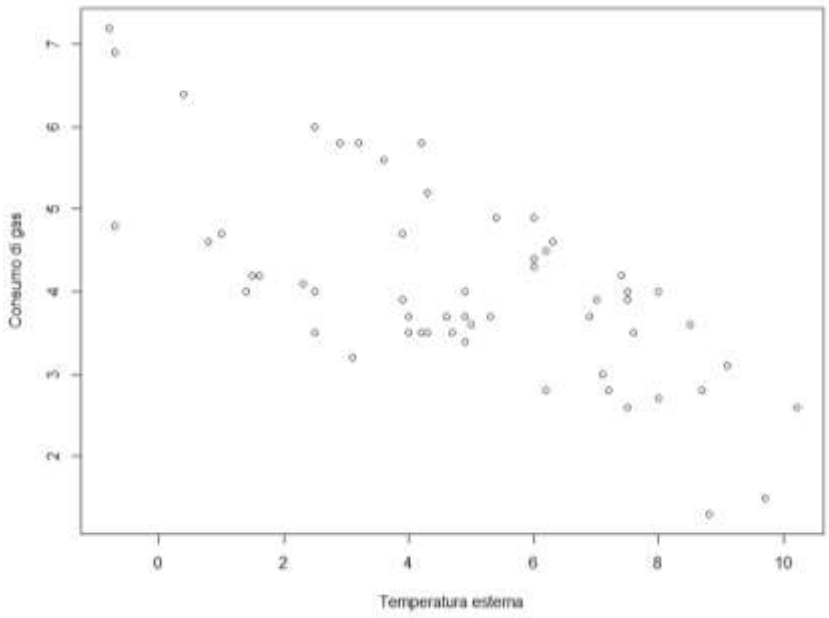
PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

4.1 Grafico a dispersione

Per la rappresentazione di due variabili numeriche quali *Temp* e *Gas* è consigliabile utilizzare un ***grafico a dispersione*** (**scatterplot**). Poniamo, quindi, la variabile *Temp* sull'asse delle ascisse e la variabile *Gas* sull'asse delle ordinate. Si provvede a specificare anche le rispettive etichette:

```
plot(x = whiteside$Temp, y = whiteside$Gas,
     xlab = "Temperatura esterna",
     ylab = "Consumo di gas")
```

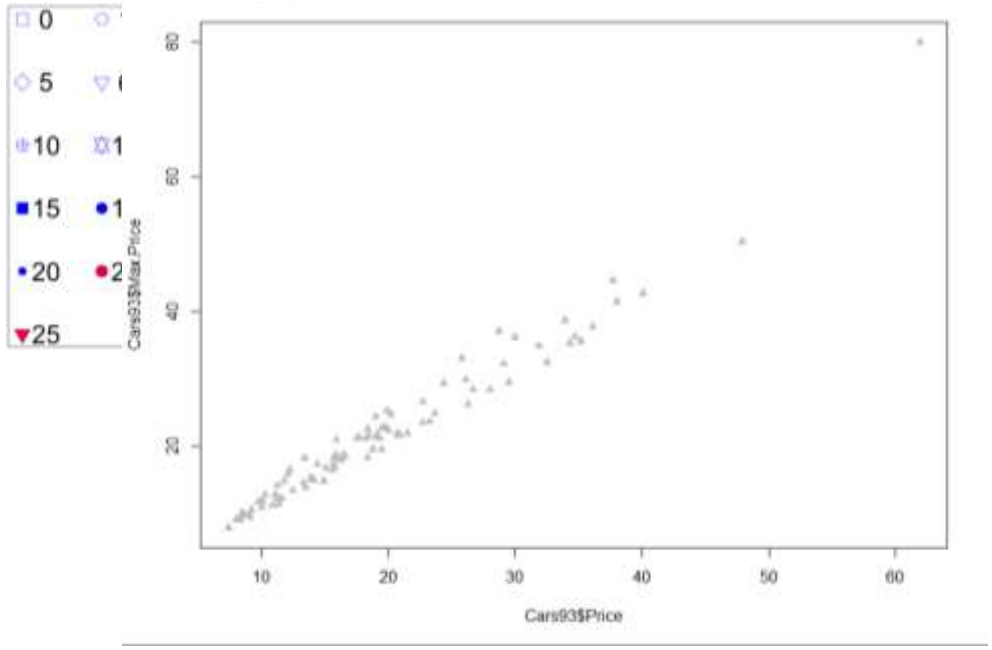


All'interno della funzione ***plot***() è possibile utilizzare diversi argomenti per rendere il grafico ancora più informativo. Per fare degli esempi ricorriamo al *dataframe Cars93* di MASS. Il dataframe Cars93 contiene i dati di 93 automobili in vendita negli Stati Uniti nel 1993. In particolare, il dataframe possiede 93 righe (una per automobile) e 27 colonne con diverse informazioni tecniche dell'automobile.

Gli argomenti ***pch*** e ***col*** della funzione ***plot***() permettono di specificare, rispettivamente, la *forma* e il *colore* dei punti del ***grafico a dispersione***. Per quanto riguarda l'argomento *pch*, esso può assumere un valore nel range 0-25 estremi inclusi. Nella figura seguente, si riporta la corrispondenza tra il codice pch e la forma del punto del grafico a dispersione.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).



Per la tipologia di colori da cui attingere, invece si rimanda al seguente link: http://www.stat.columbia.edu/~tzheng/files/Rcolor.pdf

Procediamo, quindi, con il grafico del *prezzo* (ascisse) e *prezzo massimo* (ordinate) dei valori di Cars93.

```
plot(Cars93$Price, Cars93$Max.Price, pch = 17, col = "grey")
```

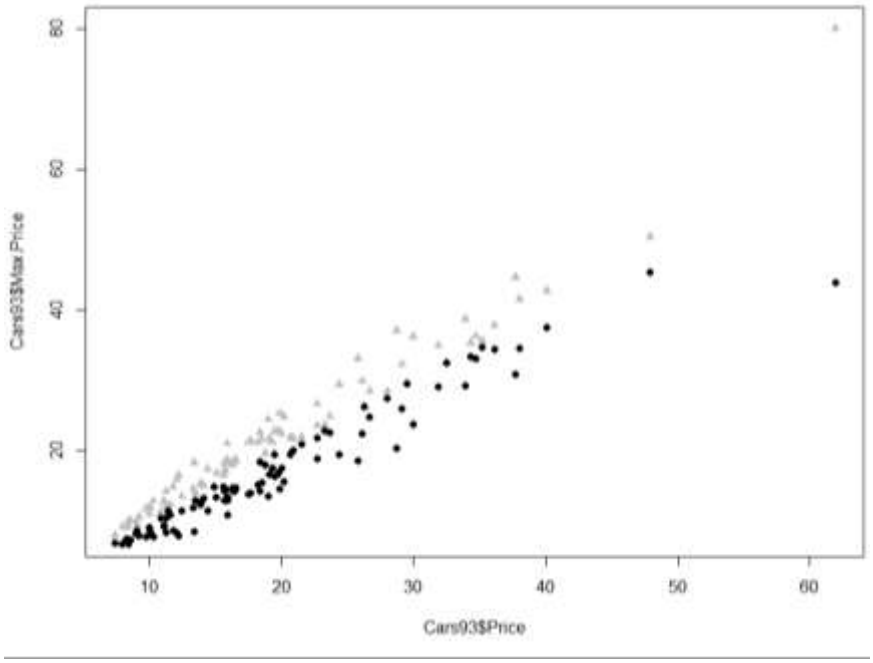
Una volta creato un grafico come quello precedente, è possibile **aggiungere nuovi punti specificando nuove variabili, forme e colori** tramite la funzione ***points***(). La funzione ***points***() deve essere lanciata dopo il comando della funzione *plot*() e agirà direttamente sul grafico presente nel quadrante di RStudio in basso a destra.

Ora si andrà ad utilizzare la stessa variabile in ascissa (**price**), ma in ordinata si riporta il *prezzo minimo dell'automobile* (in nero). Nello stesso grafico si avranno, quindi, prezzi minimi e massimi della stessa vettura.

```
> plot(Cars93$Price, Cars93$Max.Price, pch = 17, col = "grey")
> points(Cars93$Price, Cars93$Min.Price, pch = 16, col = "black")
```

PEGASO
Università Telematica

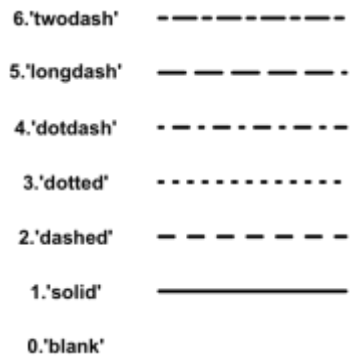
Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).



Una volta creato un grafico come quello precedente, è possibile tracciare, poi, una retta di tendenza con la funzione ***abline***() per cui:

- l'argomento ***a*** indicherà *l'intercetta;*
- l'argomento ***b*** indicherà il *coefficiente di regressione;*
- l'argomento ***lty*** specifica il *tipo della retta.*

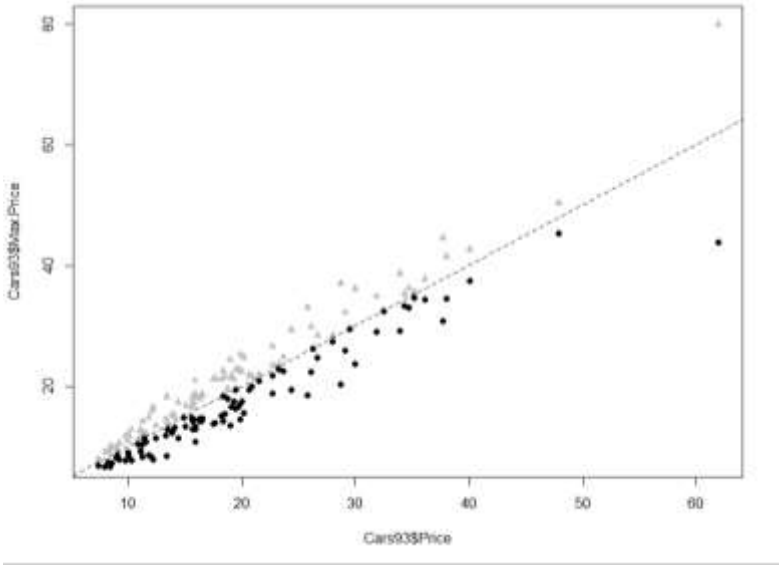
Nella figura seguente si riporta la corrispondenza tra i valori del parametro lty e il tipo della retta.




```
abline(a=0, b = 1, lty = 2)
```

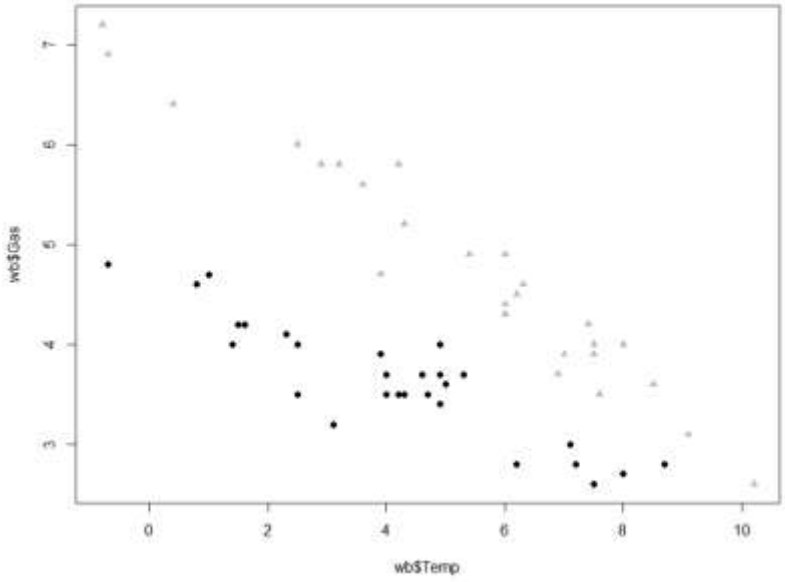
PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).



Tornando al caso precedente del consumo di gas (del *dataframe whiteside*) è possibile, inoltre, **separare i dati prima e dopo l'isolamento** utilizzando il seguente codice.

```
> wb = whiteside$Insul == "Before"
> wb = whiteside[wb,]
>
> wa = whiteside$Insul == "After"
> wa = whiteside[wa,]
>
> plot(x = wb$Temp, y = wb$Gas, pch = 17, col = "grey")
> points(x = wa$Temp, y = wa$Gas, pch = 16, col = "black")
```



Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Dal grafico, si osserva che a parità di temperatura la quantità di gas consumata è inferiore dopo l'isolamento (**nero**) rispetto a prima dell'isolamento (**grigio**).

Per visualizzare ***due grafici uno accanto all'altro*** è possibile determinare uno spazio grafico composto da *righe e colonne* tramite la funzione ***par***() specificando al suo interno ***l'argomento mfrow***. Ad esempio, con la scrittura:

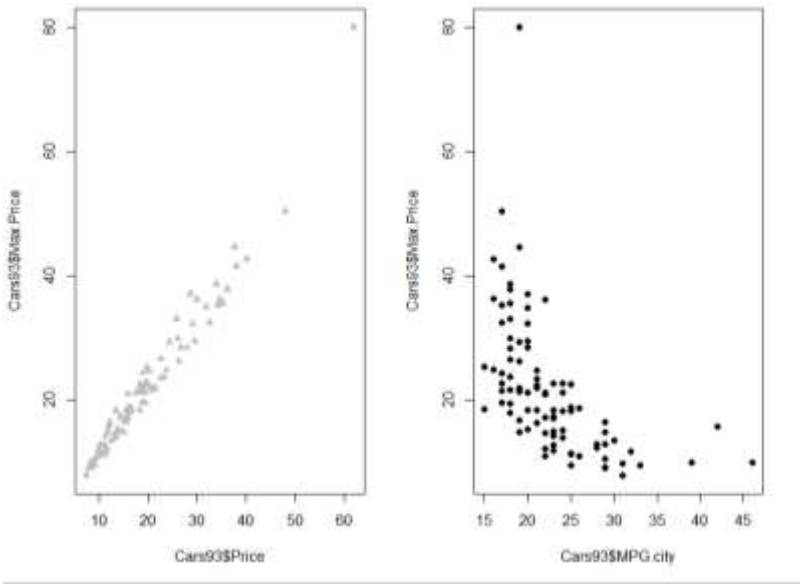
par(mfrow = c(1,2))

si «apre» uno spazio grafico composta da una riga e due colonne. Per questo motivo, i grafici lanciati successivamente sono posizionati uno accanto all'altro.

Una volta creati i grafici, per *ripristinare lo spazio grafico originario* (una riga e una colonna), si usa l'istruzione

par(mfrow = c(1,1))

```
> par(mfrow = c(1,2))
> plot(Cars93$Price, Cars93$Max.Price, pch = 17, col = "grey")
> plot(Cars93$MPG.city, Cars93$Max.Price, pch = 16, col = "black")
> par(mfrow = c(1,1))
```



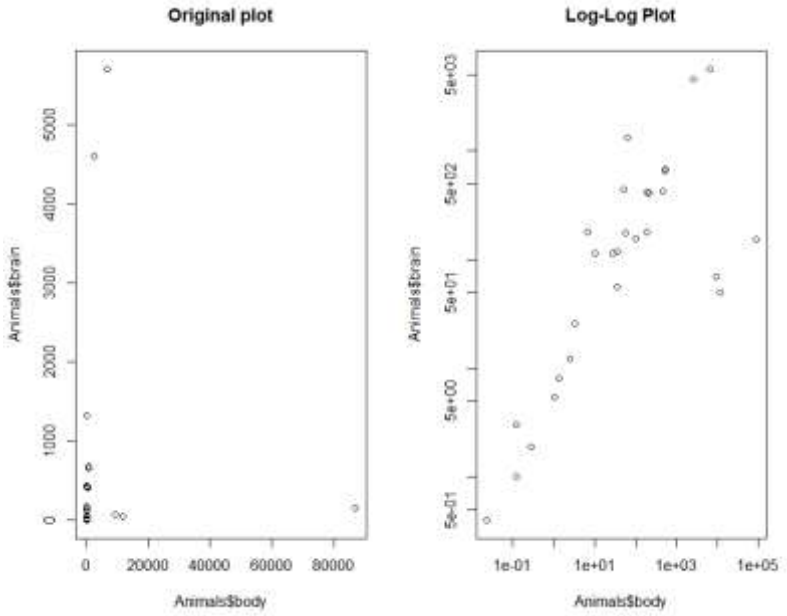
Esploriamo un altro database del pacchetto MASS, il ***dataframe Animals***. Il dataframe *Animals* contiene il *peso medio del cervello* (in grammi) e *del corpo* (in chilogrammi) per 28 specie di animali terrestri. I campi del dataframe sono, infatti, ***body*** e ***brain***.

Affianchiamo due grafici delle variabili *body* e *brain*:

- nel grafico di sinistra si relazionano i *dati grezzi delle variabili;*
- nel grafico di destra, la loro *forma logaritmica* (tramite l'argomento **log**).

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

```
> par(mfrow = c(1,2))
> plot(Animals$body, Animals$brain)
> title("Original plot")
> plot(Animals$body, Animals$brain, log = "xy")
> title("Log-Log Plot")
> par(mfrow = c(1,1))
```



4.2 Grafico a barre

Per *descrivere statisticamente una variabile di tipo qualitativo* è necessario ricorrere allo **studio delle frequenze** (*assolute* o *relative*) delle sue categorie.

Dal punto di vista grafico, è necessario utilizzare i cosiddetti ***grafici a barre*** che possono essere interpretati come la versione «*discreta*» degli *istogrammi* (prerogativa delle variabili di tipo continuo). È necessario, quindi, passare dalla creazione di una distribuzione di frequenza in forma tabellare applicando la ***funzione table***() al ***vettore con le osservazioni***.

In questo caso, si vuole analizzare la variabile fattoriale ***Insul*** del dataframe whiteside. ***Insul*** ha due categorie (livelli):

1. Before;
2. After.

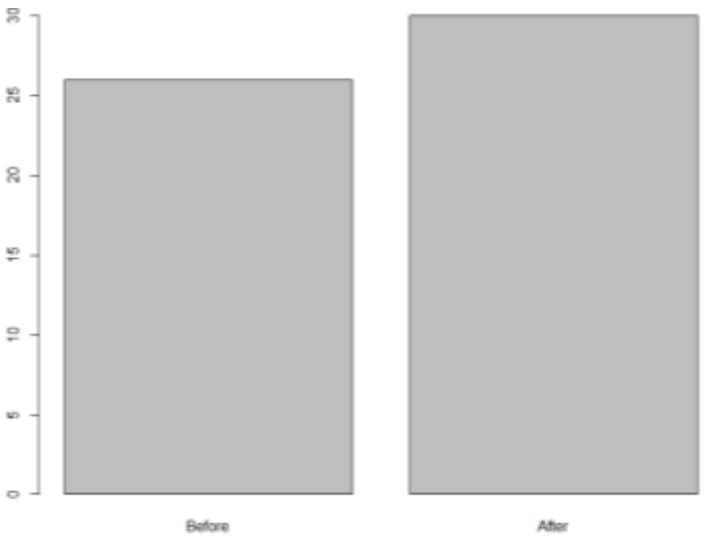
Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

```
> tbl = table(whiteside$Insul)
> tbl

Before  After
    26     30
```

Applicando la funzione ***barplot***() all'oggetto creato, si disegna il grafico a barre.

```
> barplot(tbl)
```

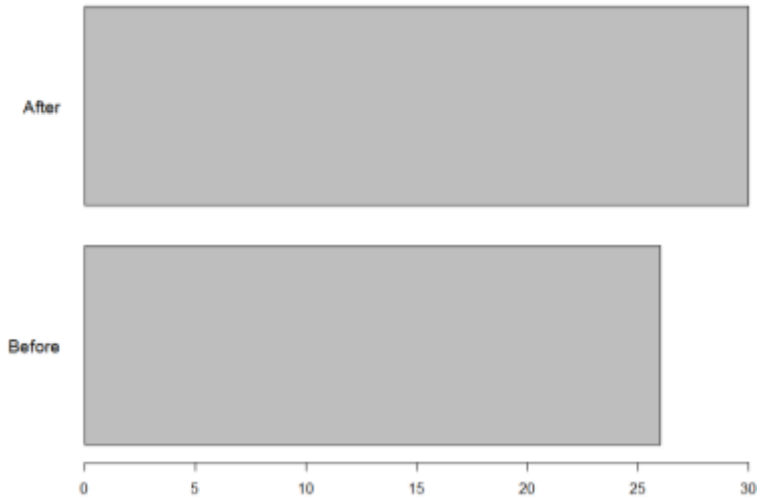


Nel grafico seguente si mostra, invece, come tale grafico può essere:

- ***ruotato in orizzontale*** grazie all'argomento *horiz = TRUE;*
- ***etichettato*** con etichette perpendicolari agli assi grazie all'argomento *las = 1;*
- ***etichettato*** con etichette più grandi del 20% grazie all'argomento *cex.names = 1.2;*
- ***colorato*** grazie all'argomento *col*.

```
barplot(tbl, las=1, cex.names = 1.2,
        horiz = TRUE, col = "grey")
```

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

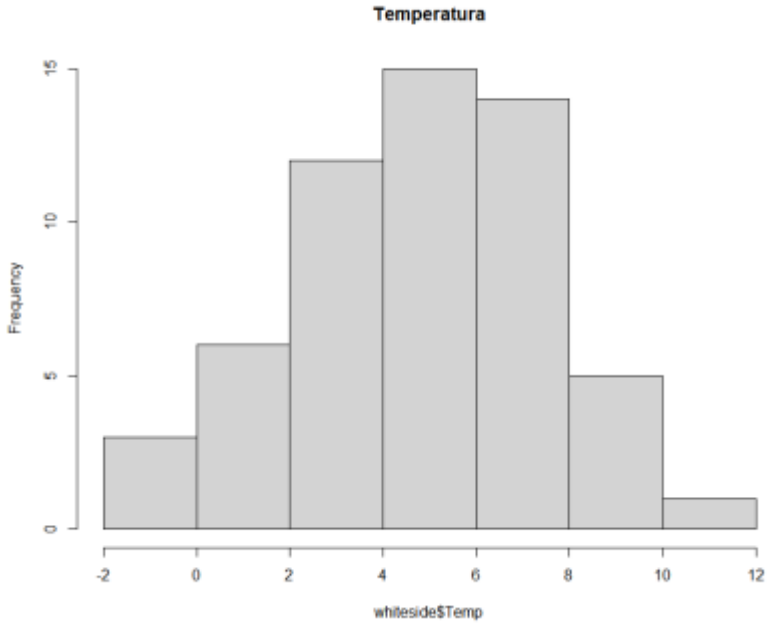


4.3 Istogramma

Per rappresentare la ***distribuzione di frequenza di una variabile continua*** dobbiamo utilizzare un **istogramma**. Per fare ciò è necessario passare da un ***raggruppamento in classi***.

Il *numero di colonne* (e di classi) è, quindi, *inversamente proporzionale all'ampiezza delle stesse.* Ne segue che maggiore ampiezza corrisponde a meno classi. La scelta del numero di colonne influenza la forma del grafico. Di seguito si presenta l'istogramma della temperatura del dataframe whiteside.

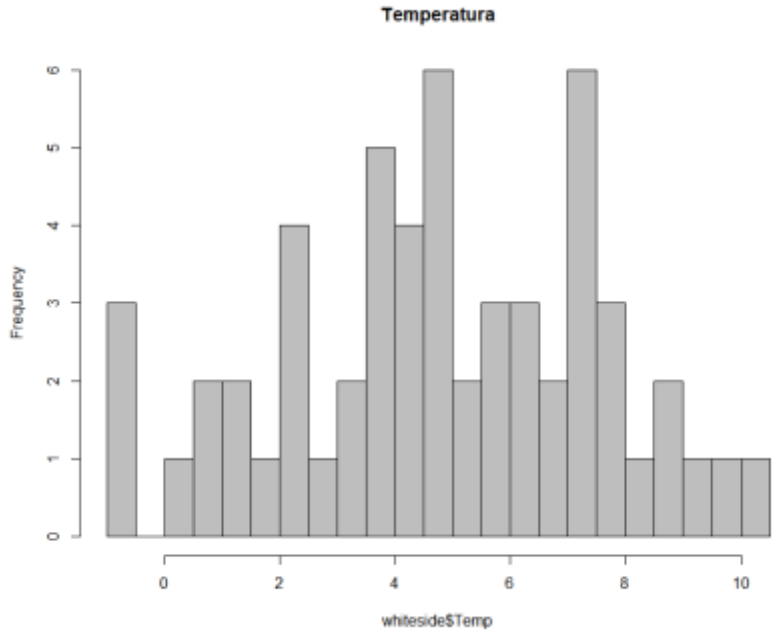
```
hist(whiteside$Temp, main = "Temperatura")
```



Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Lo stesso istogramma può essere riproposto sia specificando il numero delle classi pari a 30 (argomento ***breaks***), sia colorando le colonne di grigio tramite l'argomento ***col***. Il titolo viene specificato sempre con l'argomento main. È molto importante osservare che, in base al numero di osservazioni, *R si riserva di ridurre il numero di classi se eccessivo.*

```
hist(whiteside$Temp, main = "Temperatura", breaks = 30, col = "grey")
```



Trattandosi di una variabile continua, è interessante conoscere anche la sua ***funzione di densità*** che può essere rappresentata in due modi:

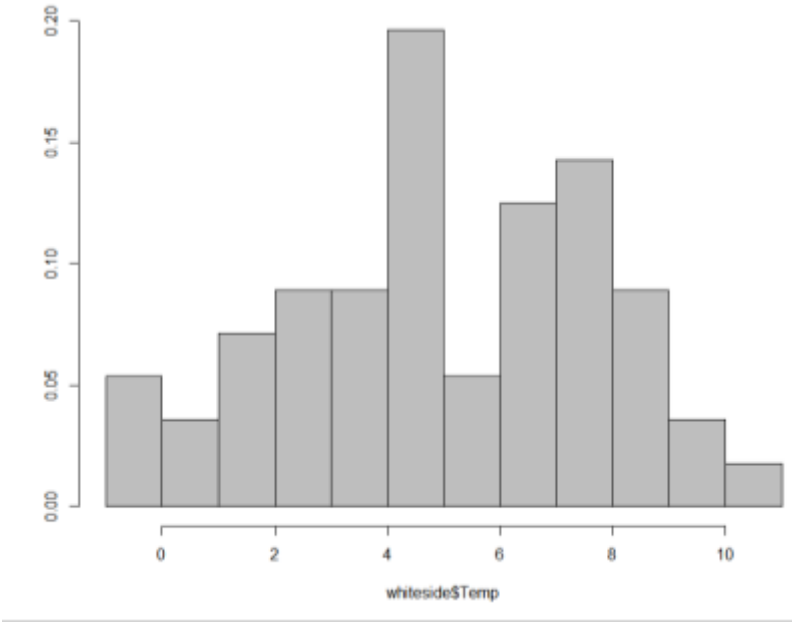
1. *tramite colonne* con la funzione ***truehist***() del pacchetto MASS per cui l'argomento ***nbins*** specifica il *numero di colonne;*
2. *tramite grafico a linee* con la funzione ***density***().

La funzione *density*() crea un oggetto di *coordinate x e y della funzione di densità*. Tale oggetto all'interno della funzione ***lines***() per generici *grafici a linee* permette di ottenere il grafico di funzione di densità.

Di seguito si riporta la prima modalità per il grafico della funzione di densità.

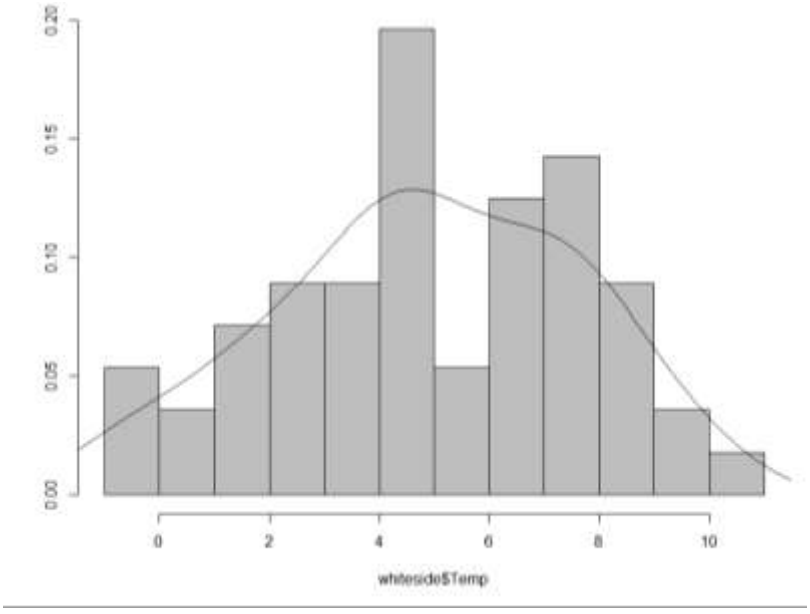
```
truehist(whiteside$Temp, nbins = 10, col = "grey")
```

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).



Di seguito, invece, si riporta la seconda modalità per il grafico della funzione di densità (si noti il grafico a linee sovrapposto al precedente).

```
> density(whiteside$Temp) %>% lines()
> density(whiteside$Temp) %>% class()
[1] "density"
```



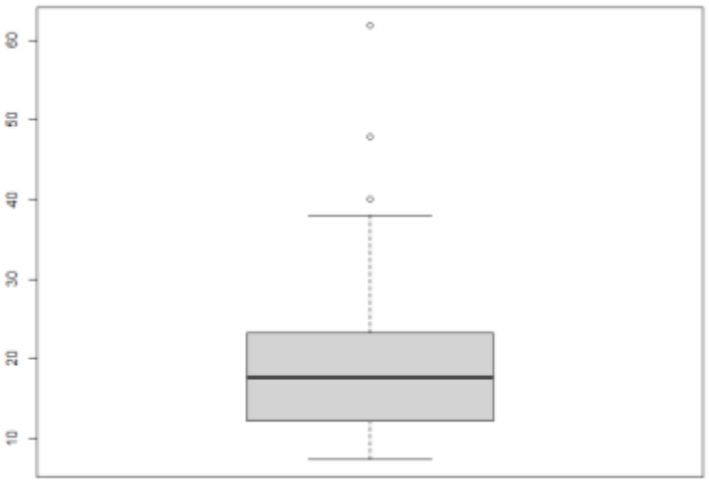
PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

4.4 Boxplot

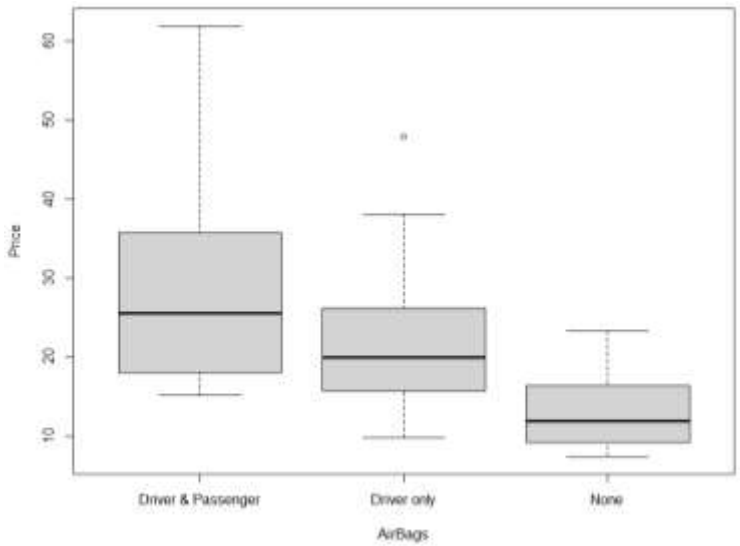
Il **boxplot** è una rappresentazione grafica utile per verificare la ***dispersione di una determinata variabile numerica***. Riportiamo il boxplot della variabile Price di Cars93.

```
boxplot(Cars93$Price)
```



Tale variabile può essere suddivisa in base ad una ***seconda variabile fattoriale*** (es. *AirBags*) nel seguente modo:

```
boxplot(Price ~ AirBags, data = Cars93)
```



PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Nel caso in cui le categorie oggetto di studio abbiano numerosità diverse, è consigliabile inserire questa informazione nel grafico ponendo l'argomento ***varwidth = TRUE***. La *larghezza dei boxplot* varierà così a seconda della numerosità del gruppo.

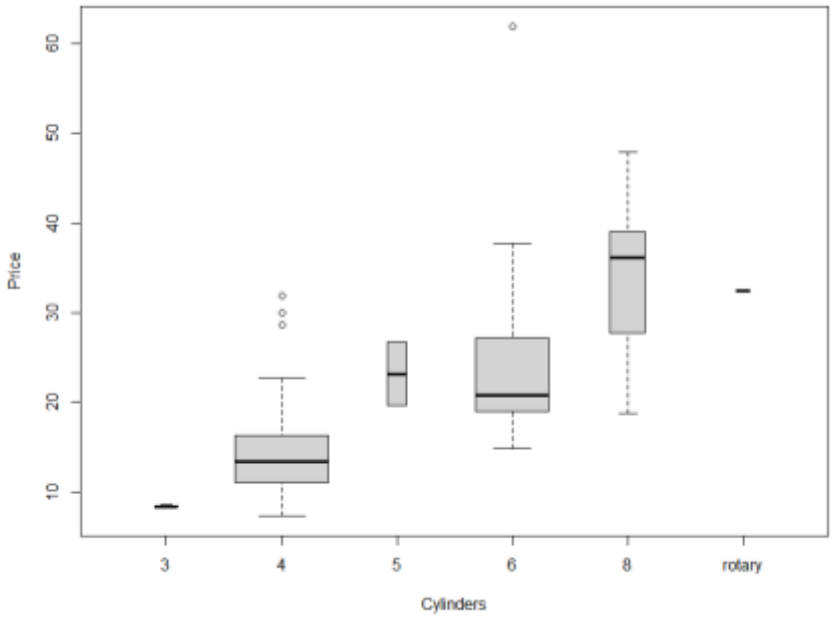
Si ipotizzi, ora, di graficare ***Price*** a seconda della variabile fattoriale ***Cylinders*** che presenta numerosità molto diverse.

```
table(Cars93$Cylinders)

  3   4   5   6   8 rotary
  3  49   2  31   7      1
```

Il risultato della funzione boxplot risulta essere:

```
boxplot(Price ~ Cylinders, data = Cars93, varwidth = TRUE
```



Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

4.5 Correlogramma

Il ***corrplot*** o ***correlogramma*** è uno strumento utile per la visualizzazione rapida delle **correlazioni** tra le variabili numeriche di un dataset. La funzione ***corrplot***() si trova nel pacchetto corrplot.

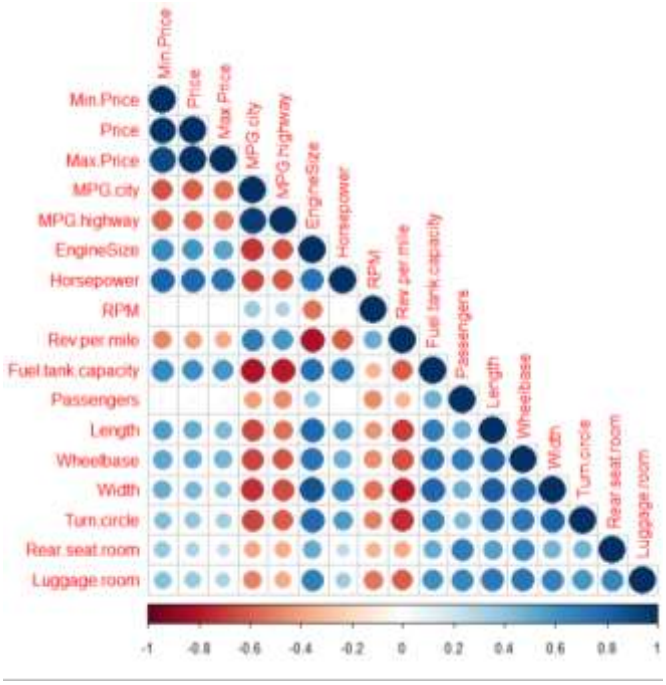
Si vogliono studiare, ad esempio, le *correlazioni tra le variabili numeriche del database Cars93.* Tramite la funzione ***select***() del pacchetto *dplyr* si selezionano le *variabili di interesse* come segue:

```
Cars93_num = Cars93 %>% dplyr::select(Min.Price:MPG.highway,
                                      EngineSize:Rev.per.mile,
                                      Fuel.tank.capacity:Luggage.room)
```

Si calcola inizialmente la **matrice di correlazione tra variabili** specificando con l'argomento ***use*** di utilizzare solo le coppie di osservazioni complete. In questo modo, si elude il problema dei possibili dati mancanti.

Successivamente, la matrice viene inserita all'interno della funzione ***corrplot***(). Con l'argomento *type* si specifica di voler osservare solo la parte di grafico sotto la diagonale. *La grandezza dei cerchi, poi, è direttamente proporzionale alla forza della relazione.*

```
> library(corrplot)
corrplot 0.90 loaded
> cor(Cars93_num, use = "pairwise.complete.obs") %>% corrplot(type = "lower")
```



Nell'esempio proposto non è stata rappresentata la matrice di correlazione. Infatti, quando il numero di variabili comincia ad essere particolarmente elevato, la sua lettura può risultare confusa e di non

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

immediata interpretazione. Il **correlogramma** risolve questa situazione proponendo un *grafico di facile e veloce comprensione.*

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Bibliografia

- Botto M., Raganelli V. (2021). Programmazione e analisi statistica con R. in riga edizioni.

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).