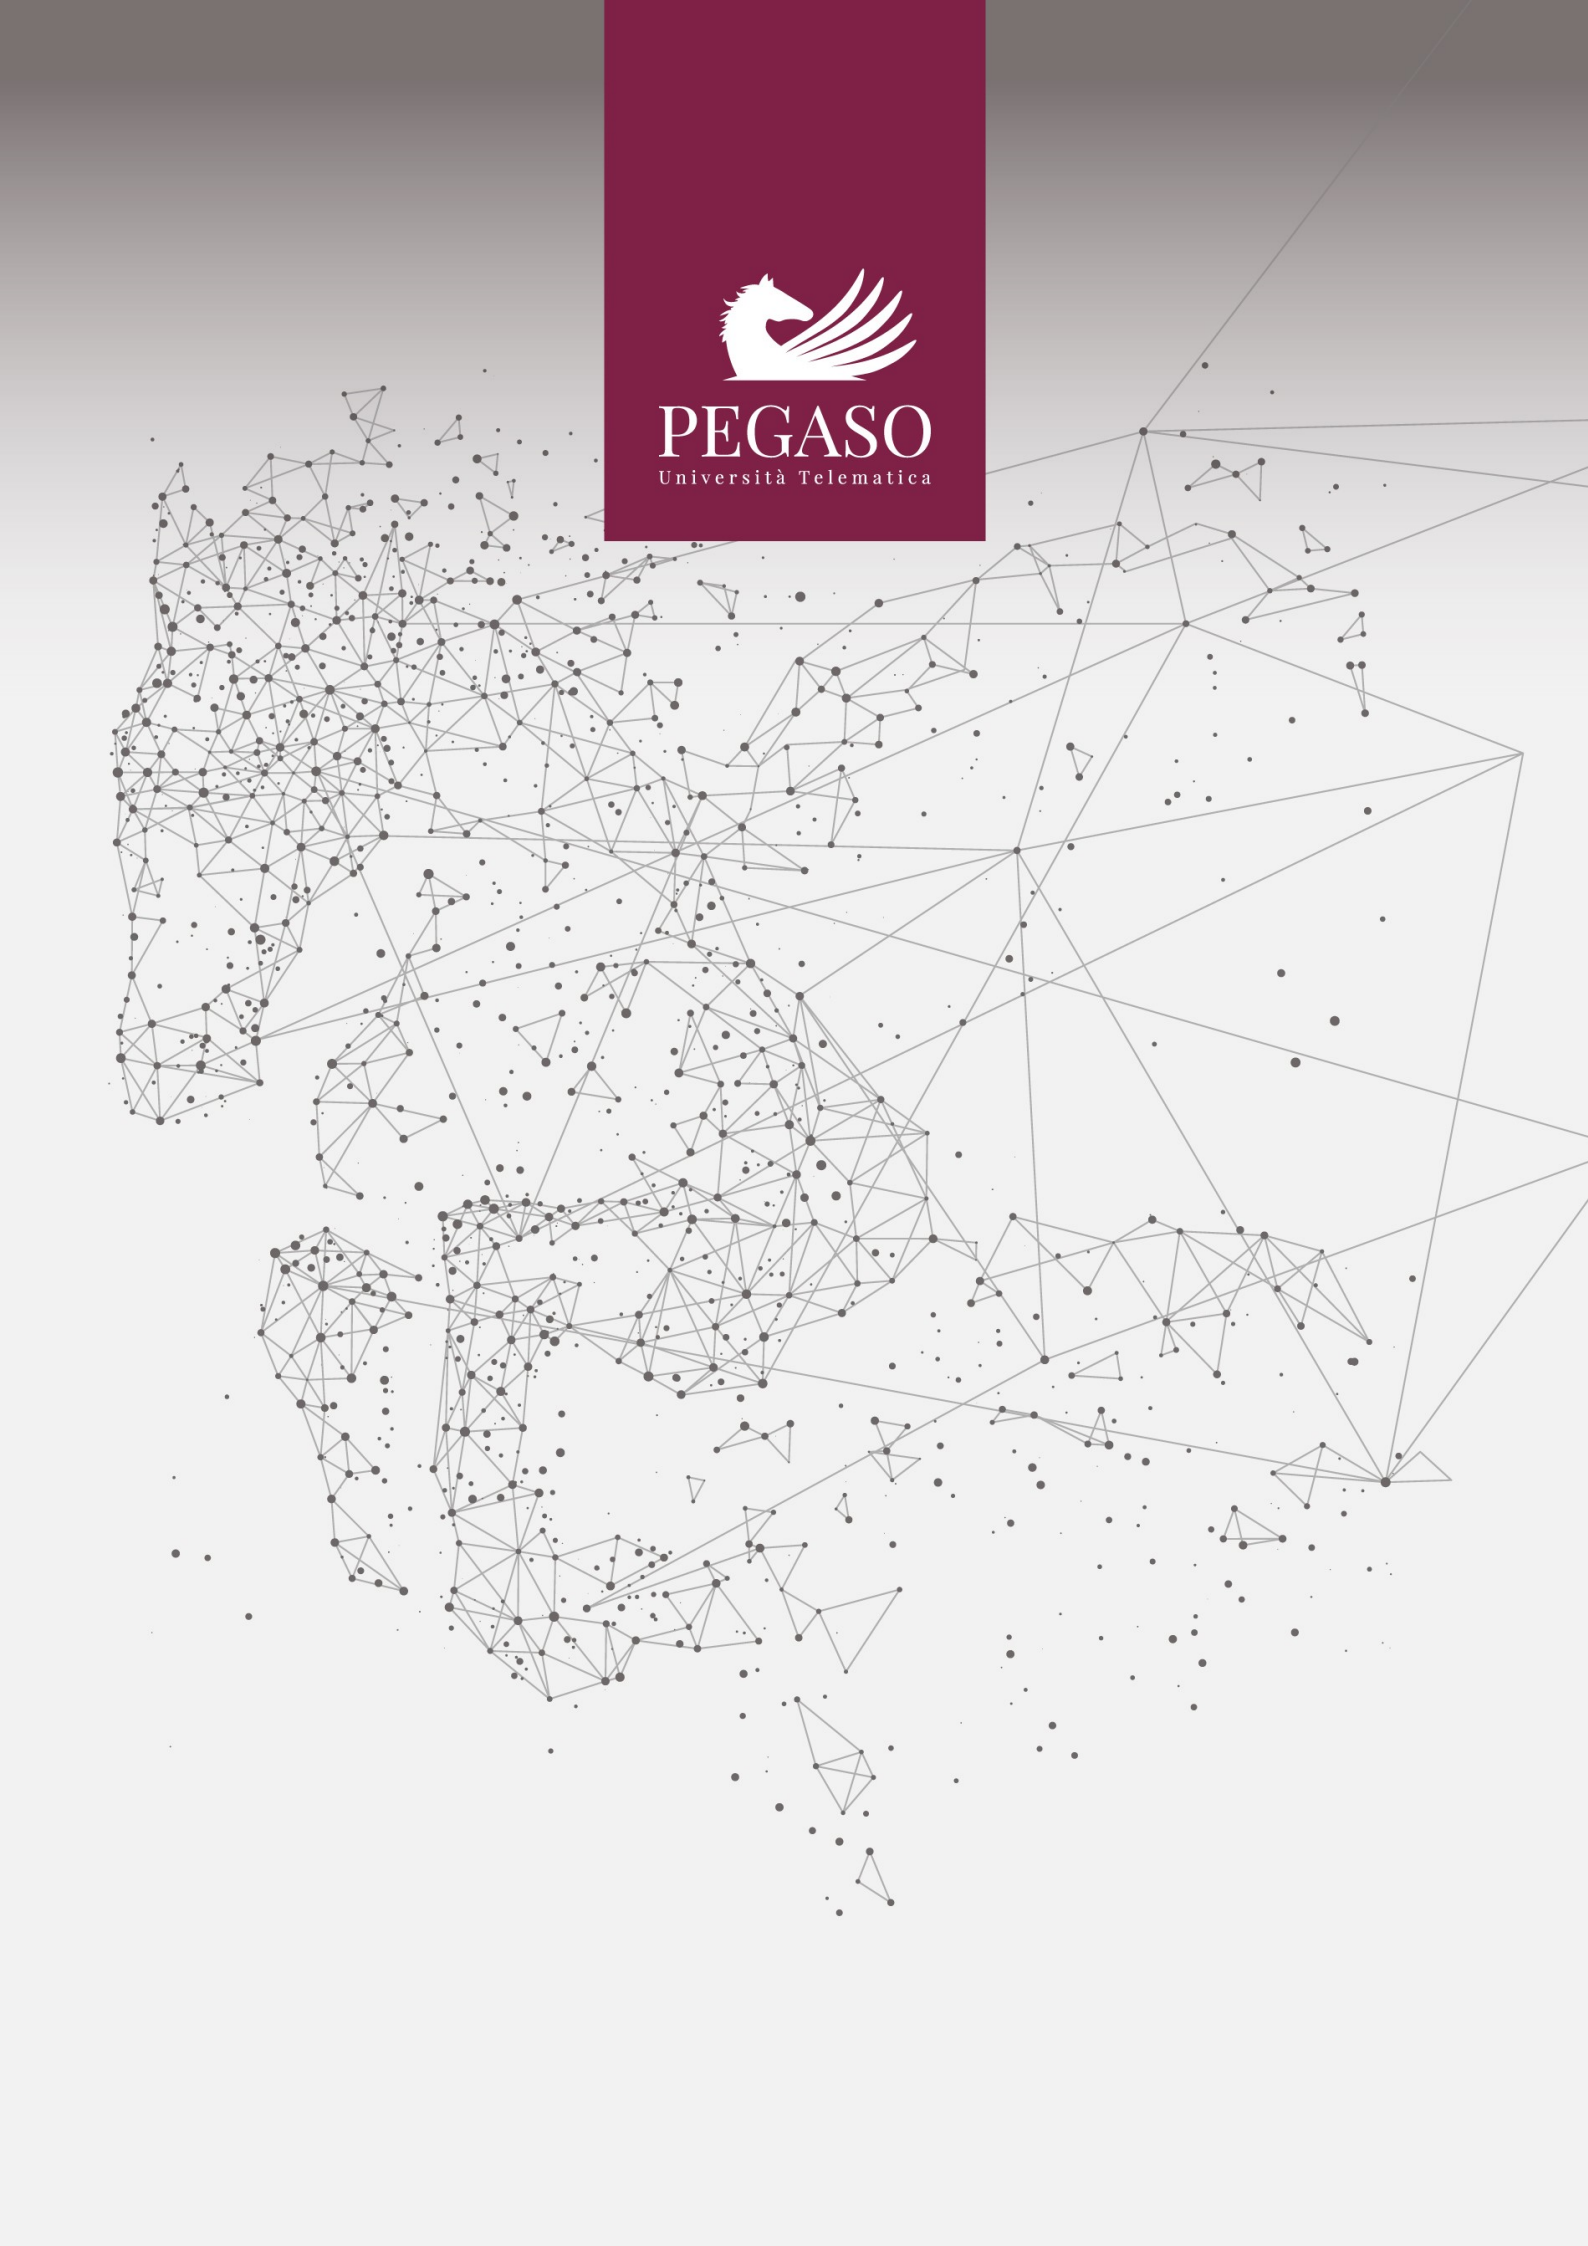

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Indice

1. INTRODUZIONE....3
2. DEFINIZIONE DEL PROBLEMA....4
3. TRADUZIONE DEL PROBLEMA IN METRICHE MISURABILI....8
4. IDENTIFICARE LA VARIABILE TARGET E I RELATIVI KPI....10
5. L'ANALISI DI CORRELAZIONE....18
BIBLIOGRAFIA....19

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

1. Introduzione

In questa dispensa di accompagnamento alla video-lezione, si presenta l'analisi preliminare dei problemi di data science. In particolare, si approfondiscono le fasi per la definizione e il riconoscimento di un problema di data science. Successivamente, si illustra l'approccio per esplorare i Key Performance Indicator (KPI) che misurano il problema in questione e illustrano ai soggetti interessati l'impatto del problema stesso. Inoltre, si presenta un problema pratico di data science e si illustrano i codici Python per identificare la variabile target e i relativi KPI. Infine, si introduce l'analisi di correlazione tra le variabili e la variabile target.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

2. Definizione del problema

Uno dei momenti più importanti e punto iniziale di qualunque progetto di scienza dei dati (***data science***), è quello in cui **si comprende e si definisce il problema da risolvere.** Per esaminare in dettaglio un problema e definire il suo ambito, è possibile utilizzare le **metriche esistenti** per spiegare i modelli ad esso correlati. Si possono, inoltre, ***quantificare e analizzare i dati storici*** e ***generare nuovi parametri.***

Le metriche identificate sono i **Key Performance Indicator** (***KPI***) che *misurano* il problema in questione e illustrano ai soggetti interessati l'impatto del problema stesso. Il processo della risoluzione di un problema di data science con programmi scritti in Python prevede, quindi, i seguenti passaggi:

1. **comprensione e definizione** del problema;
2. **identificazione dei parametri chiave** ad esso collegati;
3. utilizzo di librerie Python per il **calcolo dei KPI.**

Un **problema di data science** è una sfida a lungo o a breve termine che un'entità (commerciale o non commerciale) si trova a dover affrontare perché essa può **impedire il raggiungimento degli obiettivi aziendali**. Tale problema, inoltre, può rappresentare un ***vincolo per la crescita e la sostenibilità*** dell'azienda stessa. I **problemi di data science** sono moltissimi e variegati. Alcuni esempi di problemi di data science sono:

- il pronostico della domanda di prodotti di consumo in una settimana per la settimana successiva;
- l'ottimizzazione delle operazioni di logistica per la logistica di terze parti (3PL);
- l'individuazione di operazioni fraudolente nel settore delle richieste di indennizzo da parte delle assicurazioni.

Ovviamente, la scienza dei dati non è una tecnologia «magica» che può risolvere tali problemi semplicemente immettendo dati in algoritmi predefiniti. I problemi di data science sono, infatti, *complessi per quanto riguarda l'approccio e la progettazione necessari per creare progetti completi di analisi.*

Innanzitutto, è necessario avere **chiaro l'obiettivo finale già nella fase di definizione dei requisiti**. La risoluzione dei problemi di scienza dei dati inizia **definendo quantitativamente il problema** e realizzando, poi, *analisi e soluzioni in linea con i requisiti.*

PEGASO Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Si riportano, ora, alcuni *esempi di casi d'uso comuni* nella scienza dei dati che offrono un'idea dei problemi effettivamente affrontati ad oggi e risolti con la scienza e l'analisi dei dati:

- previsioni non precise di domanda, ricavi, perdite;
- scarsa conversione, abbandono e conservazione dei clienti;
- frodi e prezzi nei settori prestiti e assicurazioni;
- valutazione inefficiente di clienti e fornitori/distributori;
- guasti e manutenzioni imprevedibili;
- analisi devi sentimenti e delle emozioni dei clienti attraverso dati testuali.

È possibile quindi individuare le seguenti fasi per **definire e riconoscere un problema**:

1. *identificazione del problema;*
2. *raccolta dei requisiti;*
3. *elaborazione dei dati e flusso di lavoro;*
4. *identificazioni di metriche misurabili;*
5. *documentazione e presentazione.*

Verrà, ora, presentato un esempio di problema per cui verranno svolte tutte le fasi appena citate.

1. <u>Identificazione del problema</u>

L'esempio oggetto di studio riguarda una **società di gestione patrimoniale** con un *forte potere di acquisizione dei clienti nel settore fondi comuni di investimento*. La società riesce, cioè, ad individuare e avvicinare i clienti giusti.

Tale società sta cercando di ***migliorare la fidelizzazione dei clienti per aumentare***:

1. il **fatturato medio** tenuto dai clienti stessi;
2. la **quota di portafoglio** dei loro clienti *premium*.

Ne segue che il problema può essere *riassunto* con la seguente domanda:

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

«*Come è possibile migliorare il fatturato medio generato dai clienti e la quota di portafoglio dei clienti premium attraverso l'analisi della fidelizzazione dei clienti?*»

2. Raccolta dei requisiti

Una volta ***identificato il problema***, è necessario interloquire con l'azienda cliente. Tale interlocuzione può includere un **esperto in materia**. Molto probabilmente sarà necessario uno sforzo per:

- comprendere la questione dal punto di vista dell'azienda;
- indagare sul problema da varie angolazioni;
- capire i requisiti;
- cercare di trovare il modo di definire il problema partendo dai dati storici esistenti.

3. Elaborazione dei dati e flusso di lavoro

Dopo aver compreso la questione nel dettaglio, la fase successiva consiste nell'individuare e concordare delle ***metriche quantificabili per misurare il problema***. Tale fase nel lungo periodo permette di evitare diversi problemi. Le **metriche** possono essere ***identificate con il sistema esistente*** che l'azienda usa per ***monitorare le prestazioni*** oppure possono essere ***ricavate da dati storici.***

Quando si studiano le metriche per esaminare il problema, i dati per la sua identificazione e analisi possono provenire da molteplici fonti (es. database, vecchi sistemi, dati acquisiti in tempo reale, ecc.). Sarà necessario, quindi, lavorare insieme al *team che gestisce i dati del cliente* in modo da estrarre e raccogliere le informazioni richieste e inserirle in strumenti analitici per ulteriori analisi. I dati ottenuti vengono ulteriormente analizzati per identificare i loro attributi importanti e capire come cambiano nel tempo *al fine di generare i KPI.*

4. Identificare le metriche misurabili

Una volta che i dati richiesti sono stati raccolti, è possibile ***sviluppare modelli descrittivi per analizzare i dati storici*** e ottenere intuizioni sul problema. Analisi e modelli descrittivi si basano sul sapere cosa è successo in passato attraverso ***l'analisi delle tendenze temporali*** e ***la distribuzione della densità di dati.***

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

In altre parole, è necessario studiare diversi *attributi dei dati storici* al fine di comprendere *quali sono collegate al problema attuale*. Nell'esempio oggetto di studio, la società di gestione patrimoniale sta cercando soluzioni al proprio ***problema specifico di fidelizzazione dei clienti***. Dovranno, quindi, essere generati ***KPI*** per *comprendere il problema della fidelizzazione.*

A tale scopo saranno estratti dati storici per analizzare i modelli di transazione dei clienti negli investimenti precedenti e ricavare da essi i KPI. Successivamente, tali KPI dovranno essere sviluppati in base alla loro rilevanza ed efficienza nello spiegare la variabilità del problema (nell'esempio la fidelizzazione dei clienti).

5. Documentazione e presentazione

La fase finale consiste nel ***documentare i KPI identificati***, le loro tendenze significative, il modo in cui possono incidere sull'impresa nel lungo periodo. Nel caso oggetto di studio di fidelizzazione dei clienti, i parametri:

1. *durata del rapporto;*
2. *frequenza media delle transazioni;*
3. *tasso di abbandono;*

possono fungere da ***KPI*** ed essere utilizzati per *spiegare quantitativamente il problema*. Ad esempio, si osserva l'andamento del tasso di abbandono e si scopre *una tendenza crescente negli ultimi 5 mesi.* Si rappresenta graficamente tale comportamento al cliente. Il cliente riesce facilmente a comprendere l'importanza di disporre di un'***analisi predittiva delle defezioni*** *in modo da identificare il cliente prima del distacco e puntare ad una maggiore fidelizzazione.*

La possibilità di avere un sistema di fidelizzazione pronto deve essere presentata al cliente al quale è destinata la **documentazione e la rappresentazione grafica dei KPI.** Nel caso di esempio, dovrebbero essere documentati e presentati al cliente i KPI identificati e la loro variazione nell'andamento.

PEGASO Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

3. Traduzione del problema in metriche misurabili

Per ogni problema specifico è necessario identificare i KPI che lo definiscono e studiare i dati ad esso correlati. Dopo aver generato i KPI relativi al problema, bisogna analizzare le tendenze e quantificare il problema attraverso i metodi di analisi preliminare dei dati. L'approccio per **esplorare i KPI** si basa sui seguenti passi:

1. *raccolta dei dati;*
2. *analisi della produzione di dati;*
3. *visualizzazione dei KPI;*
4. *rilevanza delle caratteristiche.*

1. <u>Raccolta dei dati</u>

I *dati necessari per analizzare il problema* fanno parte della definizione del problema stesso.

Ad ogni modo, la scelta degli attributi dei dati cambierà in base al problema. A tale scopo, possono essere considerati i seguenti esempi:

- se si tratta di un ***motore di suggerimenti*** o di ***un'analisi della probabilità di abbandono dei clienti***, bisognerà esaminare, oltre al resto, gli *acquisti passati e i dati del cliente;*
- se si tratta di una ***previsione di richiesta***, bisogna esaminare i *dati di vendita giornalieri.*

  Ne segue che i dati richiesti possono cambiare da problema a problema.

2. <u>Analisi della produzione di dati</u>

Dalle fonti di dati disponibili, il passo successivo è quello di ***identificare le metriche*** relative al problema definito. Oltre ad una pre-elaborazione, a volte la produzione delle metriche richiede anche una ***manipolazione dei dati***, mentre a volte le metriche sono ***disponibili direttamente nei dati forniti.***

Si supponga di esaminare un'analisi supervisionata come ad esempio un **problema di manutenzione preventiva** (cioè ***l'analisi predittiva*** che viene utilizzata per predire la condizione di apparecchiature o macchinari in servizio prima che si guastino) in cui sono utilizzati dati di log generati da sensori o computer.

Sebbene i **dati di log non siano strutturati**, è possibile identificare quali file di log spiegano i guasti dei macchinari e quali no. I dati non strutturati sono senza colonne o righe. Ad esempio, possono essere in formato XML o in un formato analogo. I dati di log devono essere **convertiti in colonne e righe o essere resi strutturati**. Bisogna, quindi, assegnare alle colonne di dati dei nomi convertendo i dati in righe e colonne.

PEGASO Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Ritornando al caso di studio, un esempio potrebbe essere quello di *identificare l'abbandono dei clienti* e *prevedere i futuri clienti* che potrebbero allontanarsi nel prossimo futuro quando si hanno dati transazionali sugli acquisti con le caratteristiche relative ad ogni acquisto.

In questo caso specifico, è necessario **manipolare i dati** e **trasformare i dati correnti** per identificare quali clienti hanno abbandonato e quali clienti non hanno abbandonato sulla base dei dati relativi agli acquisti. In altre parole, nei **dati grezzi** ci possono essere *molte righe di acquisti per ogni cliente* che forniscono la data di acquisto, le unità acquistate, il prezzo, ecc.

Tutti gli acquisti relativi a un cliente devono essere identificati come un'unica riga, sia se il cliente ha abbandonato (cioè ha smesso di usare un prodotto o un servizio), sia se il cliente non ha abbandonato.

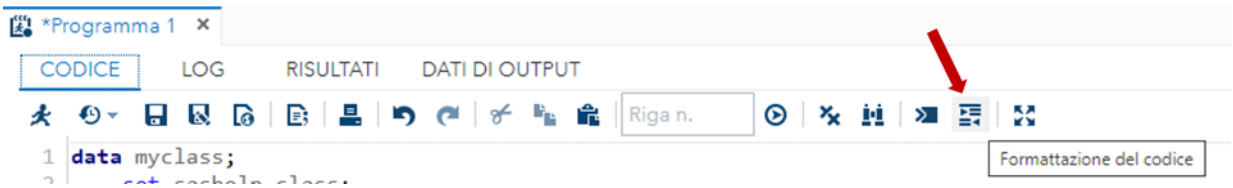
Si osserva, dunque, la **definizione di un KPI**: **abbandonato** o **non abbandonato** per un cliente. La ***variabile identificata che definisce il problema*** è la **variabile target** nota anche come *variabile di risposta* o *variabile dipendente.*

3. **Visualizzazione KPI**

Per comprendere le tendenze e i modelli dei KPI, è necessario rappresentare i KPI attraverso **tecniche di visualizzazione** interattiva. Per tale scopo, è possibile usare diversi metodi come il grafico a scatola, grafici delle tendenze temporali, grafici di densità, grafici a dispersione, ecc.

4. **Rilevanza della caratteristica**

Una volta *identificata la variabile target*, bisogna studiare gli altri attributi nei dati e la loro importanza per spiegare la ***variabilità della variabile target***. Si utilizzano, quindi, ***metodi di associazione, varianza e correlazione*** per stabilire le *relazioni tra la variabile target e le altre variabili* (***variabili esplicative*** o ***indipendenti***). Esistono diversi metodi algoritmi per il calcolo della rilevanza della caratteristica che possono essere utilizzati in base al tipo di variabili studiate (es. correlazione di Pearson, test chi-quadro, ecc.).



Come anticipato, la **variabile target** o *variabile di studio*, utilizzata come variabile/colonna nel dataset per lo studio del problema, è nota anche come **variabile dipendente.** Tutte le altre variabili/colonne prese in considerazione per l'analisi sono chiamate ***variabili indipendenti.***

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

4. Identificare la variabile target e i relativi KPI

Verrà ora presentato un problema di esempio **di sottoscrizione nel settore bancario.**

Verranno utilizzati i dati provenienti dalle **campagne di marketing diretto** effettuate da un *istituto bancario* portoghese in cui un cliente al termine della campagna ***apre o non apre un deposito a termine.***

Il **problema di sottoscrizione** è caratterizzato o definito in modo contrastante da ogni organizzazione. Nella maggior parte dei casi, i *clienti che sottoscriveranno un* ***servizio*** (il deposito a termine) hanno un **potenziale di conversione più elevato** (conversione da *persone da convincere* a *clienti*). Ne segue che in questo problema le **metriche di sottoscrizione**, cioè il *risultato di dati storici*, sono considerate la **variabile target** o **KPI.**

Si utilizza ***l'analisi descrittiva*** per esaminare le *tendenze dei dati.* Si inizia individuando e definendo la ***variabile target*** (nel caso in oggetto **sottoscritto** o **non sottoscritto**) e i *KPI relativi.*

Si scarica il file **bank.csv** dalla seguente risorsa online (*UC Irvine Machine Learning Repository*): https://archive-beta.ics.uci.edu/ml/datasets/bank+marketing. Si avvia Jupyter Notebook e si importano tutte le librerie necessarie come indicato nella figura seguente.

```
import numpy as np
import pandas as pd
import seaborn as sns
import time
import re
import os
import matplotlib.pyplot as matplot
sns.set(style = "ticks")
```

Si procede con le porzioni di codice seguenti per *leggere il file CSV* ed *esaminare il dataset.*

In particolare, la figura seguente riporta il codice per la lettura del file csv, la stampa della struttura della tabella (4.521 osservazioni/righe e 17 variabili/colonne) e la stampa delle informazioni delle colonne della tabella.

PEGASO Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

```
df = pd.read_csv('bank.csv',sep=';')
print("Struttura tabella")
print(df.shape)
print()
print("Info tabella")
df.info()
```

```
Struttura tabella
(4521, 17)

Info tabella
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4521 entries, 0 to 4520
Data columns (total 17 columns):
 #   Column     Non-Null Count  Dtype 
---  ------     --------------  ----- 
 0   age        4521 non-null   int64 
 1   job        4521 non-null   object
 2   marital    4521 non-null   object
 3   education  4521 non-null   object
 4   default    4521 non-null   object
 5   balance    4521 non-null   int64 
 6   housing    4521 non-null   object
 7   loan       4521 non-null   object
 8   contact    4521 non-null   object
 9   day        4521 non-null   int64 
 10  month      4521 non-null   object
 11  duration   4521 non-null   int64 
 12  campaign   4521 non-null   int64 
 13  pdays      4521 non-null   int64 
 14  previous   4521 non-null   int64 
 15  poutcome   4521 non-null   object
 16  y          4521 non-null   object
dtypes: int64(7), object(10)
memory usage: 600.6+ KB
```

La figura successiva riporta la visualizzazione delle prime quindici righe del dataframe letto in precedenza.

```
df.head(15)
```

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	y
0	30	unemployed	married	primary	no	1787	no	no	cellular	19	oct	79	1	-1	0	unknown	no
1	33	services	married	secondary	no	4789	yes	yes	cellular	11	may	220	1	339	4	failure	no
2	35	management	single	tertiary	no	1350	yes	no	cellular	16	apr	185	1	330	1	failure	no
3	30	management	married	tertiary	no	1476	yes	yes	unknown	3	jun	199	4	-1	0	unknown	no
4	59	blue-collar	married	secondary	no	0	yes	no	unknown	5	may	226	1	-1	0	unknown	no
5	35	management	single	tertiary	no	747	no	no	cellular	23	feb	141	2	176	3	failure	no
6	36	self-employed	married	tertiary	no	307	yes	no	cellular	14	may	341	1	330	2	other	no
7	39	technician	married	secondary	no	147	yes	no	cellular	6	may	151	2	-1	0	unknown	no
8	41	entrepreneur	married	tertiary	no	221	yes	no	unknown	14	may	57	2	-1	0	unknown	no
9	43	services	married	primary	no	-88	yes	yes	cellular	17	apr	313	1	147	2	failure	no
10	39	services	married	secondary	no	9374	yes	no	unknown	20	may	273	1	-1	0	unknown	no
11	43	admin.	married	secondary	no	264	yes	no	cellular	17	apr	113	2	-1	0	unknown	no
12	36	technician	married	tertiary	no	1109	no	no	cellular	13	aug	328	2	-1	0	unknown	no
13	20	student	single	secondary	no	502	no	no	cellular	30	apr	261	1	-1	0	unknown	yes
14	31	blue-collar	married	secondary	no	360	yes	yes	cellular	29	jan	89	1	241	1	failure	no

Il codice seguente richiama il metodo describe() del dataframe che fornisce la tabella riportata più in basso in cui sono riportate le statistiche descrittive per le variabili/colonne numeriche.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

```
print("Statistiche tabella")
df.describe()
```

```
Statistiche tabella
```

	age	balance	day	duration	campaign	pdays	previous
count	4521.000000	4521.000000	4521.000000	4521.000000	4521.000000	4521.000000	4521.000000
mean	41.170095	1422.657819	15.915284	263.961292	2.793630	39.766645	0.542579
std	10.576211	3009.638142	8.247667	259.856633	3.109807	100.121124	1.693562
min	19.000000	-3313.000000	1.000000	4.000000	1.000000	-1.000000	0.000000
25%	33.000000	69.000000	9.000000	104.000000	1.000000	-1.000000	0.000000
50%	39.000000	444.000000	16.000000	185.000000	2.000000	-1.000000	0.000000
75%	49.000000	1480.000000	21.000000	329.000000	3.000000	-1.000000	0.000000
max	87.000000	71188.000000	31.000000	3025.000000	50.000000	871.000000	25.000000

Per *studiare la variabile target* (con possibili valori **sottoscritto** o **non sottoscritto -** corrispondente alla ***variabile/colonna 'y'*** del dataframe) è importante guardare la sua distribuzione. Il tipo di variabile target è **binario** (sì/no).

Quando la ***distribuzione è sbilanciata*** verso una classe, il problema è definito come *sbilanciamento di una variabile.* È possibile studiare la **proporzione della variabile target** usando un **grafico a barre** (in quanto la variabile non è numerica). Questo metodo fornisce un'idea di *quante osservazioni ci siano per ogni classe* (nel caso in oggetto quanti sì e quanti no).

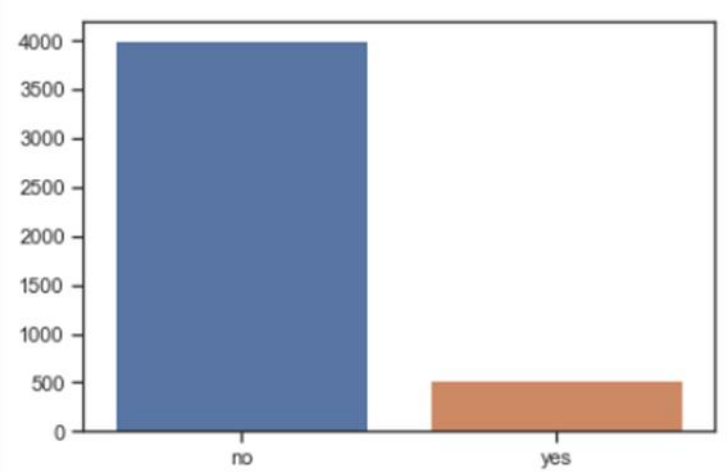
Come si vedrà nel grafico, la *proporzione dei no è molto più alta di quella dei sì* e ciò spiega lo **squilibrio dei dati.**

PEGASO Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

```
count_number_subc = df['y'].value_counts()
sns.barplot(count_number_subc.index, count_number_subc.values)
df['y'].value_counts()
```

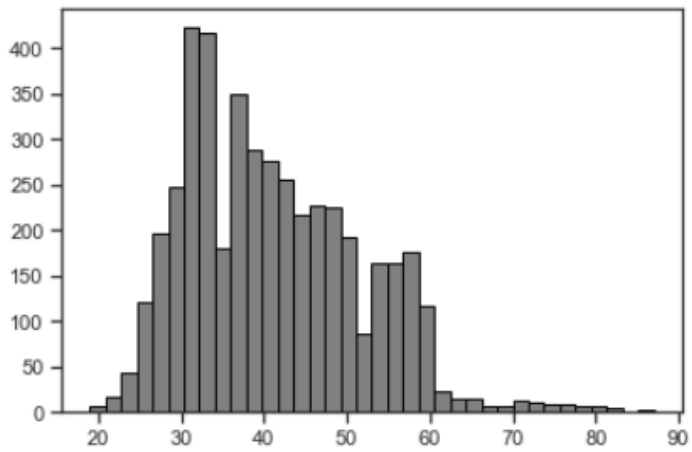
```
no     4000
yes     521
Name: y, dtype: int64
```



A seguito dei passaggi appena effettuati, si osservano le **tendenze di distribuzione per ciascuna variabile.** Si costruisce, quindi, l'**istogramma** per esaminare le *variabili numeriche/decimali* (es. '*age*' e '*balance*') e il **grafico a barre** per esaminare le *variabili categoriali* (es. '*education*' e '*month*').

Nella figura seguente si riporta l'istogramma della variabile '*age*' con un numero di colonne pari a 36.

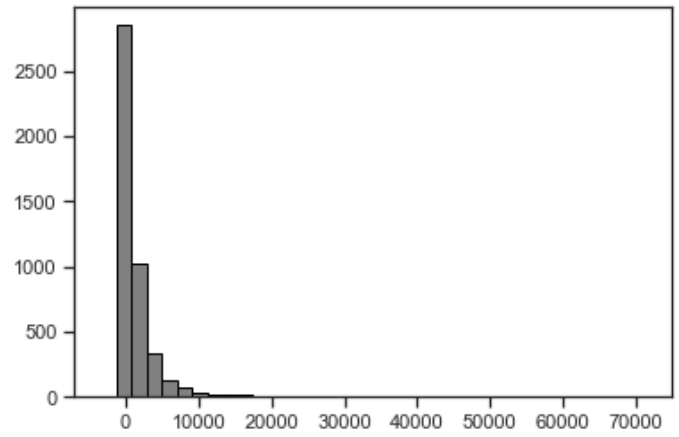
```
matplot.hist(df['age'], color = 'grey', edgecolor = 'black', bins = (int(180/5)))
```



Nella figura seguente si riporta l'istogramma della variabile '*balance*' con un numero di colonne pari a 36.

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

```
matplot.hist(df['balance'], color = 'grey', edgecolor = 'black', bins = (int(180/5)))
```

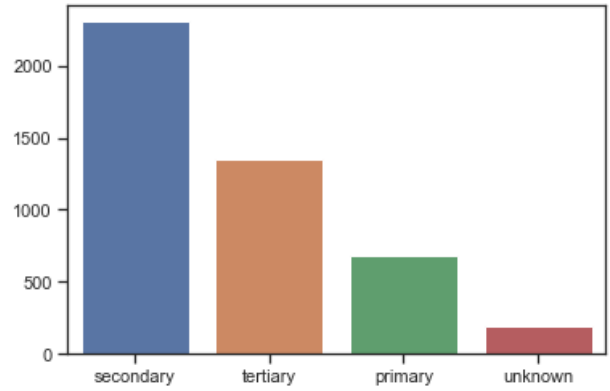


Nella figura seguente si riporta il grafico a barre della variabile categoriale '*education*'.

```
count_number_subc = df['education'].value_counts()
sns.barplot(count_number_subc.index, count_number_subc.values)

df['education'].value_counts()
```

```
secondary    2306
tertiary     1350
primary       678
unknown       187
Name: education, dtype: int64
```



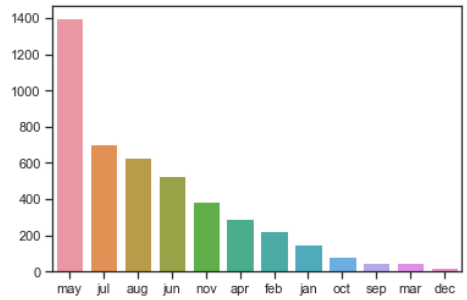
Nella figura seguente si riporta il grafico a barre della variabile categoriale '*month*'.

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

```
count_number_subc = df['month'].value_counts()
sns.barplot(count_number_subc.index, count_number_subc.values)

df['month'].value_counts()
```

```
may    1398
jul     706
aug     633
jun     531
nov     389
apr     293
feb     222
jan     148
oct      80
sep      52
mar      49
dec      20
Name: month, dtype: int64
```



Il passo successivo è generare una **distribuzione per ogni classe della variabile target** e confrontare le distribuzioni. Si disegnano, quindi, **due istogrammi** (per le variabili '*age*' e '*balance*') e **due grafici a barre** (per le variabili '*education*' e '*month*'), tutti per la ***variabile target*** (sì/no).

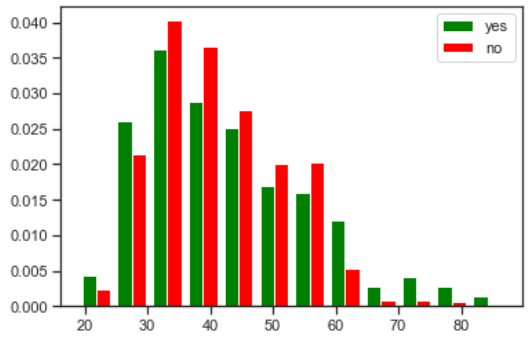
Nella figura seguente si riporta l'istogramma della variabile '*age*' in base alla variabile target con un numero di colonne pari a 12.

```
x1 = list(df[df['y'] == 'yes']['age'])
x2 = list(df[df['y'] == 'no']['age'])

#assegnazione colore per i due tipi di sottoscrizione
colors = ['green','red']
names = ['yes','no']

matplot.hist([x1, x2], bins = (int(180/15)), density = True, color = colors, label = names)
matplot.legend()
```

```
<matplotlib.legend.Legend at 0x2010d19d520>
```



Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

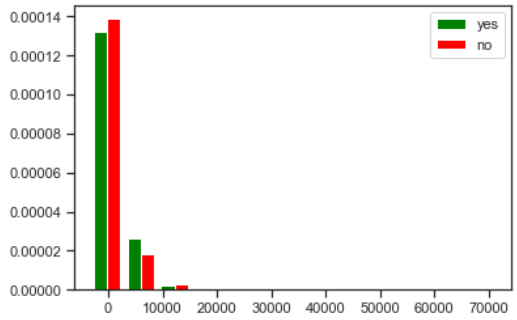
Nella figura seguente si riporta l'istogramma della variabile '*balance*' in base alla variabile target con un numero di colonne pari a 12.

```
x1 = list(df[df['y'] == 'yes']['balance'])
x2 = list(df[df['y'] == 'no']['balance'])

#assegnazione colore per i due tipi di sottoscrizione
colors = ['green','red']
names = ['yes','no']

matplot.hist([x1, x2], bins = (int(180/15)), density = True, color = colors, label = names)
matplot.legend()
```

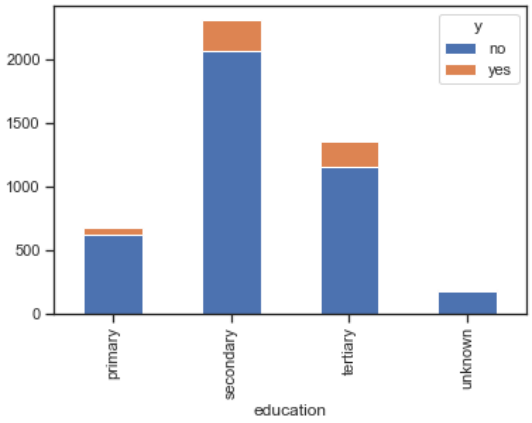
```
<matplotlib.legend.Legend at 0x2010d24efd0>
```



Nella figura seguente si riporta il grafico a barre della variabile categoriale '*education*' in base alla variabile target.

```
df.groupby(['education','y']).size().unstack().plot(kind = 'bar', stacked = True)
```

```
<AxesSubplot:xlabel='education'>
```

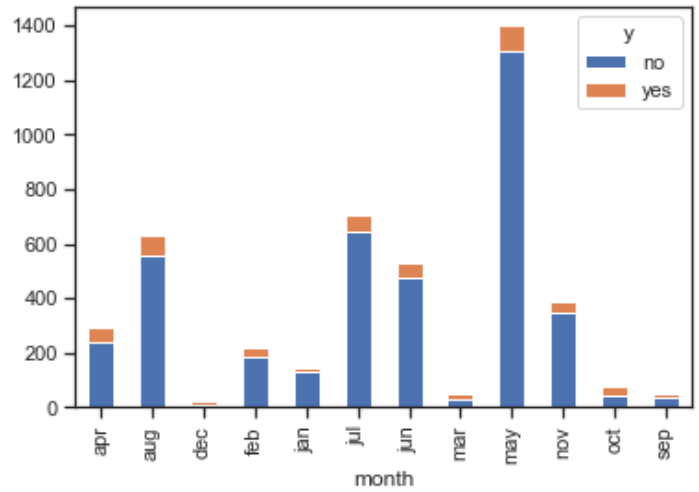


Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Nella figura seguente si riporta il grafico a barre della variabile categoriale '*month*' in base alla variabile target.

```
df.groupby(['month','y']).size().unstack().plot(kind = 'bar', stacked = True)
```

```
<AxesSubplot:xlabel='month'>
```



.

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

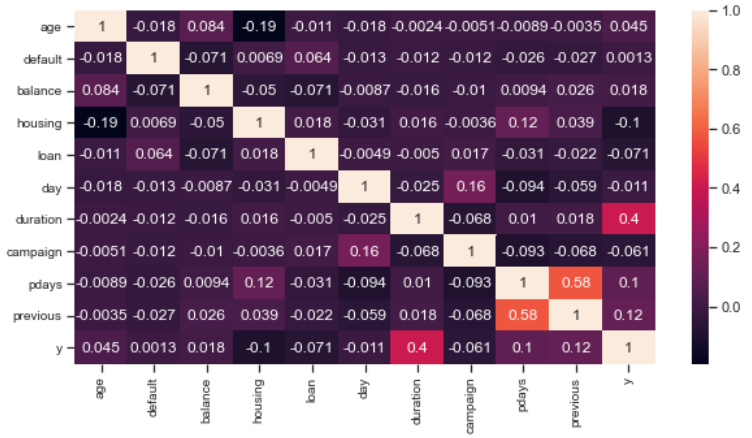
5. L'analisi di correlazione

Nei passi eseguiti precedentemente, sono state **esaminate le tendenze degli attributi** identificando le loro proprietà e il modo in cui è possibile usare vari grafici e metodi di visualizzazione. Prima di affrontare un problema di modellazione, previsione o classificazione (ad esempio prevedere dai dati della precedente campagna di marketing quali saranno i futuri clienti con la più alta probabilità di conversione), è necessario **pre-elaborare i dati e selezionare le caratteristiche importanti** che influenzeranno i modelli di output della *campagna di sottoscrizione.* Per poterlo fare è necessario trovare **l'associazione tra gli attributi e l'esito (variabile target)**, ovvero quanta ***variabilità*** della variabile target è spiegata da ogni variabile.

Le associazioni tra le variabili possono essere tracciate usando diversi metodi, ma ad ogni modo quando si sceglie un metodo o un algoritmo bisogna considerare il tipo di dati. Per esempio, se si stanno studiando variabili numeriche è possibile utilizzare l'***analisi di correlazione***. Se si stanno studiando, invece, variabili categoriali con classi multiple si può usare il metodo del chi-quadro.

Esistono comunque ***molti algoritmi che sono in grado di gestire entrambi i casi*** e fornire risultati misurabili per confrontare la rilevanza delle variabili. Con il codice seguente si sviluppa la **matrice di correlazione** per identificare la *correlazione tra le variabili, d*opo aver trasformato in valori numerici, 1 e 0, i valori binari 'yes' e 'no' delle variabili 'y', 'default', 'housing' e 'loan'.

```
df2 = df
df2['y'].replace(['yes','no'],[1,0],inplace=True)
df2['default'].replace(['yes','no'],[1,0],inplace=True)
df2['housing'].replace(['yes','no'],[1,0],inplace=True)
df2['loan'].replace(['yes','no'],[1,0],inplace=True)
corr_df = df2.corr()
sns.heatmap(corr_df,
            xticklabels = corr_df.columns.values,
            yticklabels = corr_df.columns.values,
            annot = True, annot_kws={'size':12})
heat_map = matplot.gcf()
heat_map.set_size_inches(10,5)
matplot.xticks(fontsize=10)
matplot.yticks(fontsize=10)
matplot.show()
```



Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Bibliografia

- Marin I., Shukla A. Sarang VK. (2019). L'analisi dei Big Data con Python. Tecniche nuove.

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).