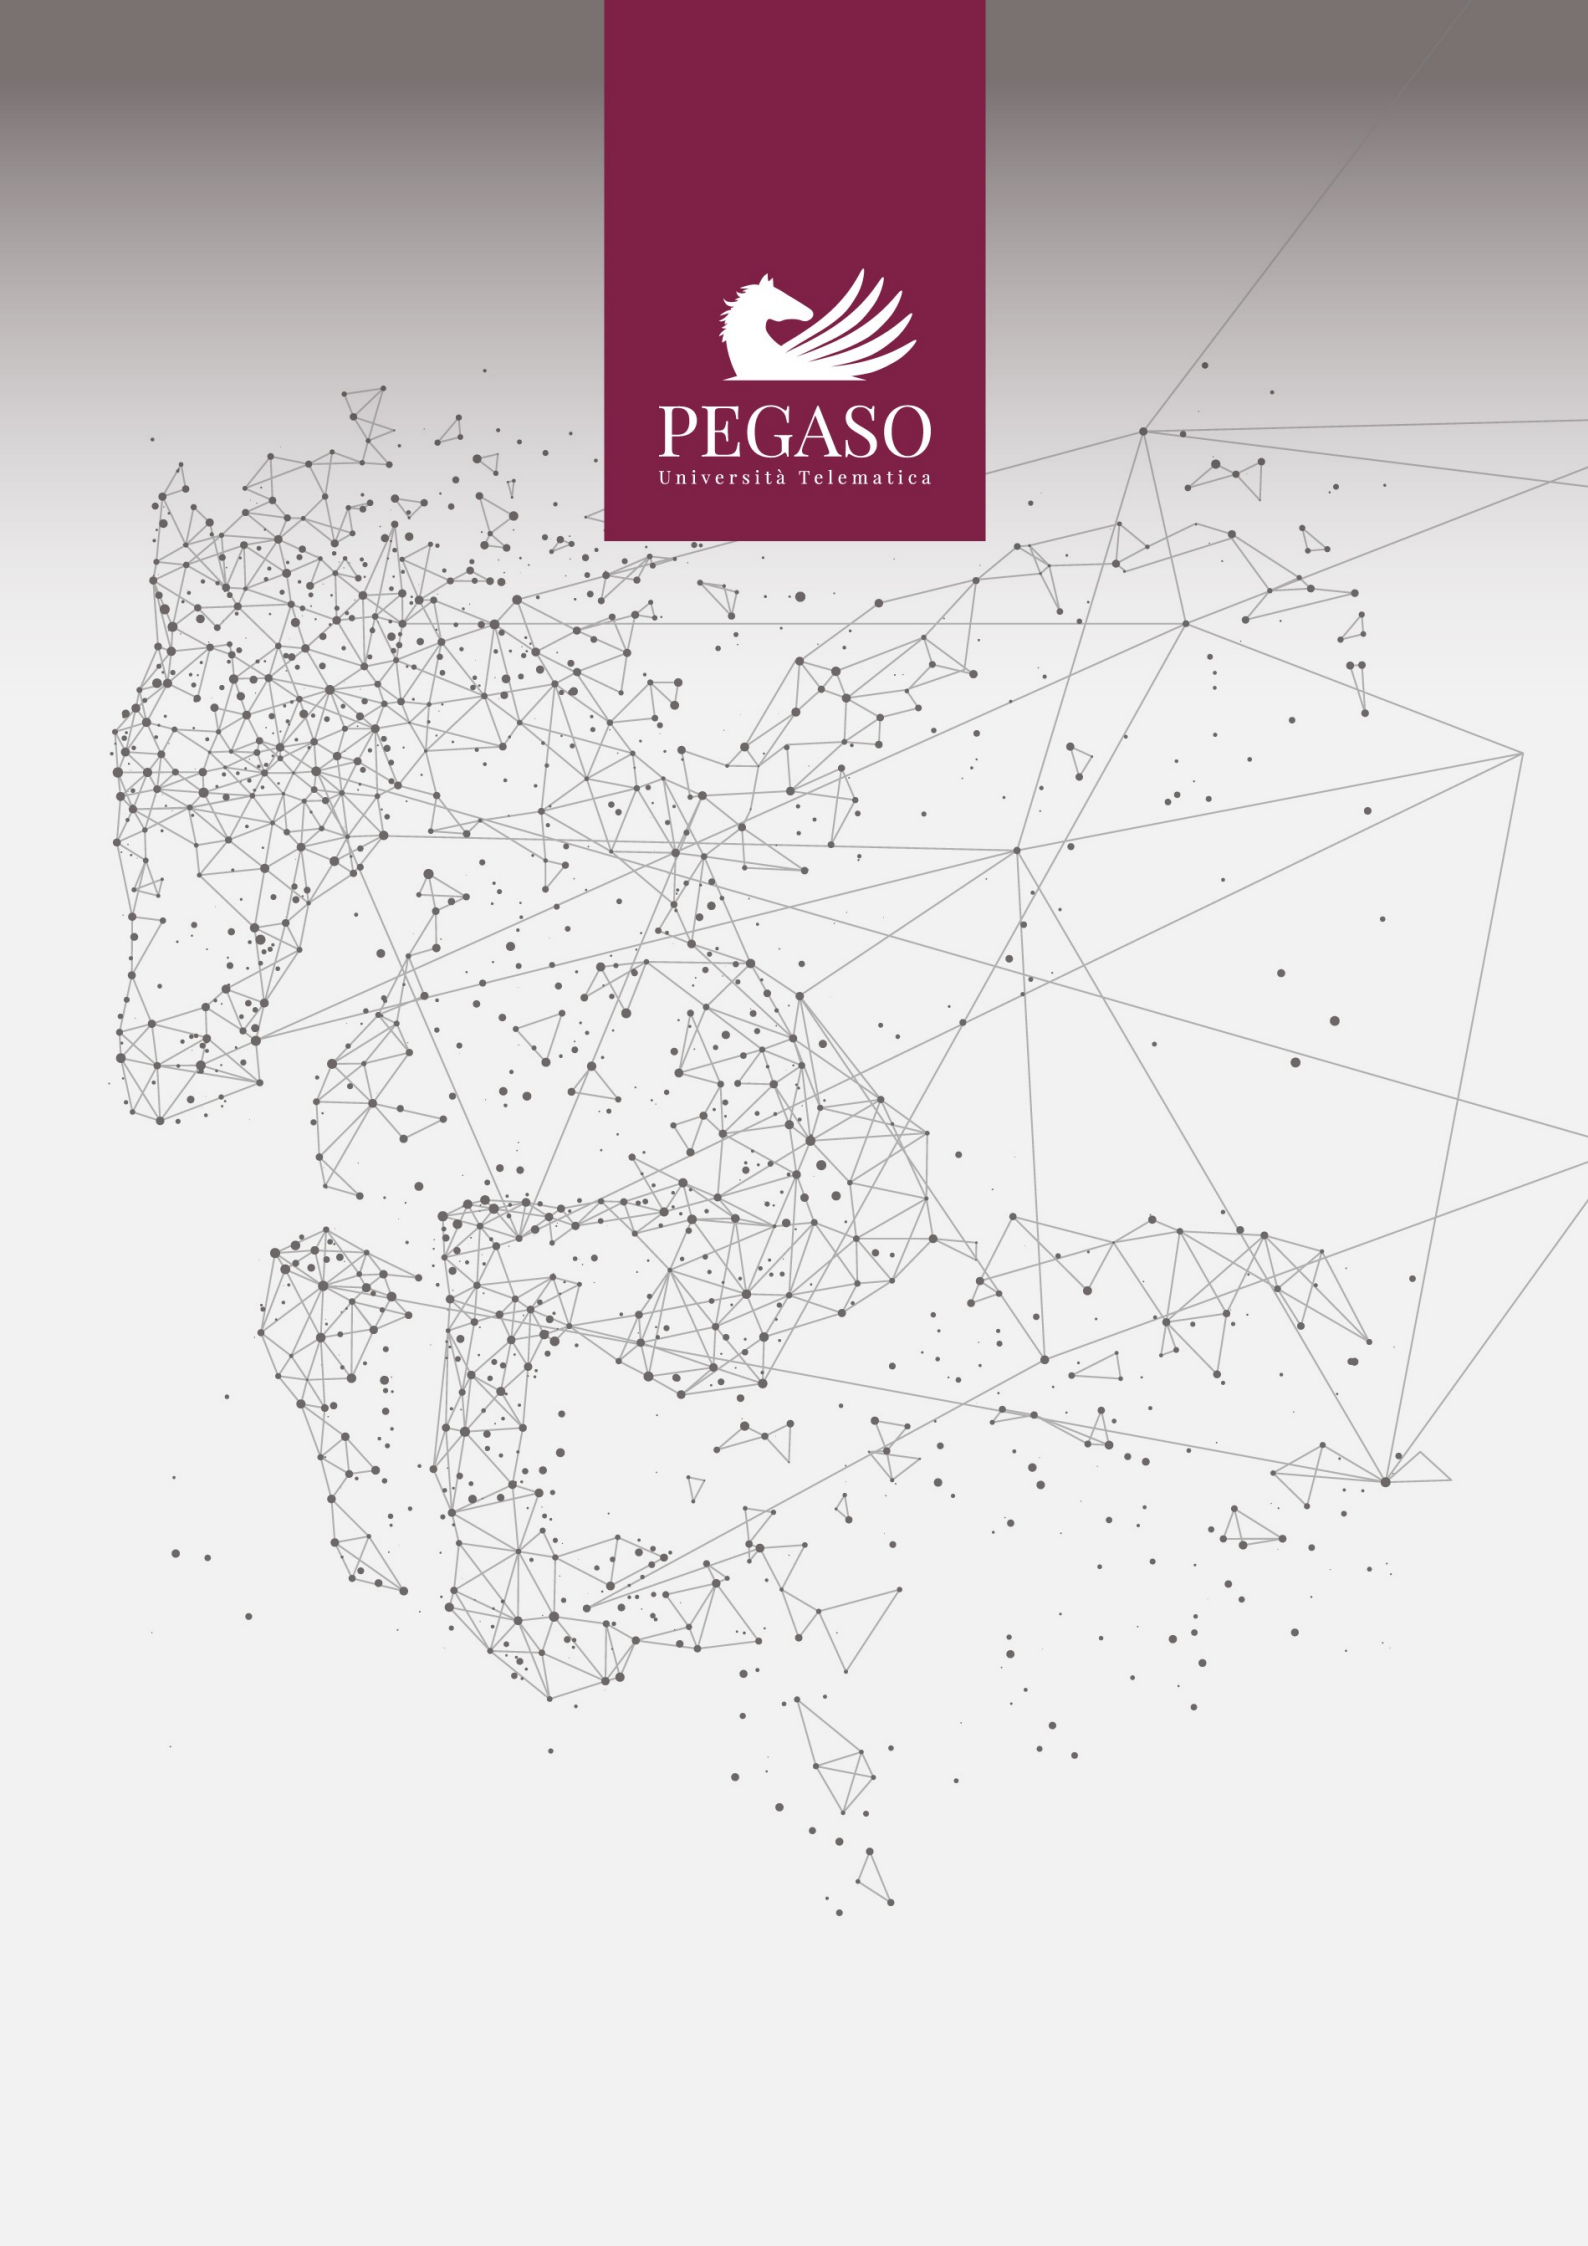

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Indice

1. INTRODUZIONE 3

2. BIG DATA: INFRASTRUTTURE ITALIANE E DOMINI APPLICATIVI 4

3. BEYOND BIG DATA: BIG DATA E AI 16

4. ESEMPI APPLICATIVI DI BIG DATA E AI 21

BIBLIOGRAFIA 23

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

1. Introduzione

In questa dispensa di accompagnamento alla video-lezione, si presentano le infrastrutture rilevanti per High Perfomance Computing in Italia e i domini principali in ambito Big Data che sono risultati essere significativi anche dal punto di vista dei finanziamenti europei per la ricerca. Si illustrano, inoltre, le frontiere dei Big Data con l'integrazione del data mining, del machine learning, del deep learning e, più in generale, dell'intelligenza artificiale. Infine, si presentano brevemente due casi di successo relativi all'uso dei Big Data e dell'intelligenza artificiale per la risoluzione di reali problemi aziendali.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

2. Big data: infrastrutture italiane e domini applicativi

Per l'elaborazione di Big Data, in **Italia**, sono presenti **infrastrutture molto importanti** relative ai cosiddetti **HPC** (*High Perfomance Computing*) e **HTC** (*High Technology Computer*). Per ***HPC*** si intendono le tecnologie utilizzate da computer cluster per creare dei sistemi di elaborazione in grado di fornire delle **prestazioni molto elevate nell'ordine dei PetaFLOPS**, ricorrendo tipicamente al *calcolo parallelo.* L'espressione è molto utilizzata essenzialmente per sistemi di elaborazioni utilizzati in campo scientifico.

La realtà più importante da questo punto di vista è il **CINECA,** un consorzio interuniversitario italiano senza scopo di lucro, cui aderiscono:

- 69 università italiane;
- 2 Ministeri (il Ministero dell'istruzione e il Ministero dell'università e della ricerca);
- 27 Istituzioni pubbliche Nazionali (10 Enti di ricerca, 5 Aziende Ospedaliere Universitarie-IRRCS, 10 Istituzioni AFAM, l'ANVUR, il Parco Archeologico del Colosseo).

La sede principale è a Casalecchio di Reno ed ha sedi a Milano, Roma, Napoli e Chieti. La sua attività principale è il ***supporto alle attività di ricerca della comunità scientifica accademica e fornisce servizi di calcolo alle università in Italia.***

Al momento della loro installazione, la maggior parte dei sistemi di supercomputer CINECA si collocava nella parte alta, dal 7° al 12° posto, della TOP-500, abilitando e supportando ***l'eccellenza nazionale ed europea nell'innovazione scientifica e tecnologica.*** Altre *strutture rilevanti in Italia per HPC* sono quelle appartenenti a:

- Istituto Nazionale di Fisica Nucleare (INFN);
- Consiglio nazionale delle Ricerca (CNR);
- Centro euro-Mediterraneo sui Cambiamenti Climatici (CMCC);
- Agenzia nazionale per le nuove tecnologie, l'energia e lo sviluppo economico sostenibile (ENEA);
- Gestione Ampliamento Rete Ricerca (GARR);
- Istituto Nazionale di Astrofisica (INAF);
- Scuola Internazionale Superiore di Studi Avanzati di Trieste (SISSA).

La tabella successiva mostra, per ogni struttura, i diversi siti (inclusa la città) e, per ciascun sito, il numero dei core, il numero dei nodi dei server e la capacità di memorizzazione in petabyte (10^{15} byte).

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

National HPC and Big Data infrastructure

Institution	Location	Site Name	# of cores	# of server nods	Storage (PB)	Tape (PB)
INFN	Bari	INFN-BARI T2	174	12	1.51	
	Bari	RECAS	4.000	250	3.55	
	Bari	GARR	1.152	58	3.00	
	Bologna	CNAF-T1	30.000	1875	40.00	90.00
	Bologna	CNAF-LHCB-T2	384	12		
	Catania	INFN-CATANIA	390	20	1.20	
	Catania	RECAS	2.592	128	0.32	
	Cosenza	RECAS	3.500	175	0.90	
	Frascati	INFN-FRASCATI	160	8	.33	
	Milano	INFN-MILANO-ATLAS	180	12	1.31	
	Napoli	INFN-NAPOLI-ATLAS	334	21	1.82	
	Napoli	RECAS	4.956	310	4.96	
	Padova	LNL	452	28	1.76	
	Pisa	INFN-PISA	1.250	78	2.49	
	Roma	INFN-ROMA1	160	10	1.34	
	Roma	INFN-ROMA1-CMS	192	6		
	Torino	INFN-TORINO	78	6	0.06	
Cineca	Bologna	MARCONI	406.000	7000	20.00	20.00
	Bologna	GALILEO	72.576	1512		
	Bologna	PICO	2.400	50		
CMCC	Lecce	CMCC	13.824	288	4.00	
CNR	Roma	Data Center	1.034	64	1.20	
ENEA	Casaccia	ENEA-Casaccia	192	12	0.02	
	Frascati	ENEA-FRASCATI	480	24	0.06	
	Portici	CRESCO4	4.864	04		
	Portici	CRESCO5	512	32	4.00	5.00
	Portici	CRESCO6	20.832	434		
GARR	Catania	GARR	1.152	58	3.00	
	Cosenza	RECAS	384	32	1.00	
	Napoli	GARR	384	24	1.00	
	Palermo	GARR	1.152	72	3.00	
INAF	Trieste	OATS	256	16	1.00	
SISSA	Trieste	SISSA	4.000	250	1.50	

Dal punto di vista scientifico e applicativo dei Big Data, è possibile individuare alcuni **domini principali.** L'associazione Big Data, anche in base ai progetti europei finanziati ***nell'ambito Big Data***, individua i seguenti domini:

1. Digital Enabling Technologies;
2. Health and Life Sciences;
3. Agri-food, biobased industry and Blue growth;
4. Smart Cities and security;
5. Scienza dei materiali;
6. Industry 4.0;
7. Scienze della terra e cambiamenti climatici;
8. Scienze sociali ed economia globali;
9. Humanities e patrimonio culturale;
10. Fisica, astrofisica e scienze spaziali.

Si procede, ora, con una breve analisi per ciascun dominio applicativo.

1. <u>Digital Enabling Technologies</u>

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Le *tendenze nell'innovazione digitale* stanno progressivamente fornendo la capacità di ***estendere globalmente la connettività*** a qualsiasi persona e qualsiasi dispositivo. Ciò permette di accedere senza problemi a qualsiasi informazione e qualsiasi dato da qualsiasi luogo e in qualsiasi momento, con elaborazione e analisi on-demand dei dati per ***modellare scenari e supportare le decisioni*** (ATAWAD: anytime, anyway, any device).

I componenti all'avanguardia di un così pervasivo ecosistema di tecnologie digitali abilitanti sono le ***reti ad alta velocità*** per *l'interconnessione* di strutture su larga scala e ***repository di grandi volumi per preservare e curare i Big Data,*** oltre ai sistemi di elaborazione di fascia alta (HPC e HPTC). Queste tecnologie si occupano della *simulazione e della modellazione di problemi scientifici e ingegneristici, nonché dell'analisi dei dati.*

In molte aree di studio e ricerca, che vanno dalla salute, alla biologia e al cambiamento climatico, all'automotive, all'aerospazio, all'energia e all'economia, la **tecnologia digitale** fornisce un *modo pratico per affrontare la complessità* e l'accesso ad essa diventa essenziale. Per sfruttare al meglio i vantaggi della tecnologia digitale, è necessario ***supportare un ecosistema completo*** che comprende *infrastrutture hardware e software, applicazioni, competenze, servizi e le loro interconnessioni.*

Per liberare il potenziale derivante dallo sfruttamento del valore dei Big Data, è essenziale ricercare nuove tecnologie, tra cui:

- *HPC;*
- *elaborazione dati;*
- *scienza dei dati;*
- *intelligenza artificiale.*

Multimedia, archiviazione dati, trasferimento dati e networking, strumenti di comunicazione e visualizzazione sono ***tecnologie abilitanti complementari per lo sviluppo del mercato dei Big Data.*** Fondamentali sono anche *l'equità nell'accesso ai dati* pubblici e, al tempo stesso, *forti tutele per la privacy e la sicurezza informatica.*

Alcuni progetti europei finanziati in ambito Digital Enabling Tecnologies: AI4EU, AIDA, AIDA-2020, ANTAREX, BD2DECIDE, DeepHealth, EnABLES, ENABLE-S3, EOSC-hub, EPEEC, EUDAT2020, EUROfusion, ExaNeSt, EXDCI, XDC, HERCULES, HPC-EUROPA3, ICEI, OPRECOMP, PRACE-4IP, SeaDataCloud, SECREDAS, Re-Search Alps, SEADATANET-II.

2. Health and life sciences

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

In ambito Big Data, negli ultimi anni, ospedali, università e centri di ricerca hanno avviato analisi fruttuose e produttive di dati a livello europeo, nazionale e regionale. Ad esempio, gli **studi omici** [1]e le scansioni di immagini multidimensionali, che producono **grandi volumi di dati e conoscenze**, sono *utili in aree dalle neuroscienze all'ortopedia, dalle malattie cardiovascolari all'invecchiamento.*

I Big Data consentono di *risolvere indizi in condizioni comuni*, ma anche di **scoprire nuovi sviluppi,** ad esempio, per la cura delle malattie rare, orientando l'assistenza sanitaria verso una ***medicina personalizzata e di "precisione",*** *il tutto riducendo i costi per i servizi sanitari nazionali e/o o delle autorità sanitarie regionali.*

I Big Data consentono, inoltre, di condurre studi prospettici di popolazione che forniranno uno spaccato nel ***trattamento di malattie epidemiologicamente significative*** come il cancro, le condizioni neurologiche e cardiovascolari, l'osteoporosi, le malattie muscolo-scheletriche, nonché patologie geriatriche e legate all'invecchiamento.

Nonostante questo forte impulso, lo sfruttamento delle informazioni dei Big Data per generare nuove conoscenze sulla salute è molto ritardato/***ostacolato dall'eterogeneità intrinseca dei Big Data e dalla mancanza di standard ampiamente accettati***, nonché dalle questioni legali relative all'*uso dei dati personali.*

Alcuni progetti europei finanziati in ambito Health and life sciences: ADOPT-BBMRIERIC, AirPROM, ChiLTERN, COMPARE, CORBEL, DeepHealth, ECDP, EDEN ISS, EJPRD, EUSTAND4PM, HPB SGA1, INforFUTURE, LANGELIN, MCDS-Therapy, MYNEWGUT, Neuromics, ORTHOUNION, PAPA-ARTIS, PLATYPUS.

3. AGRI-FOOD, BIOBASED INDUSTRY AND BLUE GROWTH

La rilevanza dei Big Data nel settore AGRI-FOOD, BIOBASED INDUSTRY e BLUE GROWTH è fondamentale per molte applicazioni industriali come:

- produzione e sicurezza alimentare;
- produzione primaria;
- allevamento di animali;
- coltivazione piante;
- biotecnologia industriale;
- scoperta di enzimi e microbi.

Migliorare la salute dei consumatori monitorando i dati relativi al cibo è una delle aree che possono beneficiare maggiormente di un uso radicalmente innovativo dei Big Data per fornire

[1] Per **studi omici** si intende lo studio dell'insieme di geni (genomica), dei trascritti (trascrittomica), delle proteine (proteomica) e dei metaboliti (metabolomica) che vengono espressi da una cellula.

PEGASO Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

raccomandazioni più personali, attraverso varie piattaforme tecnologiche, che possono migliorare la qualità della vita.

Oltre all'uso tipico dell'analisi dei dati per la sicurezza alimentare, ***i Big Data sono legati anche all'analisi predittiva***, con impatto sull'economia e sulla logistica, nonché alla metagenomica (studio di comunità microbiche direttamente nel loro ambiente naturale) per la caratterizzazione del *deterioramento degli alimenti. L'Autorità Europea per la Sicurezza Alimentare* (**EFSA**) è interessata ai ***futuri approcci strategici alla valutazione del rischio nei settori della sicurezza di alimenti e mangimi*** che traggono vantaggio dall'acquisizione, dall'elaborazione e dalla condivisione di grandi quantità di dati e prove.

I Big Data hanno anche un'importanza crescente nelle pratiche agricole, poiché l'integrazione di dati provenienti da sensori, applicazioni Internet of Things (IoT) e genomica può portare gli agricoltori ad aumentare la loro ***produttività e sostenibilità***. Possono anche migliorare l'efficienza e la sostenibilità, nonché la flessibilità e la sicurezza nell'industria alimentare e biologica.

Infine, IoT, cloud computing e Big Data e analisi dei dati sono necessari per *la condivisione, l'elaborazione avanzata e l'analisi dei dati chiave di interesse* per:

- la ***sicurezza marittima*** (compresi i fenomeni migratori);
- la ***sicurezza della navigazione*** marittima e dei trasporti;
- la ***pesca*** e l'***acquacoltura*** *sostenibili;*
- l'***ambiente biotico*** (animali e piante);
- lo ***sfruttamento abiotico*** (ambiente tranne animali e piante) delle risorse marine.

Alcuni progetti europei finanziati in ambito AGRI-FOOD, BIOBASED INDUSTRY e BLUE GROWTH: CIRCLES, CYBELE, INMARE, LEGVALUE, MedAID, PANINI, PerformFISH, Prolific, RES URBIS, SMARTCHAIN, TREASURE, VALUMICS.

4. <u>Smart cities and security</u>

I Big Data sono un'area di crescente interesse anche per i ***responsabili delle politiche pubbliche***, per le ***città*** e la ***gestione urbana***. Sono legati, infatti, all'enorme flusso di dati provenienti da:

- dati amministrativi e sociali;
- infrastrutture energetiche, di mobilità e di trasporto delle città;
- grandi e crescenti reti di sensori (comprendendo grandi nodi collegati sotto il paradigma Internet-of-Things);
- videosorveglianza e telecamere ambientali.

L'analisi dei dati ai fini di ***innovazione sociale e servizi human-centric*** (es. sicurezza personale e fisica, crowd-sensing/rilevamento partecipativo in ambiente urbano), ***mobilità intelligente*** e ***servizi di***

PEGASO Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

logistica intelligente, oltre che di protezione delle infrastrutture critiche e gestione delle ***emergenze,*** sta diventando cruciale e impegnativa a causa dell'***ampiezza dei dati*** e dell'***esigenza di tempestività.*** Collegata alla smart city e ai Big Data sociali, poi, la sicurezza informatica (inclusa la privacy, la gestione del controllo degli accessi, la biometria, ecc.) è una delle aree più critiche nell'analisi e nella gestione dei Big Data.

C'è una crescente domanda di informazioni sulla sicurezza, sulle tecnologie e sui servizi di gestione degli eventi, che raccolgono e analizzano i Big Data degli eventi di sicurezza utilizzati per ***gestire le minacce.*** Nei **trasporti**, il volume dei dati è aumentato a causa della crescita della quantità di traffico (tutte le modalità) e dei rilevatori. Inoltre, **viaggiatori, merci e veicoli** stanno generando più dati dai dispositivi mobili e monitorando i transponder (compresi treni, navi e aerei).

Nuovi modi per raccogliere, gestire e analizzare grandi quantità di dati sono importanti sia per i governi che per le aziende private che offrono servizi di trasporto. L'*ottimizzazione del trasporto multimodale e nella gestione dei flussi di traffico* permette, infatti, di ottenere *città più intelligenti.*

L'enorme quantità di dati provenienti, ad esempio, da sistemi GPS, monitoraggio del traffico in tempo reale, disponibilità di parcheggi e disponibilità di stazioni di ricarica elettriche, può fornire **vantaggi competitivi** al fine di ottimizzare la progettazione, la manutenzione e la gestione dell'energia del veicolo, migliorare automazione e sicurezza a bordo e ridurre le emissioni di CO_2.

Alcuni progetti europei finanziati in ambito Smart cities and security: Domino, FLEXMETER, FOCAS, ICARUS, MARISA, OSMOSE, PRYSTINE, SocialCar, SOGNO, TRAFAIR.

5. <u>Scienze dei materiali</u>

I dati e i metadati per lo ***sviluppo di nuovi materiali***, la loro elaborazione e i cicli di vita delle applicazioni sono considerati risorse chiave per accelerare la scoperta e l'innovazione in tutti i settori di progettazione e produzione. Una caratteristica speciale del dominio dei materiali è la *ricchezza di informazioni predittive che possono essere ottenute dalle simulazioni*, ora estese ad approcci quantistici e multiscala grazie a HPC e HTC.

Nella progettazione di materiali e sistemi (bio)molecolari questo non è più limitato alle loro strutture e stabilità. Include, infatti, una vasta gamma di funzionalità, come ad esempio:

- attrito e usura alla biocompatibilità;
- colore e aspetto ottico all'idrofobicità;
- trasporto di elettroni;
- proprietà termiche all'interno dei dispositivi.

L'***acquisizione di dati dalla spettroscopia avanzata e dall'imaging dei materiali***, poi, è sempre più importante e richiede la condivisione e l'analisi dei set di dati eterogenei e altamente distribuiti che ne derivano. Un esempio viene dalla ***comunità della microscopia elettronica***: producono dati

PEGASO Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

multidimensionali che devono essere archiviati, trasferiti, condivisi, gestiti ed elaborati, sia online (cioè durante l'acquisizione) che offline.

Alcuni progetti europei finanziati in ambito scienze dei materiali: EMCC-CSA, EoCoE, EXTMOS, GEMMA, GRAPHENE FLAGSHIP, GRIDABLE, INTERSECT, IQubits, MaX, NEXTOWER, SimDOME, NANODOME.

6. <u>Industry 4.0</u>

I ***settori industriali manifatturieri*** sono l'area più rilevante e impattante nella ricerca nazionale italiana, nell'innovazione e nelle attività aziendali, in termini di dipendenti, produzione e business.

Nella figura seguente, si riportano i 9 pilastri alla base dell'Industry 4.0.



La relativa attività di ricerca applicata è svolta:

- in un ***insieme di organizzazioni coordinate di ricerca e innovazione*** (laboratori universitari, nonché interdipartimentali, tecnopoli, gli 8 centri di competenza istituiti nell'ambito del programma Industria 4.0, ecc.);
- ***industrie*** che lavorano nel settore manifatturiero, meccanica, lavorazione industriale e in molti settori correlati come meccatronica, automotive, robotica e automazione, packaging, ceramica, apparecchiature elettroniche, tessile e abbigliamento, macchinari e produzione di metalli, ecc.

I ***cambiamenti nei processi produttivi e nella loro gestione*** richiedono sempre più lo sfruttamento di conoscenza estratta dai dati, acquisita (offline e online) in prototipazione virtuale, test, produzione, utilizzo e manutenzione. Industria 4.0 sfrutta i nuovi paradigmi dell'IoT e dei cyber-physical system, sfruttando l'enorme quantità di dati provenienti da simulazioni e macchine per ottenere prestazioni superiori e una produzione efficiente dal punto di vista energetico.

L'industria manifatturiera è attualmente nel mezzo di una ***rivoluzione basata sui dati***. Gli *impianti di produzione* devono essere in grado di soddisfare i requisiti dell'aumento esponenziale della produzione di

PEGASO Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

dati, nonché possedere le tecniche analitiche necessarie per estrarre preziose conoscenze dai Big Data. *Tecniche, servizi, applicazioni, piattaforme ed esigenze infrastrutturali* sono spesso condivise con altri campi di ricerca e produzione, in termini di cloud/edge computing e HPC, analisi e visualizzazione di Big Data, apprendimento automatico ed elaborazione di flussi online.

Alcuni progetti europei finanziati in ambito Industry 4.0: AEOLIX, CARIM, CLASS, CloudiFacturing, ColRobot, DREAM, ETEKINA, EXCELLERAT, FIRST, Fortissimo, FORTISSIMO2, I-MECH, IMPROVE, INCLUSIVE, IO-Twins, LINCOLN, Plan4Res, ROSSINI, SARAS, SYMBIOPTIMA, SYMPLEXITY.

7. <u>Scienze della terra e cambiamenti climatici</u>

I Big Data nel ***cambiamento climatico*** sono legati ai servizi per:

- sviluppare, trasferire e far funzionare ***modelli del «Sistema Terra» ad alta risoluzione spaziale;***
- sviluppare metriche e strumenti diagnostici per la valutazione dei modelli e per le specifiche esigenze degli utenti finali;
- acquisire, memorizzare ed elaborare dati nell'ordine dei petabyte da simulazioni e osservazioni di modelli.

Il termine 'Dati della Terra' (Earth Data), infatti, si riferisce a:

- **simulazioni** dell'atmosfera, degli oceani e dello stato del mare (disaccoppiate o accoppiate nei modelli del sistema terrestre);
- **sistemi di osservazione** ambientale, geofisica e oceanografica;
- **mappature** dei fondali e ai servizi di previsione per gli enti istituzionali (Protezione Civile, Guardia Costiera e Ministero dell'ambiente);
- **grandi banche dati** sugli usi dell'energia nell'industria, fattori di emissione, dati di base per la valutazione del ciclo di vita (LCA – Life Cycle Assessment), calcolo dell'impronta di carbonio;
- **banche dati** relative agli usi del mare nell'ambito di una strategia di crescita blu (del mare).

I modelli atmosferici hanno ***aumentato la loro risoluzione spaziale e temporale*** e hanno prodotto un'enorme quantità di dati di output sia in modalità diagnostica che previsionale. Archivi di parametri della superficie atmosferica ad alta risoluzione (***circa 1 km***) (vento, temperatura, radiazione solare, ecc.) previsti, ***su base giornaliera***, fino a 48 ore prima, sono disponibili per molte applicazioni ambientali e di energia rinnovabile.

I ***servizi di calcolo per le previsioni meteorologiche numeriche*** sono forniti giornalmente e le previsioni di insieme operativo sulla scala temporale mensile vengono eseguite su base settimanale. I modelli di trasporto chimico producono sia previsioni di inquinamento atmosferico a 5 giorni per l'Italia e l'Europa sia simulazioni diagnostiche annuali per il Paese. I dati orari per le concentrazioni di inquinanti

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

atmosferici e i campi meteorologici sono, poi, calcolati sul dominio nazionale con risoluzione spaziale orizzontale che va **da 4 a 1 km per 12 livelli verticali dal livello del suolo a un'altitudine di 12 km.**

Il risultato dell'elaborazione è il ***cambiamento ambientale particolarmente rapido nelle zone costiere e offshore sotto la pressione del cambiamento climatico*** (es. innalzamento relativo del livello del mare) con ripercussioni su bacini idrografici, pianure costiere (es. subsidenza antropica) e offshore (es. sfruttamento di idrocarburi, pesca a strascico, centrali energetiche, traffico marittimo). I sistemi di osservazione oceanica combinati con l'HPC forniscono, inoltre, scenari di mareggiate e inondazioni costiere associate, stato del mare, erosione costiera e tendenze ecologiche a lungo termine.

Alcuni progetti europei finanziati in ambito scienze della terra e cambiamenti climatici: AtlantOS, BE-OI, ChEESE, CLARA, CRESCENDO, ENVRI PLUS, HIGHLANDER, IMMERSE, Iscape, LISTEN MEDGOLD, MEDSCOPE. MISTRAL, MOSES, ODYSSEA, OPERANDUM, PRIMAVERA, ROCK, RURITAGE, SeaDataCloud, SECLI-FIRM, SOCLIMPACT, SYSTEM-RISK.

8. **Scienze sociali ed economia globali**

I dati come video, foto e micromessaggi condivisi su social network, GIS (Geographic Information System), reti di relazioni, nonché dati comportamentali e psicologici promuovono ***attività interdisciplinari*** rispetto agli aspetti economici, legali ed etici e ai principi di privacy.

I ***dati comportamentali*** *si riferiscono a set di dati multidimensionali sul comportamento umano e sociale*. Azioni e interazioni che consentono di comprendere preferenze, atteggiamenti e abitudini individuali e comunitari.

I ***set di dati psicologici***, invece, *raccolgono i risultati di test psicologici, sondaggi, esami di atteggiamento e fonti simili.*

L'analisi dei dati comportamentali contribuisce a ***progettare servizi mirati e personalizzati in diversi ambiti*** (es. trasporti, sanità, ambiente). L'analisi dei dati sui social network e GIS è focalizzata sulla comprensione degli aspetti interni delle relazioni umane e può essere applicata a molti campi (es. *pubblicità commerciale, studio della propensione all'acquisto, analisi del sentiment*). L'analisi dei dati psicologici, d'altra parte, aiuta i ricercatori a provare o confutare teorie e/o supportare le conclusioni con prove statistiche.

La raccolta e l'analisi di grandi quantità di dati comportamentali ha anche importanti conseguenze per la ***formulazione e l'applicazione delle norme giuridiche.***

Inoltre, l'uso crescente di set di dati amministrativi su larga scala, dati del settore privato e dati dei social media, può contribuire a una ricerca sulle scienze sociali di grande impatto che ***trascende i***

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

tradizionali confini disciplinari, compresi i campi dell'economia, delle scienze attuariali[2] e finanziarie, della matematica, della statistica, della programmazione e informatica. L'emergere di un ***approccio multidisciplinare ai Big Data*** può fornire una solida base di prove per l'elaborazione delle politiche, nonché una base di conoscenza quantitativa per risolvere problemi in ambito finanziario, assicurativo e di gestione del rischio.

Anche gli ***aspetti legali possono svolgere un ruolo importante nel successo dei Big Data*** in finanza ed economia, in particolare per quanto riguarda:

- il diritto della concorrenza;
- i diritti di proprietà intellettuale;
- il diritto sulla privacy;
- il diritto dei consumatori.

L'elaborazione rapida e in tempo reale di Big Data ha, infine, un ***forte impatto potenziale su aree chiave quali***:

- analisi dei dati dei clienti;
- strategie di marketing innovative;
- tendenze e aspettative del mercato;
- accesso al credito e ai finanziamenti per famiglie e imprese;
- e-commerce e sistemi di e-paying per un più facile accesso di consumatori e cittadini ai servizi;
- gestione del rischio;
- approfondimenti aziendali, intelligenza organizzativa ed efficienza operativa.

Alcuni progetti europei finanziati in ambito scienze sociali ed economia globali: CoSIE, MICADO, MIREL.

9. <u>Humanities e patrimonio culturale</u>

I Big Data nelle *scienze umane e nel campo del patrimonio culturale* hanno un enorme potenziale per la ***trasmissione*** *del patrimonio culturale, della storia, della cultura e dell'identità e per il miglioramento della creatività e lo stimolo allo sviluppo economico.* Questi dati non riguardano, però, solo set di dati culturali di grandi dimensioni in rete, ma richiedono anche nuovi metodi di studio e interpretazione nelle scienze sociali e umanistiche (SSH – Social Sciences and Humanities), incluso il campo delle ***Digital Humanities*** (Informatica Umanistica - campo di studi, ricerca, insegnamento che nasce dall'***unione di discipline umanistiche e informatiche***) che comprende ricerca, analisi e divulgazione della conoscenza attraverso i media informatici.

[2] Che applicano metodi matematici e statistici per valutare il rischio nelle assicurazioni e nella finanza.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Alcuni progetti europei finanziati in ambito humanities e patrimonio culturale: I-Media-Cities, INSCRIBE, IPERION CH.

10. <u>Fisica, astrofisica e scienze spaziali</u>

Molte sono le aree di ricerca in *fisica, astrofisica e scienze spaziali* che traggono beneficio dai Big Data. Alcune delle ***aree chiave*** sono:

- lo studio della struttura su larga scala dell'universo, la cosmologia e la natura dei buchi neri e dell'universo caldo ed energetico, nonché la formulazione teorica della formazione delle galassie e della loro evoluzione;
- l'osservazione e studio dell'Universo con i più grandi telescopi del mondo di nuova generazione nelle bande spettrali dell'infrarosso ottico, radio ed elettromagnetico ad alta energia;
- la simulazione di dati di lenti gravitazionali e simulazione di segnali da (e in connessione con la ricerca di) onde gravitazionali;
- gli studi delle proprietà del bosone di Higgs con gli esperimenti LHC al CERN di Ginevra.

Gli strumenti e le missioni come acceleratori della fisica delle particelle (in particolare esperimenti LHC), telescopi di nuova generazione (come ad es. il CTA, l'osservatorio ad alta energia più grande e sensibile del mondo, o SKA, il più grande radiotelescopio del mondo, o ELT, il più grande telescopio a infrarossi ottici del mondo) e le missioni di astrofisica e scienze spaziali *sono già entrati nel cosiddetto* ***regime dei Big Data.*** Alcuni esempi:

- entro il 2030, la CTA dovrebbe produrre più di 100 PB di dati, mentre i dati grezzi totali di SKA 1 dovrebbero superare di un fattore 5 il traffico Internet globale generato nell'anno 2015;
- Euclid (lancio nel 2022) raccoglierà diversi milioni di immagini e circa 30 Petabyte di dati che verranno combinati con altri giganteschi set di dati ottenuti con telescopi terrestri;
- ogni anno gli esperimenti di LHC raccolgono alcuni Petabyte (PB) di dati che vengono copiati nelle infrastrutture informatiche nazionali, in Italia al CNAF Tier 1;
- una quantità quasi uguale di dati simulati è necessaria per finalizzare questi studi.

Questi temi implicano naturalmente la necessità di Big Data, in termini di:

- *gestione dell'archivio dati, accessibilità e interoperabilità;*
- *high throughput e high performance computing (HTC e HPC);*
- *rete ad alta velocità;*
- *strumenti di elaborazione e modellazione delle immagini.*

PEGASO Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Alcuni progetti europei finanziati in ambito Fisica, astrofisica e scienze spaziali: AMICI, ARIES, ENSAR2, ESCAPE, EuroPLEx, FELLINI, INSPYRE, INTENSE, KM3Net 2.0, MAGCOW, RADIATE, SINE2020, TEQ, XLS.

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

3. Beyond Big Data: Big Data e AI

Come abbiamo potuto osservare finora, la ***Data Science*** è l'ampio studio scientifico che si concentra sul **dare un senso ai dati**. Ad esempio, i sistemi di raccomandazione utilizzati per *fornire suggerimenti personalizzati ai clienti in base alla loro cronologia di ricerca* sono basati proprio su studi di scienza dei dati. Se un cliente cerca una canna e un'esca e l'altro cerca una lenza oltre agli altri prodotti, c'è una buona possibilità che anche il primo cliente sia interessato all'acquisto di una lenza.

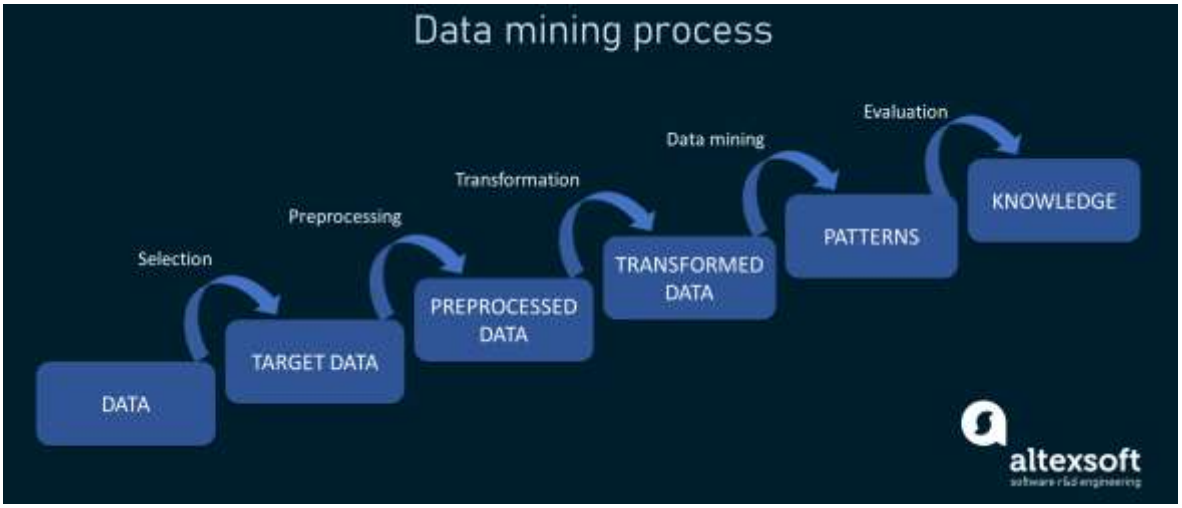
Il ***data mining*** è comunemente una *parte della pipeline di Data Science.* A differenza della Data Science, il data mining riguarda più le ***tecniche e gli strumenti utilizzati per svelare modelli tra i dati precedentemente sconosciuti e rendere i dati più utilizzabili per l'analisi.***

Riprendendo l'esempio con le forniture per la pesca, il data mining riguarda lo studio dei dati degli ultimi 2 anni per trovare correlazioni tra il numero di vendite di canne da pesca prima e durante le stagioni di pesca nei negozi situati in diversi stati.

Il *processo di data mining* è costituito da due parti:

1. **pre-elaborazione dei dati** - comprende passaggi come la pulizia dei dati, l'integrazione dei dati e la trasformazione dei dati;
2. **data mining effettivo** - riguarda la valutazione del modello e la rappresentazione della conoscenza dei dati in una forma di facile comprensione.

Il data mining è spesso visto come parte di un campo più ampio chiamato **Knowledge Discovery in Databases (KDD).** Ad esempio, permette la funzione "*Comprati spesso insieme*" di Amazon come esempio di tendenze scoperte. Nella figura seguente, si riporta uno schema che illustra le ***fasi del processo di data mining.***



Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Il ***machine learning*** (***ML*** o *apprendimento automatico*) mira, invece, a ***addestrare le macchine su dati storici*** in modo che possano elaborare nuovi input basati su modelli appresi senza una programmazione esplicita, ovvero senza istruzioni scritte manualmente affinché un sistema esegua un'azione.

Se non fosse per l'apprendimento automatico, i motori di raccomandazione sarebbero fuori portata in quanto è difficile per un essere umano elaborare milioni di query di ricerca, «Mi piace» e recensioni per scoprire quali clienti acquistano comunemente canne con esche e quali acquistano le canne con la lenza.
Il machine learning può essere di diversi tipi:

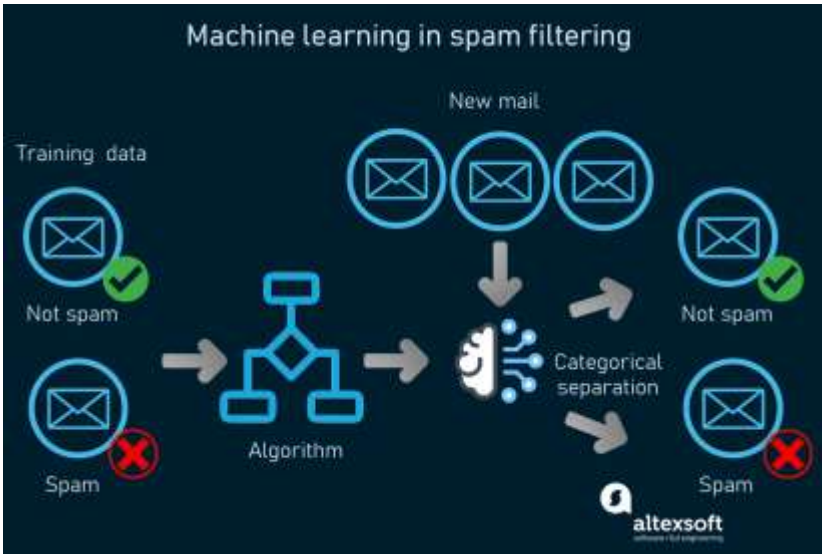
1. ***apprendimento supervisionato*** (*supervised learning*) - le macchine vengono addestrate a trovare soluzioni a un dato problema con *l'assistenza di esseri umani che raccolgono ed etichettano i dati e quindi li forniscono ai sistemi.* A una macchina viene detto quali caratteristiche dei dati guardare, in modo che possa determinare modelli, inserire oggetti nelle classi corrispondenti e valutare se la loro previsione è giusta o sbagliata;
2. ***apprendimento non supervisionato*** (*unsupervised learning*) - le macchine imparano a **riconoscere modelli e tendenze** nei dati di addestramento non etichettati senza essere supervisionate dagli utenti;
3. **apprendimento semi-supervisionato** (*semi-supervised learning*) - i modelli vengono addestrati con un **piccolo volume di dati etichettati e un volume molto più grande di dati non etichettati**, utilizzando sia l'apprendimento supervisionato che non supervisionato;
4. ***apprendimento per rinforzo*** (*reinforcement learning*) - i modelli, posti in un ambiente chiuso a loro non familiare, devono trovare una **soluzione a un problema attraverso tentativi ed errori seriali**. Simile a uno scenario trovato in molti giochi, le macchine ricevono una **punizione** per un *errore* e una **ricompensa** per una *prova riuscita*. In questo modo, imparano a trovare una ***soluzione ottimale.***

Per mostrare come funziona il machine learning, si prenderà come esempio, il classico *filtraggio della posta indesiderata nello **spam** dell'account di posta elettronica.* I sistemi di rilevamento dello spam aiutano a filtrare i messaggi irrilevanti da quelli importanti per gli utenti. I sistemi analizzano il contenuto delle e-mail e classificano i dati utilizzando algoritmi di machine learning.

Il compito di tali modelli basati su ML è determinare se un messaggio in arrivo è "spam" o "non spam" (in altre parole "ham"). Poiché il rilevamento dello spam è un argomento per l'apprendimento automatico supervisionato, il modello viene prima addestrato con set di dati etichettati: esempi di e-mail di spam e ham accuratamente definiti dalle persone. Nella figura seguente, si riporta lo schema relativo al ML nel filtraggio dello spam.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).



Il **deep learning (DL)** è il ramo più pubblicizzato del *machine learning* che utilizza algoritmi complessi di reti neurali profonde ispirati al modo in cui funziona il cervello umano. I modelli DL possono trarre ***risultati accurati da grandi volumi di dati di input senza che venga detto loro quali caratteristiche dei dati "osservare".***

Si immagini di dover determinare quali canne da pesca generano recensioni online positive su un sito Web e quali causano quelle negative. In questo caso, le reti neurali profonde possono estrarre caratteristiche significative dalle recensioni ed eseguire analisi del *sentiment*.

Il DL è un *sottoinsieme* del **machine learning**, ma avanzato grazie a reti neurali complesse, originariamente ispirate alle reti neurali biologiche nel cervello umano. Le reti neurali contengono nodi in diversi livelli interconnessi che comunicano tra loro per dare un senso a voluminosi dati di input.

Esistono vari tipi di reti neurali come reti neurali convoluzionali, reti neurali ricorsive e reti neurali ricorrenti. Una tipica rete neurale è costituita dal livello di input, da più livelli nascosti e dal livello di output impilati uno sopra l'altro.

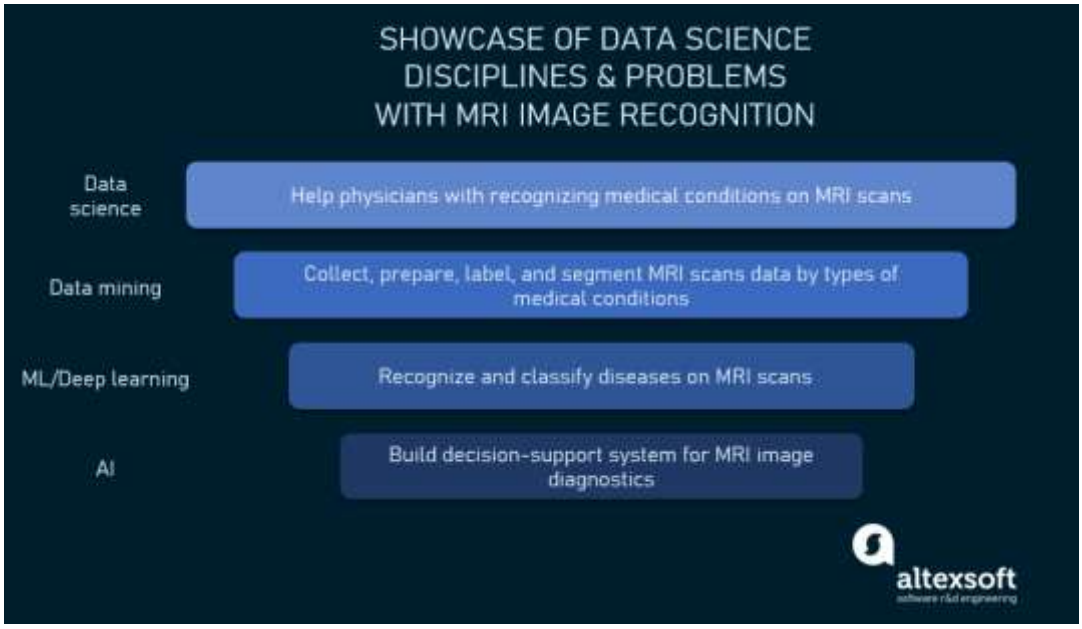
L'**artificial intelligence** (***AI*** o *intelligenza artificiale*) è un argomento complesso. Per semplicità, diciamo che qualsiasi prodotto di dati della vita reale può essere chiamato AI. Nell'esempio ispirato alla pesca, si immagini di voler acquistare un determinato modello di canna da pesca, ma si ha a disposizione solo una foto e non si conosce il marchio.

Un sistema di intelligenza artificiale è un prodotto software in grado di esaminare tale immagine e fornire suggerimenti sul nome di un prodotto e sui negozi in cui è possibile acquistarlo. Per creare un prodotto di intelligenza artificiale è necessario utilizzare il data mining, l'apprendimento automatico e talvolta il deep learning.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Nella figura seguente, si riporta un esempio significativo per comprendere le diverse funzioni degli argomenti appena trattati, utilizzando le discipline della scienza dei dati illustrate nel riconoscimento delle immagini MRI (Magnetic Resonance Imaging - imaging a risonanza magnetica).



Ricapitolando, la ***scienza dei dati*** ha un uso più generale. È un campo di studio proprio come l'informatica o la matematica applicata.

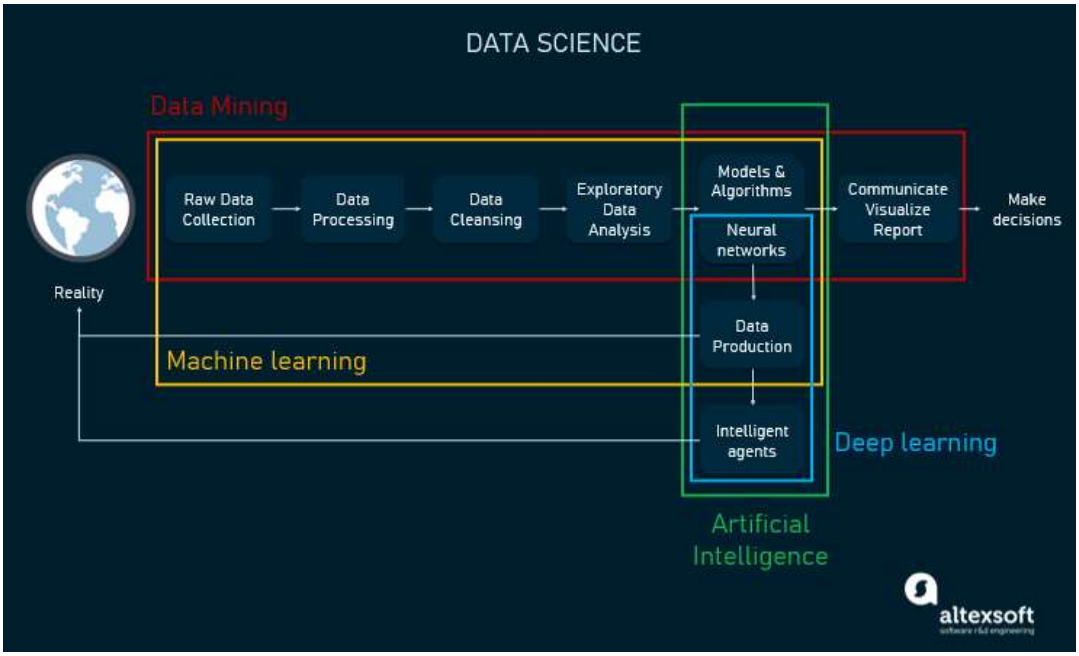
Il ***data mining*** riguarda più tecniche strettamente focalizzate all'interno di un processo di Data Science, ma cose come il riconoscimento di modelli, l'analisi statistica e la scrittura di flussi di dati sono applicabili all'interno di entrambi.

La scienza dei dati e, quindi, il data mining possono essere utilizzati per *costruire la base di conoscenze necessaria per l'apprendimento automatico, l'apprendimento profondo* e, di conseguenza, *l'intelligenza artificiale.*

Nella figura successiva, si riporta un'illustrazione delle relazioni tra Data Science, machine learning, intelligenza artificiale, deep learning e data mining.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).



Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

4. Esempi applicativi di Big Data e AI

Center for Geospatial Analytics, NCSU

Soluzioni Big Data e AI sono state applicate anche alla ***lotta contro la siccità e la fame nel mondo.*** Secondo le Nazioni Unite, è prevista una crescita della popolazione mondiale di 3 miliardi entro i prossimi 30 anni. Per sfamare un numero così alto di persone, la *produzione alimentare dovrà raddoppiare.*

Ad oggi, però, stiamo già utilizzando il *70% dell'acqua dolce del pianeta per l'agricoltura.* Ne consegue che non c'è abbastanza acqua o terreno per sostenere le pratiche di coltivazione attuali, figuriamoci per raddoppiare la produzione agricola.

I ricercatori della North Carolina State University (NCSU) stanno lavorando a una soluzione sostenibile. All'interno del ***Center for Geospatial Analytics***, i ricercatori della NCSU stanno iniziando a individuare e analizzare modelli in set di dati spaziotemporali al fine di comprendere meglio, e quindi ***prevedere, eventi climatici su larga scala*** *come inondazioni, siccità, incendi, nonché il rendimento dei raccolti.* In questo modo, è possibile aiutare le aziende agricole su larga scala a stabilire quando irrigare le colture e quando evitare di farlo, risparmiando risorse di cui abbiamo così disperatamente bisogno.

Per analizzare set di dati eterogenei di tali dimensioni per un problema su scala così ampia, il team della NCSU aveva bisogno di computer ad alte prestazioni dotati delle più recenti ***tecnologie di intelligenza artificiale e deep learning.***

Per quanto riguarda le risorse hardware, Lenovo ha collaborato con i ricercatori di NCSU per fornire loro l'accesso ai potenti supercomputer del *Lenovo Artificial Intelligence Innovation Center* a Morrisville, in North Carolina.

Con le nuove funzionalità di intelligenza artificiale, i ricercatori del Center for Geospacial Analytics della North Carolina State University hanno potuto ***analizzare enormi quantità di dati dei sensori provenienti da fattorie di tutti gli Stati Uniti.***

Sulla base di ***modelli meteorologici regionali***, i ricercatori ora sono in grado di *prevedere i periodi migliori per irrigare le colture*, riducendo lo spreco di acqua e migliorando, di conseguenza, la sostenibilità. I risultati dello studio sono:

- *analisi di più dati, a una maggiore velocità;*
- *accelerazione di progetti con nuovi algoritmi;*
- *riduzione dello spreco di acqua;*
- *cambiamento radicale.*

Beam Suntory, Inc.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Beam Suntory, Inc. è una compagnia statunitense, sussidiaria di Suntory Beverage & Food Ltd, a sua volta parte del gruppo Suntory di Osaka, in Giappone. La sua sede centrale si trova a Chicago, in Illinois, USA. È la terza produttrice mondiale di bevande distillate, dietro a Diageo e Pernod Ricard.

Nel 2005 acquista 20 marchi della Allied Domecq, diventando così uno dei più grandi produttori di whiskey a livello internazionale, uno dei maggiori produttori mondiali di superalcolici.

Obiettivo di Beam Suntory era mantenere la meticolosa tradizione testata nel tempo, ma trasformando la tecnologia. Per raggiungere tale obiettivo, Beam Suntory si è posta tre sotto-obiettivi:

1. *ridurre tempi di inattività e manutenzione;*
2. *incrementare efficienza e produzione;*
3. *aumentare la percentuale di mercato.*

Il raggiungimento dell'obiettivo sarebbe stato molto difficile con un'infrastruttura obsoleta. Lenovo ha collaborato, quindi, con il team di Beam Suntory per trovare nuove soluzioni (anche e soprattutto hardware) basate su ***tecnologie pre-configurate, pre-testate e certificate.***

Il nuovo sistema scalabile ha riunito tutte le risorse di elaborazione, storage, hardware e software, semplificando la gestione dei dati e ***riducendo al minimo il rischio di tempi di inattività non pianificati.***

I risultati del caso Beam Suntory-Lenovo in cifre:

- 30% di riduzione dei costi;
- 50% di riduzione di consumo di energia;
- riduzione dello spazio per i rack (armadi per hardware) da 15 unità a 3 unità.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Bibliografia

- Altexsoft - https://www.altexsoft.com/
- Associazione Big Data https://associazionebigdata.it/
- Beam Suntory, INC https://www.beamsuntory.com/
- CINECA https://www.cineca.it/
- Lenovo – Analytics and AI https://www.lenovo.com/it/it/data-center/solutions/analytics-ai/
- PD Solutions https://www.pdsol.com/news/what-is-industry-4-0/

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).