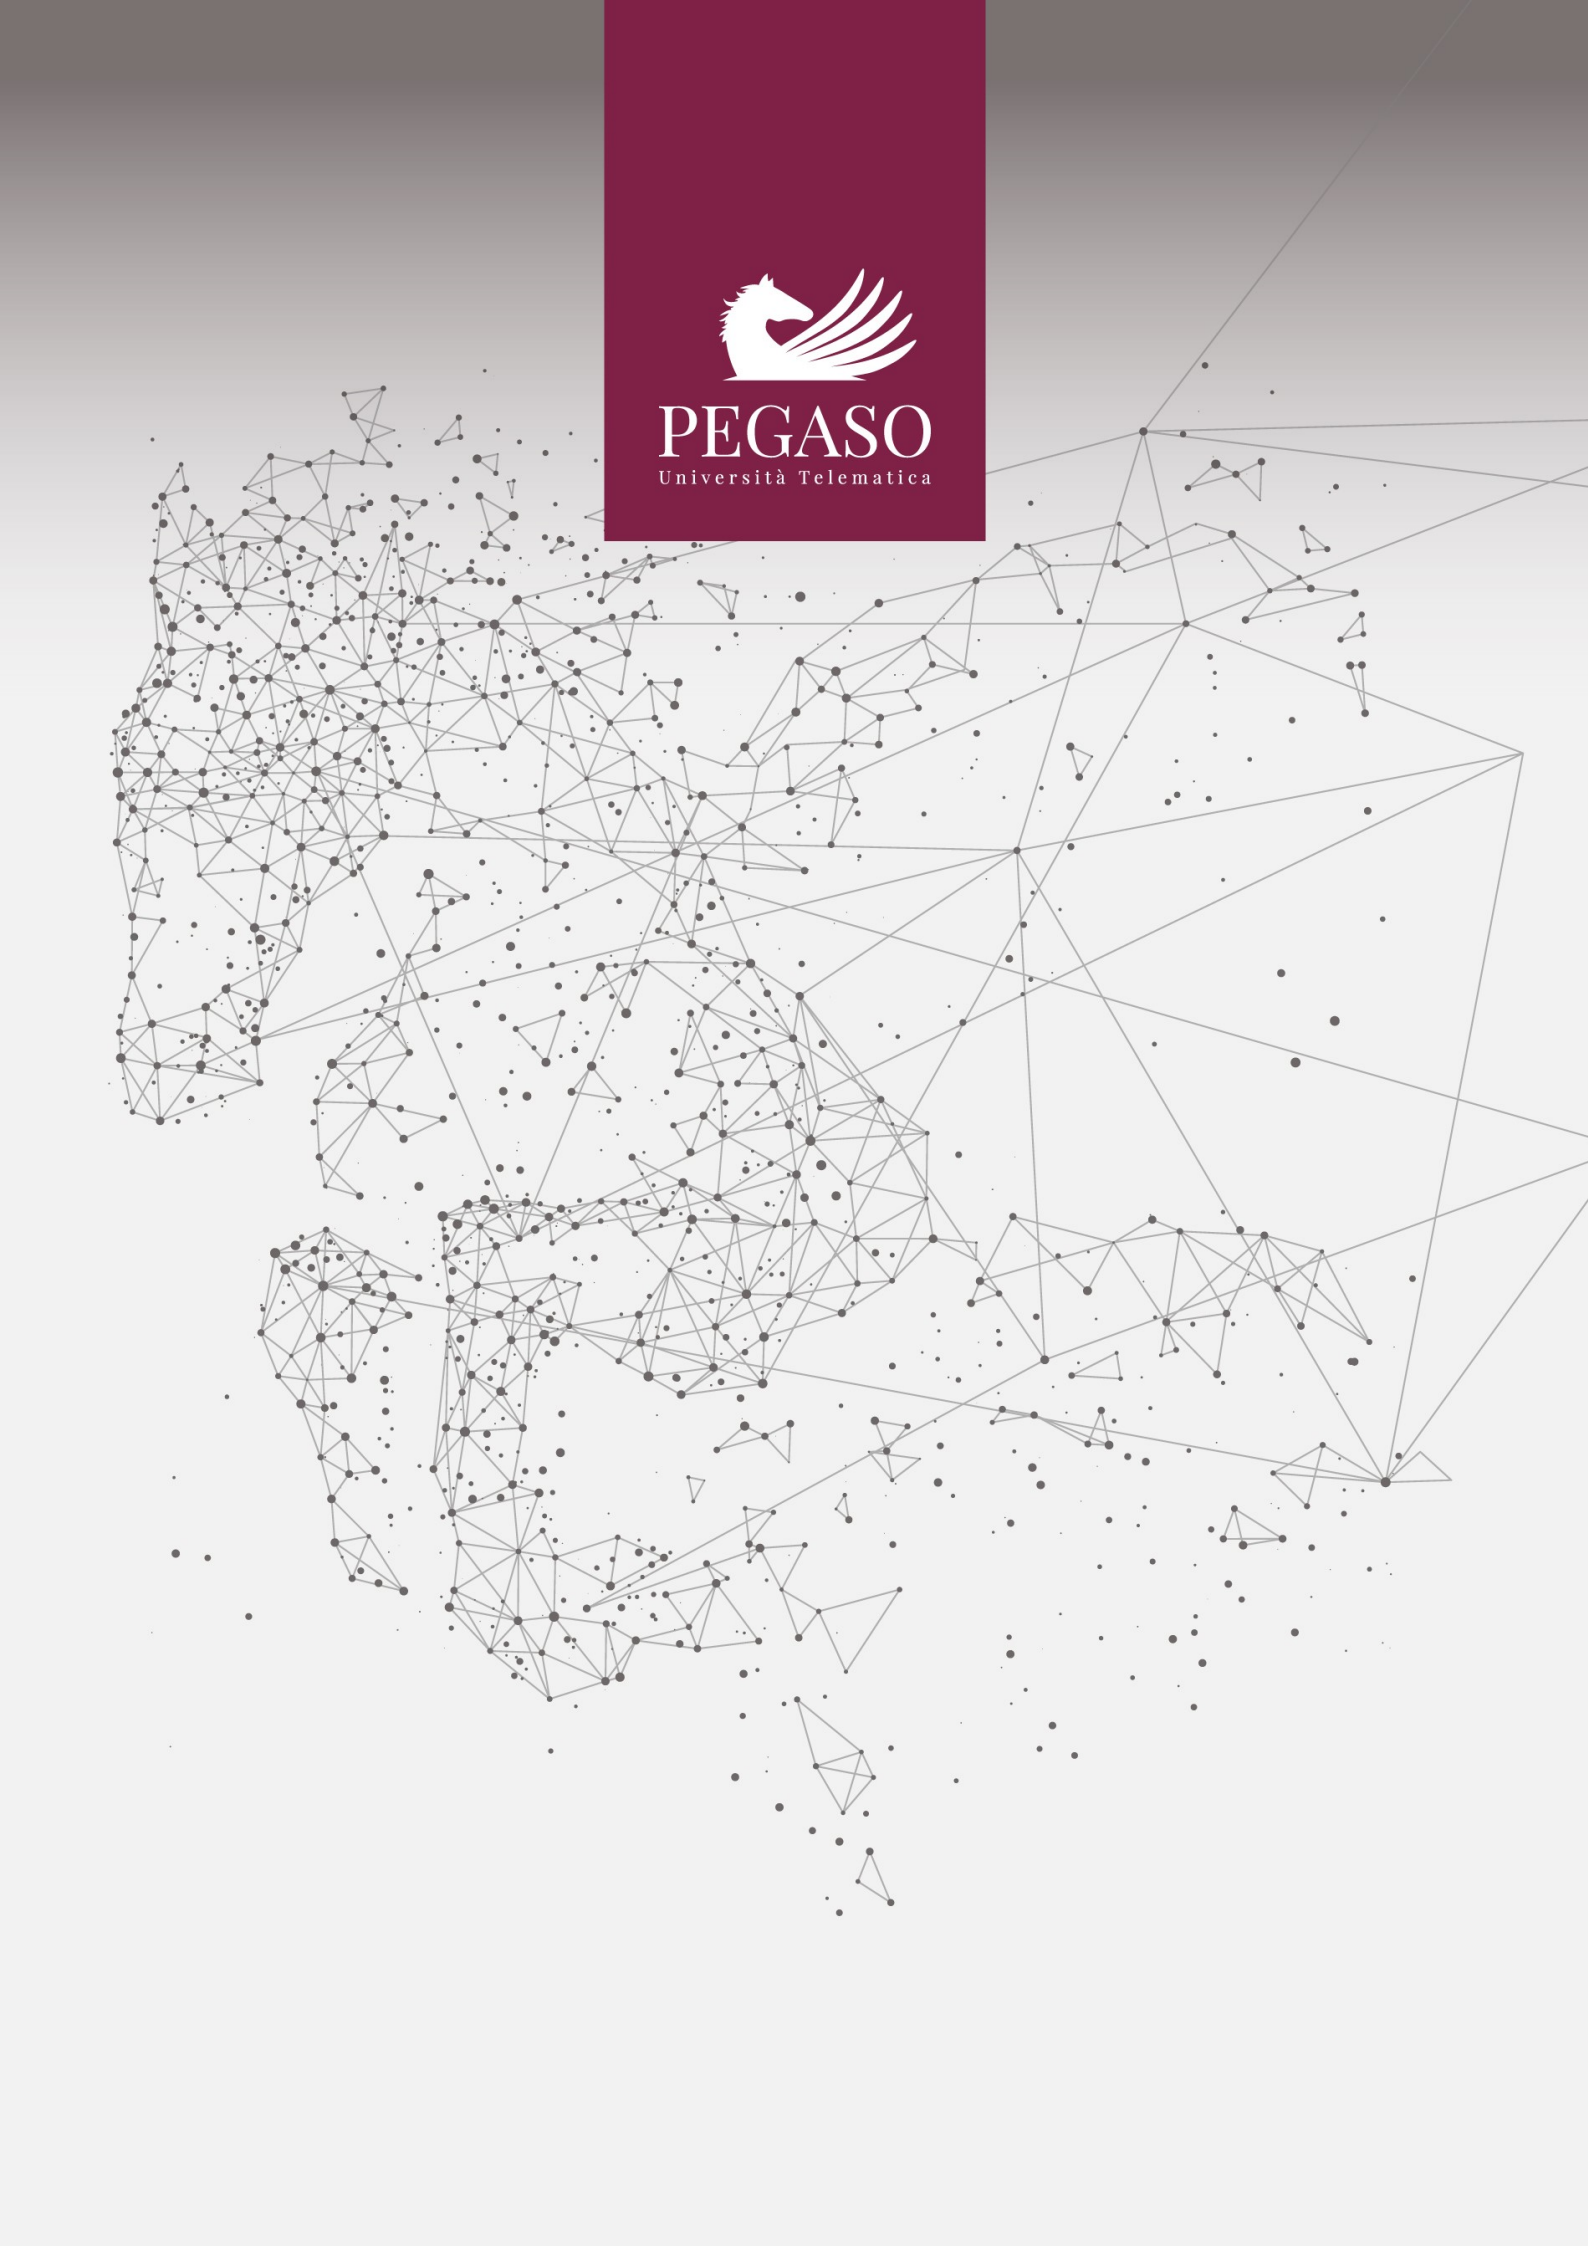

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Indice

INTRODUZIONE 3

1. PARADIGMI 4

2. INTRODUZIONE AL LEARNING 8

3. LEARNING CON BIG DATA 14

BIBLIOGRAFIA 18

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Introduzione

In questa dispensa di accompagnamento alla video-lezione, si introducono i paradigmi in cui si possono dividere gli approcci computazionali in ambito AI e si presentano i fondamenti dell'apprendimento automatico. In particolare, dopo un breve focus sui due paradigmi più utilizzati in ambito Big Data, si introduce il concetto di neurone artificiale (percettrone) e si presenta sia il suo modello, sia un esempio di addestramento tramite calcolo dei pesi sinaptici. Infine, si illustra la struttura a strati di una rete neurale e si riportano i livelli di classificazione che una rete neurale può raggiungere in base al numero di strati di cui è composta.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

1. Paradigmi

Gli approcci computazionali in ambito AI si possono dividere, a grandi linee, in quattro paradigmi. Tali paradigmi sono considerabili anche come modelli concettuali in grado di descrivere un certo tipo di computazione. Ogni paradigma è basato su un meccanismo di calcolo ispirato all'intelligenza umana, cioè comprende una famiglia di algoritmi con varie specializzazioni.

Le quattro tipologie più note di paradigmi sono:

1. evolutionary algorithm;
2. fuzzy logic;
3. expert system;
4. machine learning (comprendente neural network e deep learning).

Il paradigma viene selezionato sulla base di tre motivi principali:

1. è il più adatto per il problema da affrontare perché non si riesce a risolverlo con un algoritmo tradizionale, non si riesce a dettagliare ogni calcolo da eseguire;
2. si vuole studiare un certo approccio indipendentemente dalla necessità di risolvere un problema specifico;
3. si è obbligati da fattori indipendenti dalla propria volontà anche se il problema può essere risolto in modo semplice solo per dimostrare che si usa l'AI (caso peggiore è purtroppo frequente).

In ambito Big Data, i paradigmi più indicati sono ***expert system*** e ***machine learning*** (comprendente neural network e deep learning).

Un sistema esperto è un programma che cerca di riprodurre le prestazioni di uno o più persone esperte in un determinato campo di attività. Esso è formato da una base di conoscenza e da un motore inferenziale: quando riceve una serie di fatti è in grado di dedurre nuovi fatti. Tale sistema può trovare la soluzione ottimale a un problema specifico senza dover far intervenire una persona esperta sul tema oggetto del problema.

Un paragone molto generico può essere fatto con la mente umana e il suo modo di ragionare caratterizzato dalla capacità di effettuare concatenamenti logici (inferenza) e dalla conoscenza relativa al problema specifico. Un esempio molto semplice di sistema esperto può essere quello del calcolo dell'area di un triangolo senza che si conosca la formula esplicita derivante dalla geometria. In questo caso, bisognerebbe creare un sistema esperto in grado di ragionare sulla geometria piana a cui spiegare il concetto di area e mettere in grado di ricavare in modo autonomo l'algoritmo risolutore.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Molto interessante è l'utilizzo dei sistemi esperti in ambito sanitario (medical expert system). In ambito sanitario il referto stampato inviato da un laboratorio veniva controllato solo da un patologo. Oggi la documentazione può essere analizzata da un sistema automatico che interpreta i risultati dei test.

L'apprendimento automatico (o machine learning, ML), invece, permette di acquisire conoscenza tramite diverse forme di apprendimento derivate dall'esperienza realizzate su tanti esempi di input e output oppure di soli input. Con varie forme di apprendimento si possono prevedere nuovi dati, suddividere i dati in classi, creare nuove classi, generalizzare creando nuovi dati in base a quelli già noti. Un paragone del machine learning molto generico può essere fatto con la struttura del cervello umano nel caso delle reti neurali ispirate neuroni umani.

Nel contesto delle reti neurali ispirate ai neuroni umani si è sviluppato l'apprendimento profondo (deep learning) grazie a reti neurali molto ampie. Per fare un esempio molto semplice di utilizzo del machine learning, si ipotizzi di dover calcolare l'area di un triangolo. All'algoritmo non si fornisce la formula matematica ma terne del tipo (misure della base, misura dell'altezza e area). Dopo un po' di tempo il sistema di ML fornisce aree per triangoli le cui misure non sono mai state considerate; il tutto senza avere nessuna nozione del concetto di area del triangolo.

Il ML si utilizza, quindi, quando si conoscono le associazioni tra input e output, ma non esiste un algoritmo esplicito per la trasformazione input/output. Il sistema deve essere adattivo quindi deve generalizzare le osservazioni. Purtroppo, non è semplice capire come avviene il passaggio dall'input all'output e ciò potrebbe portare a difficoltà di accettazione in certi contesti.

Nel vasto campo del ML, le reti neurali sono vagamente ispirate alla rete formata da neuroni biologici esistente nel cervello umano. Si utilizza un modello computazionale composto di neuroni matematici piuttosto semplici. La collocazione dei neuroni in vari livelli operanti in parallelo e gli algoritmi di ottimizzazione forniscono interessanti opportunità per risolvere problemi di classificazione e predizione.

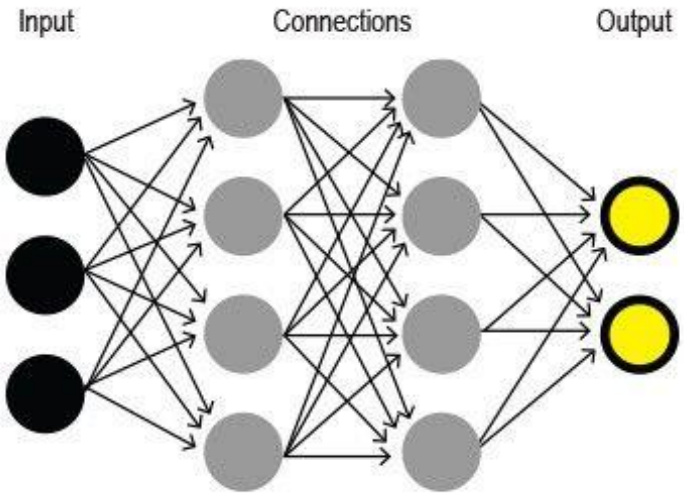
Esistono diversi modelli in grado di apprendere dagli esempi forniti con o senza supervisione dell'esperto. Le reti neurali hanno il grosso difetto di non essere spiegabili nel linguaggio simbolico umano.

I risultati vengono accettati senza comprendere fino in fondo perché sono stati generati in quel modo.

La figura seguente riporta la tipica struttura di una rete neurale, composta da diversi strati (in verticale) di neuroni artificiale connessi tra loro.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).



In una rete neurale è possibile aumentare notevolmente il numero di neuroni, aumentare notevolmente il numero di livelli, usare particolari funzioni di ottimizzazione.

Quando queste tre condizioni sono soddisfatte è possibile raggiungere il cosiddetto Deep Learning (DL).

La possibilità di avere diversi livelli di rappresentazione, corrispondenti ad una gerarchia di caratteristiche e concetti, permette di creare concetti di alto livello sulla base di quelli a livello più basso. Per esempio, un volto umano è un concetto di alto livello formato da concetti più semplici (occhi, naso, bocca, ecc.) che a loro volta sono descrivibili con colore, forma, posizione, ecc.

La complessità di realizzazione di un alto numero di esempi richiesti si ripaga con l'ampia capacità di classificazione delle immagini, dei testi e di altre tipologie di dato.

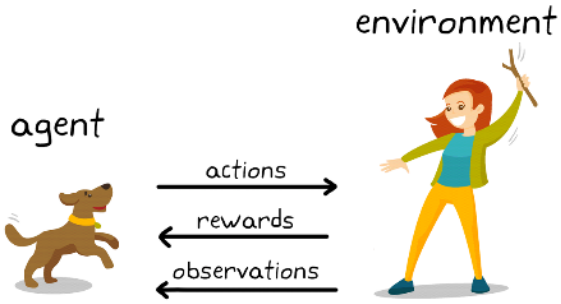
L'apprendimento per rinforzo, infine, è una tecnica di apprendimento automatico (di ML, quindi) che punta a realizzare agenti autonomi in grado di scegliere azioni da compiere per raggiungere obiettivi tramite l'interazione con l'ambiente in cui sono immersi e una ricompensa che lo scopo di incoraggiare comportamenti corretti.

L'apprendimento per rinforzo viene usato in problemi di decisioni sequenziali, in cui l'azione da compiere dipende dallo stato attuale del sistema e ne determina quello futuro.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

La figura seguente schematizza l'interazione tra l'agente intelligente e l'ambiente secondo l'approccio di apprendimento per rinforzo.



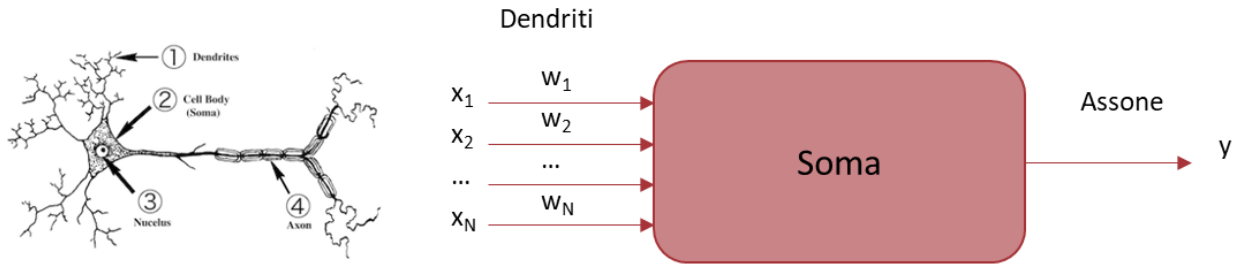
Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

2. Introduzione al learning

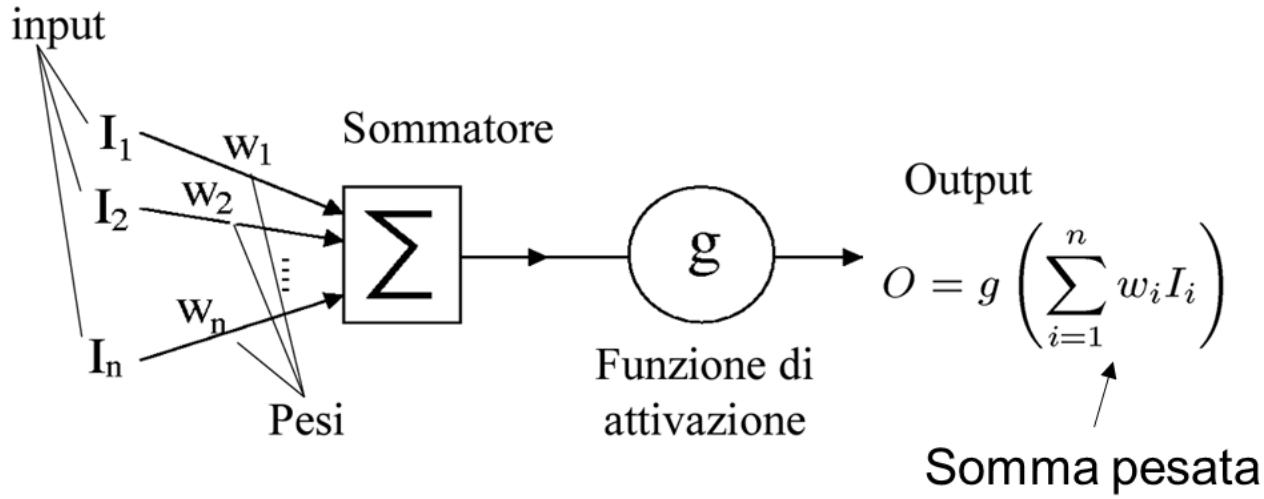
Per poter capire come funziona l'apprendimento e perché è necessaria una grande mole di dati per l'apprendimento stesso è necessario partire dal neurone artificiale (perceptron) che simula il neurone umano.

Il neurone artificiale è un sistema ad N ingressi e un'uscita. Più in particolare, ogni segnale di ingresso viene moltiplicato per il cosiddetto peso sinaptico (w_i) che varia nel tempo ed è alla base dell'apprendimento (learning).

La figura seguente riporta a sinistra lo schema del neurone umano e a destra la sua modellazione matematica formata da N ingressi, N pesi sinaptici, un'unità elaboratrice (soma) e una uscita (assone).



Prima di procedere con la classificazione delle sinapsi, si analizza il modello matematico del neurone artificiale. Come schematizzato nella figura seguente ciascun valore di input viene moltiplicato per un peso sinaptico (w). I prodotti di tutti gli ingressi per i relativi pesi sinaptici vengono sommati (somma pesata) e, successivamente, tale prodotto viene passato come parametro ad una funzione di attivazione che calcola il valore di output.



Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

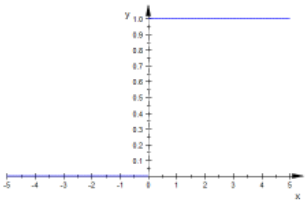
In base ai pesi sinaptici, le sinapsi sono dette;

- eccitatorie se w>0;
    - attenuatrici se 0<w<1;
    - amplificatrici se w>1;
- inibitorie se w<0.

Definendo la funzione di attivazione del modello matematico del neurone è possibile ottenere il percettrone (neurone artificiale). In particolare, la funzione di attivazione più plausibile è la funzione a soglia q(x) di Heaviside. Tale funzione è una funzione a tratti per cui, il risultato è uguale a 0 per valori di x minori di zero e uguale a 1 per valori di x maggiori o uguali a zero. Segue la definizione matematica della funzione.

$$\theta : R \longrightarrow \{0, 1\}$$

$$\theta(x) = \begin{cases} 0 & \text{se } x < 0 \\ 1 & \text{se } x \geq 0 \end{cases}$$



Attraverso l'uso di un valore di soglia t da sottrarre alla somma pesata, è possibile traslare la funzione sull'asse delle ascisse. La formula matematica corrispondente è:

$$O = \theta\left(\sum_{i=1}^{n} w_i I_i - t\right)$$

In questo caso, applicando la funzione di Heaviside, il risultato sarà uguale a 0 per valori di x minori di t e uguale a 1 per valori di x maggiori o uguali a t.

Il perceptron è un modello non lineare perché nonostante la funzione somma pesata sia lineare, la funzione di attivazione è una funzione non lineare.

È possibile definire quindi il comportamento del perceptron nel seguente modo:

- il perceptron si attiva (output =1), se il segnale accumulato dagli ingressi e opportunamente pesato attraverso le sinapsi supera una cera soglia;

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

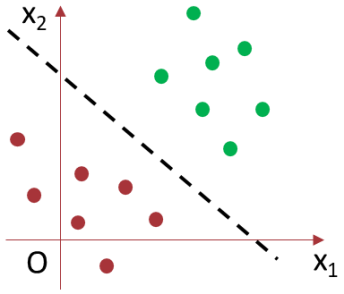
- il perceptron non si attiva (output = 0) in caso contrario.

L'apprendimento dunque consiste nel selezionare i corretti valori dei pesi e della soglia della funzione di attivazione. Come sarà chiaro nell'esempio di apprendimento, il problema di apprendimento di un perceptron è basato sul seguente schema:

1. dato un insieme di punti su uno spazio n-dimensionale, classificare tali punti in due gruppi (positivi e negativi);
2. dato un nuovo punto decidere a quale dei due gruppi appartiene.

Il primo problema è di classificazione, mentre per il secondo è richiesta capacità di generalizzazione. Il teorema di convergenza del perceptron (Rosenblatt, 1962) assicura che il percettrone riuscirà a delimitare le due classi se il sistema è linearmente separabile.

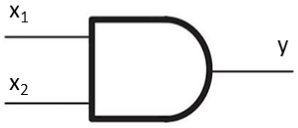
Di seguito, si riporta un esempio grafico bidimensionale (2 ingressi) di spazio linearmente separabile (punti verdi dai punti rossi).



Si propone ora un esempio molto semplice, ma significativo ed esplicativo del funzionamento del perceptron. In particolare, nella prima fase (detta di addestramento) si addestrerà il perceptron a risolvere un problema attraverso i pesi sinaptici. Nella seconda fase (detta di utilizzo), si procederà ad utilizzare il modello come rete combinatoria con i pesi sinaptici costanti calcolati nella prima fase.

L'esempio che si propone è quello di riprodurre una porta logica AND. Come riportato nella tavola della verità seguente, l'output di una porta logica AND è vero solo se entrambi gli input sono veri.

x_1	x_2	y
0	0	0
0	1	0
1	0	0
1	1	1



Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Per procedere con l'apprendimento i valori dei pesi sinaptici si impostano ad un valore casuale. Con riferimento al modello riportato nella figura seguente, nel nostro caso si pone w_1=0.9 e w_2=0.9. Si imposta poi il valore della soglia t = 0.5.



SI procede, quindi, calcolando il valore della somma pesata per la prima combinazione dei due ingressi (x_1=0 e x_2=0):

$$s = x_1*w_1+ x_2*w_2= 0*0.9+0*0.9 = 0$$

$$q(s-t) = q(0-0.5) = q(-0.5) = 0$$

Il valore della somma pesata è pari a zero. Il valore di output ottenuto calcolando la funzione di Heaviside sul valore zero è proprio zero. Poiché il risultato è corretto, i valori dei pesi non vengono aggiornati.

Si procede con la seconda combinazione di ingressi (x_1=0 e x_2=1):

$$s = x_1*w_1+ x_2*w_2= 0*0.9+1*0.9 = 0.9$$

$$q(s-t) = q(0.9-0.5) = q(0.4) = 1$$

Il valore della somma pesata è pari a 0.9. Il valore di output ottenuto calcolando la funzione di Heaviside sul valore 0.9 è 1. Poiché il risultato è errato (è diverso dal valore atteso), si procede con l'aggiornamento dei pesi. Si calcola l'errore e come segue:

$$e = \text{valore_atteso} - \text{predizione} = 0-1 = -1$$

Per la correzione dell'errore, si aggiungerà ai pesi sinaptici il valore dell'errore ***e*** moltiplicato per il learning rate ***l***. Il learning rate ***l*** è un valore compreso tra 0 e 1 (i valori degli ingressi rimarranno x_1=0 e x_2=1):

$$w_1 = w_1+ l*e*x_1= 0.9+0.5*(-1)*0 = 0.9$$

$$w_2 = w_2+ l*e*x_2= 0.9+0.5*(-1)*1 = 0.9-0.5 = 0.4$$

Mentre il valore del primo peso sinaptico w_1 rimane invariato, il valore del secondo peso sinaptico w_2 si riduce a 0.4.

Si procede con la terza combinazione di ingressi (x_1=1 e x_2=0):

$$s = x_1*w_1+ x_2*w_2= 1*0.9+0*0.4 = 0.9$$

$$q(s-t) = q(0.9-0.5) = q(0.4) = 1$$

Il valore della somma pesata è pari a 0.9. Il valore di output ottenuto calcolando la funzione di Heaviside sul valore 0.9 è 1. Il risultato è errato: si procede con l'aggiornamento dei pesi.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Calcoliamo l'errore e:

$$e = valore_atteso - predizione = 0-1 = -1$$

Per la correzione dell'errore, si aggiungerà ai pesi sinaptici il valore dell'errore ***e*** moltiplicato per il learning rate ***l:***

$$w_1 = w_1 + l*e*x_1 = 0.9+0.5*(-1)*1 = 0.9 - 0.5 = 0.4$$

$$w_2 = w_2 + l*e*x_2 = 0.4+0.5*(-1)*0 = 0.4$$

Mentre il valore del secondo peso sinaptico w_2 rimane invariato, il valore del primo peso sinaptico w_1 si riduce a 0.4.

Si procede, quindi, con la quarta combinazione di ingressi (x_1=1 e x_2=1):

$$s = x_1*w_1 + x_2*w_2 = 1*0.4+1*0.4 = 0.8$$

$$q(s-t) = q(0.8-0.5) = q(0.3) = 1$$

Il valore della somma pesata è pari a 0.8. Il valore di output ottenuto calcolando la funzione di Heaviside sul valore 0.8 è 1. Il risultato è corretto.

Ora si riprova a presentare la prima combinazione di ingressi (x_1=0 e x_2=0):

$$s = x_1*w_1 + x_2*w_2 = 0*0.4+0*0.4 = 0$$

$$q(s-t) = q(0-0.5) = q(-0.5) = 0$$

Il valore della somma pesata è pari a 0. Il valore di output ottenuto calcolando la funzione di Heaviside sul valore 0 è 0. Anche in questo caso il risultato è corretto. L'apprendimento è andato a buon fine poiché per tutte e quattro le casistiche il neurone artificiale produce il risultato corretto.

Si procede ora calcolando l'equazione della retta di separazione che separa linearmente lo spazio. Si imposta la seguente equazione:

$$x_1*w_1 + x_2*w_2 - t = 0$$

Si sostituiscono i valori dei pesi sinaptici appena calcolati:

$$x_1*0.4 + x_2*0.4 - 0.5 = 0$$

Si calcola l'equazione della retta:

$$x_2 = (0.5 - x_1*0.4)/0.4 \rightarrow x_2 = 1.25 - x_1$$

e si calcolano le intercette della retta con gli assi:

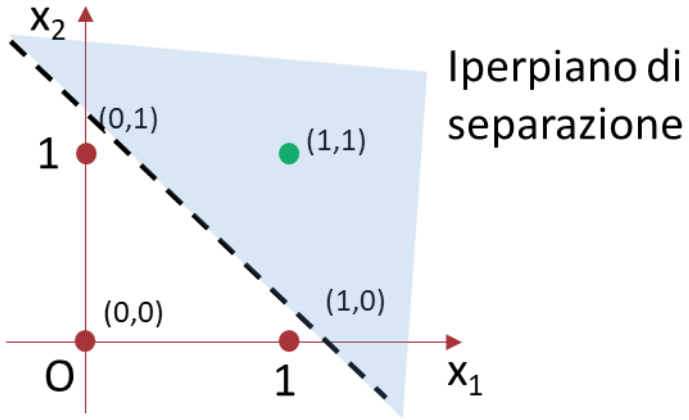
$$\text{per } x_1 = 0 \rightarrow x_2 = 1.25$$

$$\text{per } x_2 = 0 \rightarrow x_1 = 1.25$$

Il grafico che segue riporta la retta di separazione appena calcolata e i quattro punti relativi alla funzione AND.

PEGASO
Università Telematica

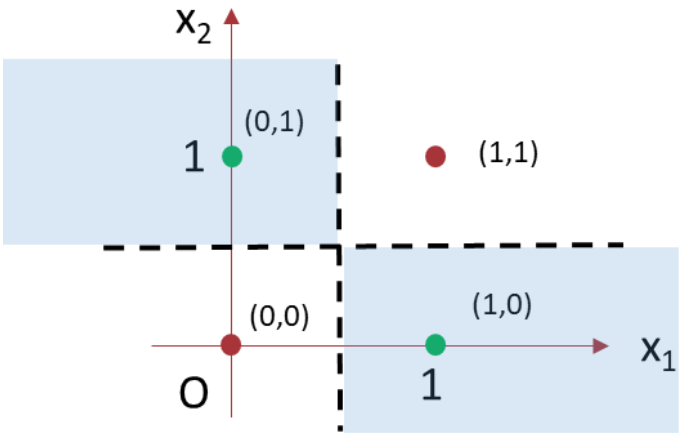
Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).



Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

3. Learning con Big Data

Il percettrone ha purtroppo dei limiti di classificazione. Ad esempio, non riesce a simulare la funzione logica XOR (si veda la figura seguente) poiché non linearmente separabile.



Per ovviare a tale limite, si ricorre a **reti neurali** costituita da:

- un insieme di nodi (neuroni);
- un insieme di pesi (sinaptici) associati ai collegamenti;
- un insieme di soglie o livelli di attivazione.

La rete è, quindi, formata da una successione sovrapposta di strati ognuno dei quali ha un certo numero di perceptron. Si comincia dai nodi terminali che ricevono l'input (non sono veri e propri neuroni) che costituiscono lo strato di input.

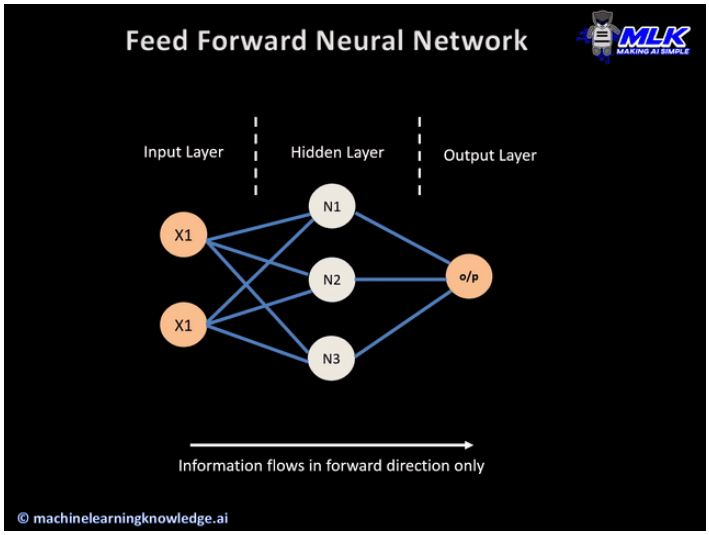
Seguono uno o più hidden layer (livello nascosto) chiamati così perché non direttamente visibili da input e output. Conclude l'ultimo strato di neuroni che forniscono in output il risultato del modello.

Ogni neurone di uno strato è collegato con tutti i neuroni dello strato successivo, mentre i neuroni dello stesso strato non sono collegati. Nel conteggio del numero di layer non si tiene conto dello strato di input poiché tali neuroni non sono in grado di eseguire calcoli.

L'informazione viene elaborata in modo feed forward cioè dall'input all'output calcolando l'attivazione dei neuroni di uno strato alla volta. Si parla, infatti, anche di FFNN (Feed Forward Neural Network). Nella figura successiva si riporta una rete neurale con uno strato di input, uno strato nascosto (hidden) e uno strato di output.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).



L'addestramento (learning) delle reti neurali è stato reso possibile all'algoritmo di back propagation che permette di calcolare i pesi di ciascun collegamento.

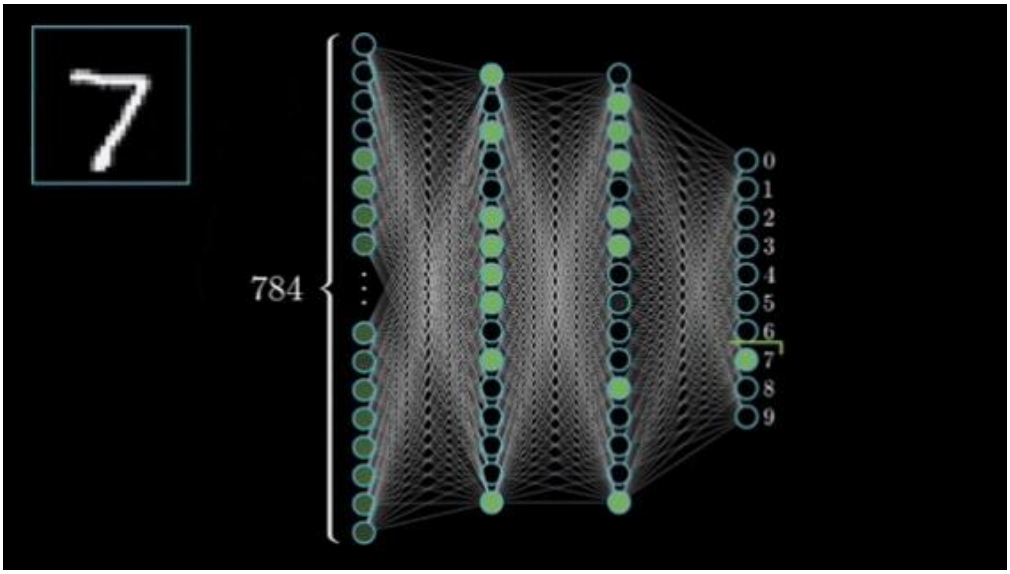
I Big Data, in questo caso, entrano in gioco perché l'apprendimento possa essere più efficiente possibile. Per valutare le prestazioni di una rete neurale, infatti, si utilizzano tre diversi dataset:

1. il **training dataset** che è l'insieme dei dati su cui la rete effettua l'apprendimento;
2. il **test dataset** che è un insieme di dati indipendenti dal training set ma con la stessa distribuzione di probabilità. Questo dataset viene utilizzato per valutare il modello finale di rete che verrà selezionata nel processo di validazione;
3. il **validation dataset** che è l'insieme di dati su cui valutare le performance della rete neurale. Essendo terminato l'addestramento quando si utilizza questo dataset, in questa fase i valori dei pesi non vengono modificati.

Nella figura seguente si riporta un esempio di rete neurale con più strati nascosti (hidden) utilizzata per il riconoscimento di numeri scritti a mano attraverso un'immagine. Nel caso in oggetto, la rete riconosce il numero 7 scritto a mano in modo corretto. Si notino le attivazioni dei neuroni segnalate da pallini verdi.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).



Molto importante è comprendere la capacità di classificazione di reti neurali all'aumentare degli strati di neuroni. Nella tabella seguente si riportano tre importanti casi.

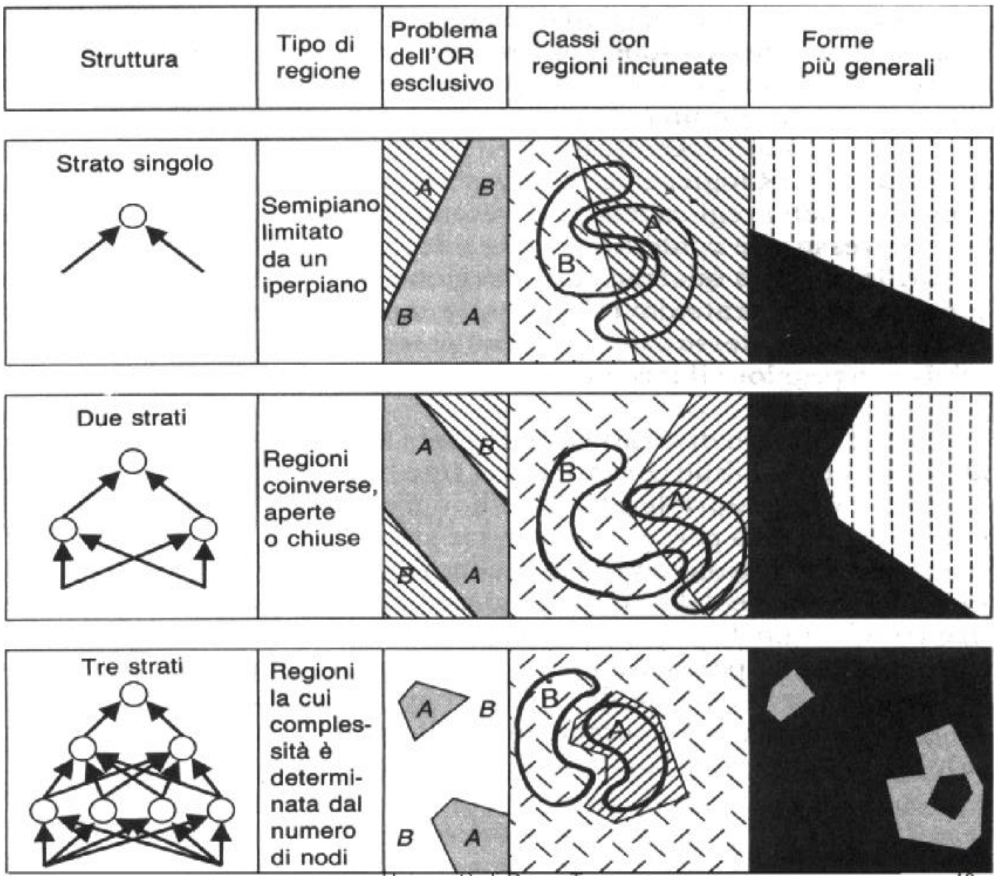
Nel primo caso, la rete è costituita da un solo percettrone. Il comportamento è quello analizzato; il tipo di regione di classificazione è un semipiano limitato da un iperpiano. Sono esclusi, quindi, casi di classi con regioni incuneate.

Nel secondo caso, la rete è costituita da due strati. Il tipo di regione di classificazione è convesso (aperto o chiuso). Questo tipo di rete permette di risolvere il caso dell'XOR. Le classi con regioni incuneate sono ancora escluse dalla classificazione.

Nel terzo caso, la rete è costituita da tre strati. Il tipo di regione di classificazione, in questo caso, è determinato dal numero di nodi. Ovviamente, riesce a risolvere il problema dell'XOR, ma anche casi più complessi, come le classi con regioni incuneate.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).



Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Bibliografia

- Marmo, Roberto. Algoritmi per l'intelligenza artificiale: Progettazione dell'algoritmo-Dati e Machine Learning-Neural Network-Deep Learning. HOEPLI EDITORE, 2020

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).