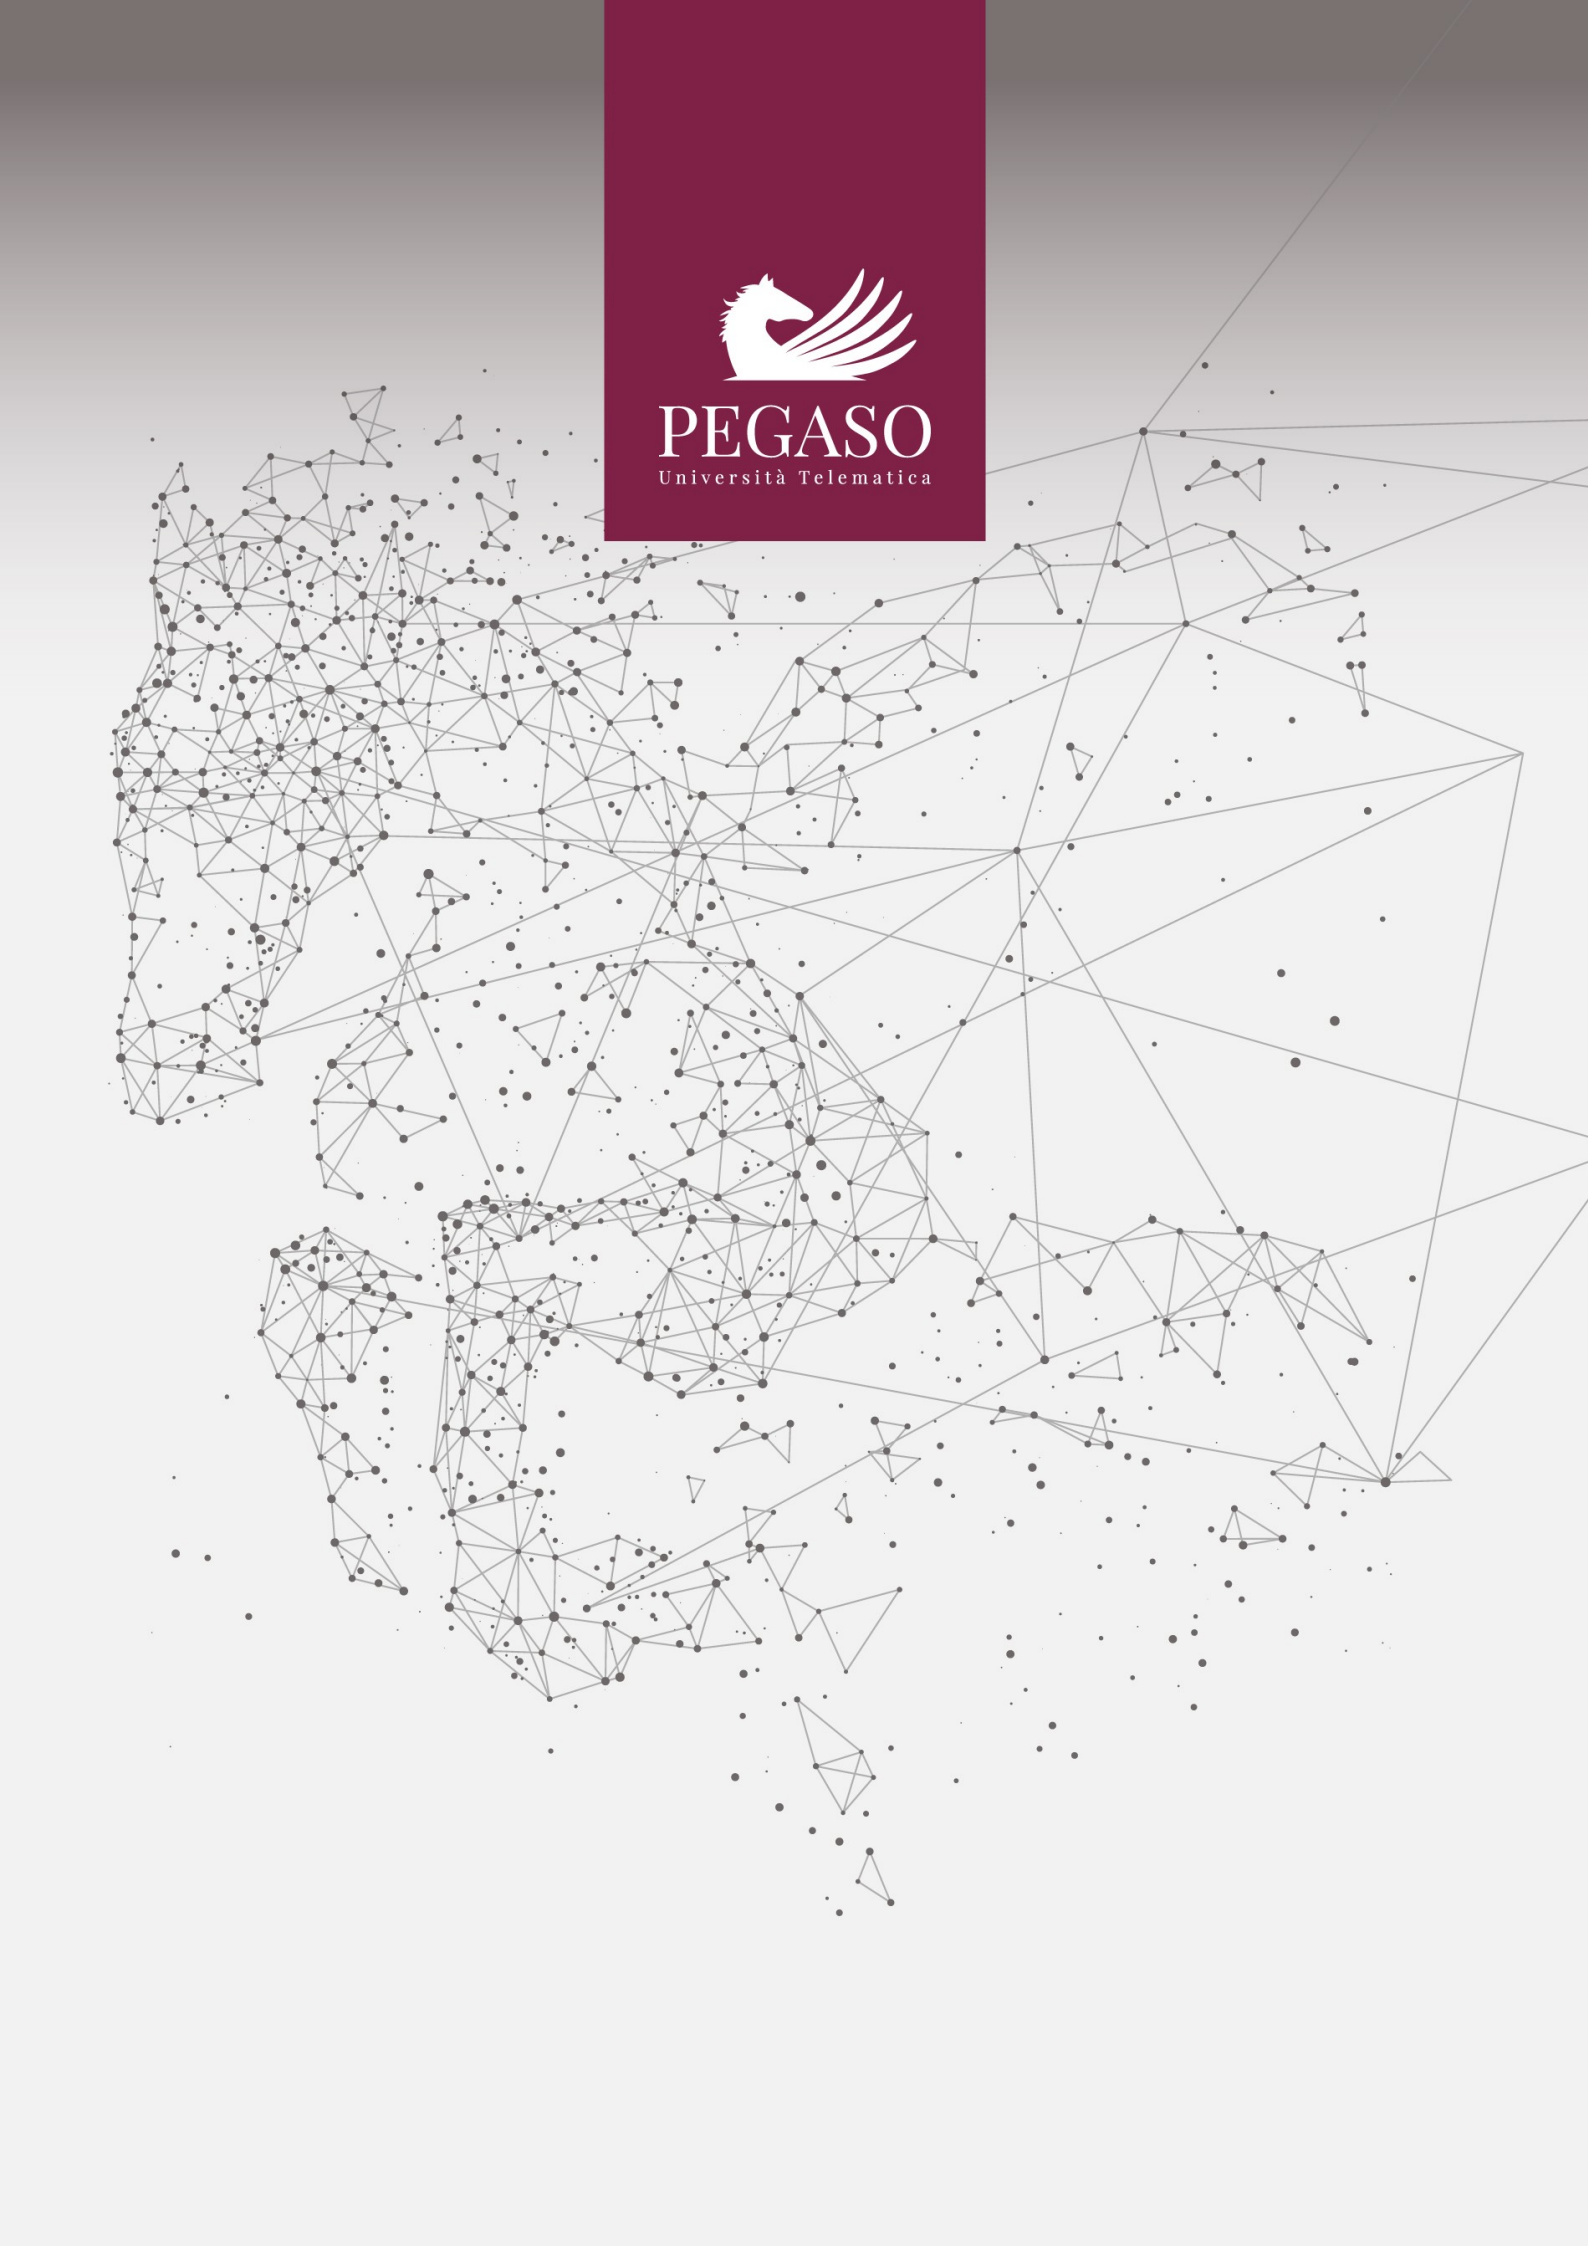

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Indice

1. MULTICAST BASATO SU ALBERI 3

2. MULTICAST BASATO SU FLOODING 6

3. DISSEMINAZIONE DATI BASATA SU GOSSIP 8

BIBLIOGRAFIA 11

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

1. Multicast basato su alberi

La comunicazione multicast, ovvero quella tecnologia che fornisce supporto per l'invio di dati a più ricevitori, è un argomento importante nella comunicazione di sistemi distribuiti.

Numerose proposte di soluzioni a livello di rete e di trasporto sono state implementate e valutate nel corso degli anni nel contesto dei protocolli di rete. La creazione di canali di comunicazione per la diffusione delle informazioni ha rappresentato una sfida significativa per tutte le soluzioni proposte. Nella pratica, ciò ha richiesto un notevole sforzo di gestione e, in molti casi, l'intervento umano. Inoltre, gli ISP hanno mostrato riluttanza a supportare il multicast finché non vi è stata una reale convergenza di proposte.

Con l'introduzione della tecnologia peer-to-peer, in particolare la gestione strutturata delle reti overlay, è diventato più semplice stabilire canali di comunicazione. Poiché le soluzioni peer-to-peer vengono in genere distribuite a livello di applicazione, sono state sviluppate numerose tecniche di multicast a livello di applicazione. In questa lezione, vedremo alcune di queste tecniche.

Esistono metodi aggiuntivi per ottenere comunicazioni multicast oltre a stabilire percorsi di comunicazione espliciti. La diffusione delle informazioni basata su gossip offre metodi di multicast semplici (ma spesso inefficienti).

Nel multicast a livello di applicazione, i nodi si organizzano in una rete overlay, che viene quindi utilizzata per distribuire i dati ai suoi membri. Osservazione importante: i router di rete non appartengono al gruppo. Di conseguenza, le connessioni tra i nodi nella rete overlay possono estendersi su più collegamenti fisici e i messaggi di routing all'interno dell'overlay potrebbero non essere ottimali rispetto a ciò che il routing a livello di rete avrebbe potuto ottenere.

La costruzione della rete overlay è una questione di progettazione cruciale. Esistono due approcci fondamentali. In primo luogo, i nodi possono auto-organizzarsi direttamente in un albero, il che significa che esiste un percorso unico (overlay) tra ogni coppia di nodi.

Un metodo alternativo è che i nodi si organizzino in una rete mesh, in cui ogni nodo ha più vicini e, in generale, esistono più percorsi tra ogni coppia di nodi. La distinzione principale tra i due è che quest'ultimo fornisce tipicamente una maggiore robustezza: se una connessione si interrompe (ad esempio, perché un nodo fallisce), le informazioni possono ancora essere diffuse senza dover riorganizzare immediatamente l'intera rete overlay.

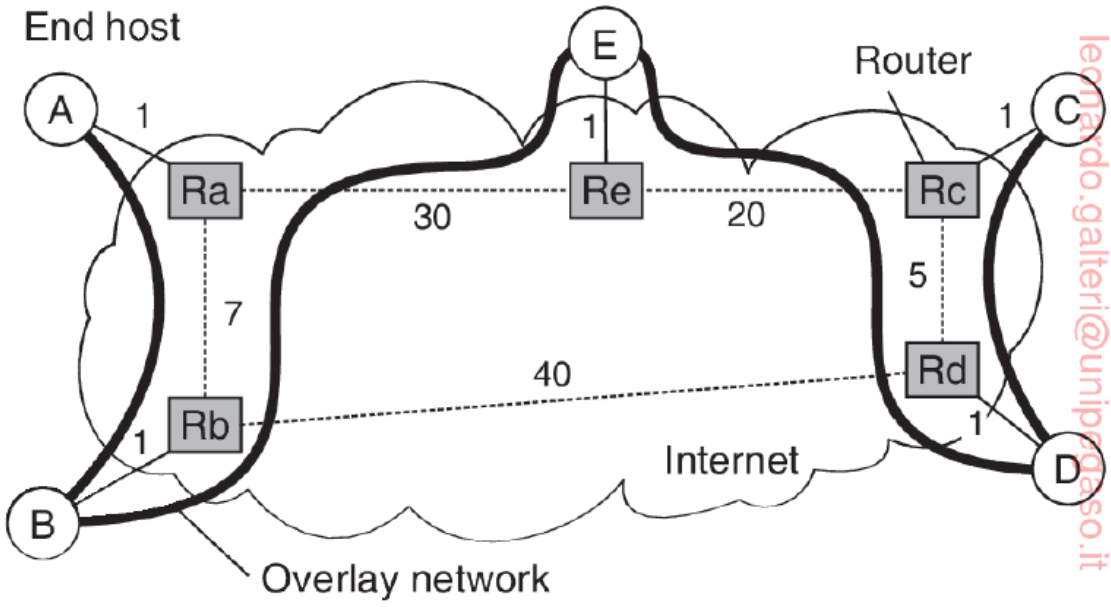
Una volta che abbiamo organizzato i nodi in un overlay, costruire un albero non un'operazione così complessa; tuttavia, costruire un albero efficiente potrebbe rivelare una storia completamente diversa. Si noti che nella descrizione corrente, la selezione dei nodi partecipanti all'albero non tiene conto delle

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

metriche delle prestazioni; si basa esclusivamente sull'instradamento (logico) dei messaggi attraverso l'overlay.

La Figura 1 illustra un piccolo insieme di cinque nodi organizzati in una semplice rete di overlay, con il nodo A che funge da radice dell'albero multicast allo scopo di comprendere il problema in questione. Inoltre, vengono visualizzati i costi di attraversamento di un collegamento fisico. Ora, ogni volta che A esegue il multicast di un messaggio agli altri nodi, questo messaggio attraversa due volte ciascuno dei collegamenti (B, Rb), (Ra, Rb), (E, Re), (Rc, Rd) e (D, Rd). Se avessimo costruito (A, E) e (C, E) piuttosto che (B, E) e (D, E), la rete di overlay sarebbe stata più efficiente. Tale configurazione avrebbe eliminato la necessità di attraversare (Ra, Rb) e (Rc, Rd) due volte.



leonardo.galteri@unipegaso.it

Figura 1 - Courtesy of van Steen, Maarten & Tanenbaum, Andrew. (2017). Distributed Systems, Third edition

In generale, la qualità di un albero multicast a livello di applicazione viene misurata utilizzando tre metriche distinte: link stress, stretch e tree cost. Il link stress è definito per collegamento e misurato dal numero di volte in cui un pacchetto attraversa lo stesso collegamento. Come mostrato nella Figura 1, una sollecitazione di collegamento maggiore di 1 deriva dal fatto che, sebbene un pacchetto possa essere inoltrato lungo due connessioni logicamente distinte, una parte di tali connessioni può corrispondere allo stesso collegamento fisico.

Lo stretch o Relative Delay Penalty (RDP) misura il rapporto tra il ritardo tra due nodi di overlay e il ritardo che quegli stessi nodi incontrerebbero nella rete sottostante. Nella rete overlay, i messaggi da B a C

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

seguono il percorso B → Rb → Ra → Re → E → Re → Rc → Rd → D → Rd → Rc → C, sostenendo un costo totale di 73 unità.

Tuttavia, i messaggi sarebbero stati instradati nella rete sottostante lungo il percorso B → Rb →Rd → Rc→ C, sostenendo un costo totale di 47 unità e risultando in uno stretch di 1,55. Chiaramente, l'obiettivo della costruzione di una rete overlay è quello di ridurre al minimo lo stretch aggregato, o equivalentemente, l'RDP medio misurato su tutte le coppie di nodi.

Infine, il tree cost è una metrica globale comunemente associata alla riduzione al minimo dei costi di collegamento aggregati. Ad esempio, se il costo di un collegamento è il ritardo tra i suoi due nodi finali, l'ottimizzazione del costo dell'albero comporta l'individuazione di uno spanning tree minimo in cui il tempo totale per la diffusione delle informazioni a tutti i nodi è ridotto al minimo.

Si supponga che un gruppo multicast disponga di un nodo noto associato che tiene traccia dei nodi che si sono uniti all'albero per semplificare un po' le cose. Quando un nuovo nodo invia una richiesta di join, contatta questo nodo di *rendezvous* per ottenere un elenco (potenzialmente incompleto) dei membri. L'obiettivo è identificare il miglior candidato per il padre del nuovo nodo nell'albero. Chi dovrebbe essere scelto? Esistono numerose alternative e proposte diverse spesso comportano soluzioni molto dissimili.

Si consideri, ad esempio, un gruppo multicast con una singola sorgente. In questo caso, la selezione del nodo ottimale è ovvia: la sorgente dovrebbe essere scelta (perché in tal caso possiamo essere certi che il tratto sarà uguale a 1).

Tuttavia, questo si tradurrebbe in una topologia a stella con la sorgente al centro. Non è difficile immaginare che la fonte si sovraccarichi, nonostante la sua semplicità. In altre parole, la selezione di un nodo sarà tipicamente limitata ai nodi con k o meno vicini, dove k è un parametro del progetto. Questo vincolo complica notevolmente l'algoritmo per la creazione dell'albero, poiché una buona soluzione potrebbe richiedere la riconfigurazione di una parte dell'albero esistente.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

2. Multicast basato su flooding

Fino ad ora abbiamo ipotizzato che quando un messaggio deve essere multicast, deve essere ricevuto da ogni nodo della rete di overlay. Ciò corrisponde, in senso stretto, alla radiodiffusione. Il multicast si riferisce generalmente all'invio di un messaggio a un sottoinsieme di tutti i nodi o a un particolare gruppo di nodi. Nel multicast, ridurre al minimo l'uso di nodi intermedi per i quali il messaggio non è destinato è una considerazione di progettazione cruciale. Per fare un esempio, se la rete è strutturata come una struttura ad albero multilivello, ma solo i nodi foglia devono ricevere un messaggio multicast, potrebbero essere necessari diversi nodi per archiviare e quindi inoltrare un messaggio che non è destinato a loro.

La creazione di una rete di overlay per gruppo multicast è un metodo semplice per evitare questa inefficienza. Di conseguenza, il multicast di un messaggio ad un gruppo G equivale a trasmettere il messaggio a G. Uno svantaggio di questa soluzione è che un nodo che appartiene a più gruppi dovrà mantenere un elenco separato dei suoi vicini per ogni gruppo a cui appartiene.

Se supponiamo che una rete corrisponda a un gruppo multicast e abbiamo bisogno di trasmettere un messaggio, allora il flooding è un metodo ingenuo per farlo. In questo caso, ogni nodo inoltra un messaggio **m** ai suoi vicini, escluso il nodo da cui ha ricevuto il messaggio. Inoltre, se un nodo mantiene un record dei messaggi che ha ricevuto e inoltrato, può semplicemente ignorare i duplicati. Il flooding è inefficiente perché verranno inviati circa il doppio dei messaggi rispetto ai collegamenti nella rete di overlay.

Per comprendere le prestazioni del flooding, modelliamo una rete di overlay come un grafico **G** connesso avente **N** nodi e **M** edge. Tenendo a mente che il flooding ci richiede di inviare (almeno) messaggi **M,** solo se G è un albero il flooding sarà ottimale, porché in tal caso si avrà che $M = N - 1$. Quando **G** è completamente connesso, dovremo inviare messaggi $M = \binom{N}{2} = \frac{1}{2} \cdot N \cdot (N-1)$ nel caso peggiore.

Supponiamo di non avere informazioni sulla struttura della rete di overlay e che la migliore ipotesi che possiamo fare è che possa essere rappresentata come un grafo casuale o grafo aleatorio, che (per semplificare le cose) è un grafo con probabilità p_e che due nodi siano collegati da un edge, noto anche come grafo di Erdos-Rényi. In particolare, consideriamo la nostra rete di overlay come una rete peer-to-peer non strutturata e non abbiamo informazioni sulla sua costruzione. Con p_e di probabilità che due nodi

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

siano collegati e un totale di $\binom{N}{2}$ edge, è semplice prevedere che la nostra rete invierà $M = \frac{1}{2} \cdot p_e \cdot N \cdot (N-1)$ messaggi.

Il flooding probabilistico può essere utilizzato per ridurre il numero di messaggi. Quando un nodo sta floodando un messaggio **m** e deve inoltrare quel messaggio a un vicino specifico, lo farà con probabilità p_f. Il numero totale di messaggi inviati diminuirà linearmente a causa di p_f. Tuttavia, c'è un rischio: più basso è p_f, maggiore è la probabilità che non tutti i nodi della rete vengano raggiunti. Questo rischio è dovuto al fatto che tutti i vicini di un particolare nodo **Q** hanno scelto di non inoltrare **m** a **Q**. Se **Q** ha **n** vicini, allora la probabilità che ciò accada è approssimativamente $(1 - p_f)^n$. Chiaramente, il numero di vicini gioca un ruolo significativo nel determinare se inoltrare o meno un messaggio e possiamo sostituire la probabilità statica di inoltro con una che tenga conto del grado del vicino.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

3. Disseminazione dati basata su gossip

L'utilizzo di algoritmi epidemici, noti anche come gossip, riguarda tecniche cruciali per la diffusione delle informazioni. Osservando come le malattie si diffondono tra gli esseri umani, i ricercatori hanno studiato a lungo se fosse possibile sviluppare semplici tecniche per la diffusione di informazioni in sistemi distribuiti su larga scala. L'obiettivo principale di questi algoritmi epidemici è quello di propagare rapidamente le informazioni attraverso un ampio gruppo di nodi utilizzando solo dati locali. In altre parole, non prevede una componente centrale che coordini la diffusione delle informazioni.

Allo scopo di chiarire i principi generali alla base di questi algoritmi, assumeremo che tutti gli aggiornamenti per un particolare elemento di dati siano avviati da un singolo nodo, evitando così qualsiasi problema di lost update.

Come suggerisce il loro nome, gli algoritmi epidemici sono fondati sulla teoria delle epidemie, che esamina la diffusione delle malattie infettive. Nel caso di sistemi distribuiti su larga scala, diffondono informazioni piuttosto che malattie. Inoltre, la ricerca sulle epidemie per i sistemi distribuiti ha un obiettivo completamente diverso: mentre le organizzazioni sanitarie faranno tutto il possibile per prevenire la diffusione di malattie infettive tra grandi popolazioni, i progettisti di algoritmi epidemici per sistemi distribuiti tenteranno di "infettare" tutti i nodi con nuove informazioni il più rapidamente possibile.

Utilizzando la terminologia delle epidemie, un nodo di sistema distribuito viene definito infetto se contiene dati che è disposto a diffondere ad altri nodi. Un nodo che non ha ancora incontrato i dati viene definito suscettibile. Un nodo che è stato aggiornato ma non vuole o non è in grado di propagare i propri dati viene rimosso. Si noti che si assume di essere in grado di distinguere tra vecchi e nuovi dati, ad esempio perché si può verificare la loro data di ultima modifica o si può controllare le loro versioni con un sistema di versioning. In questo contesto, si dice anche che i nodi propagano gli aggiornamenti.

I modelli di propagazione più diffusi includono il modello anti-entropia. In questo modello, un nodo **P** seleziona casualmente un altro nodo **Q** e quindi scambia gli aggiornamenti con **Q**. Esistono tre modi per condividere le informazioni:

- **P** recupera solo i nuovi aggiornamenti da **Q**.
- **P** invia solo i propri aggiornamenti a **Q**.
- **P** e **Q** si inviano reciprocamente aggiornamenti (ad esempio, un approccio push-pull)

Quando si tratta di diffondere rapidamente gli aggiornamenti, inviare solo gli aggiornamenti è una scelta sbagliata. Innanzitutto, si noti che in un approccio basato esclusivamente su push, solo i nodi infetti possono propagare gli aggiornamenti. Tuttavia, se un gran numero di nodi sono infetti, la probabilità che

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

ciascuno scelga un nodo suscettibile è relativamente bassa. Pertanto, è probabile che un nodo rimanga suscettibile per un lungo periodo di tempo se non viene scelto da un nodo infetto.

Al contrario, la strategia basata su pull è significativamente più efficace quando numerosi nodi sono infetti. In questo caso, i nodi vulnerabili avviano essenzialmente il meccanismo di propagazione degli aggiornamenti. Esiste un'alta probabilità che questo nodo contatti un nodo infetto, scarichi gli aggiornamenti e successivamente venga infettato.

Se solo un singolo nodo è infetto, gli aggiornamenti si diffonderanno rapidamente a tutti gli altri nodi usando entrambe le forme di anti-entropia, sebbene il push-pull rimanga la strategia più efficace. Si definisce round come un periodo durante il quale ogni nodo avrà avviato uno scambio di aggiornamenti con un altro nodo selezionato casualmente. Il numero di round necessari per propagare un singolo aggiornamento a tutti i nodi viene quindi mostrato come O(log(N), dove N è il numero di nodi nel sistema. Ciò indica che la propagazione degli aggiornamenti non è solo rapida, ma anche scalabile.

Una variante dei metodi epidemici è indicata come rumor spreading. Funziona come segue: se il nodo **P** è stato appena aggiornato per il dato **x**, tenta di inviare l'aggiornamento a qualsiasi altro nodo **Q** contattandolo. Tuttavia, **Q** potrebbe essere già stato aggiornato da un altro nodo. In tal caso, **P** potrebbe perdere interesse a propagare ulteriormente l'aggiornamento, con probabilità p_{stop}.

Paragonabile alla vita reale è il pettegolezzo che diffonde voci. Quando Bob ha notizie interessanti da condividere, potrebbe chiamare la sua amica Alice per dirle tutto. Alice, come Bob, sarà molto ansiosa di raccontare ai suoi amici la voce. Tuttavia, sarà delusa quando chiamerà Chuck, ad esempio, e scoprirà che la notizia lo ha già raggiunto. C'è una buona probabilità che smetta di chiamare i suoi altri amici, perché qual è il punto se lo sanno già?

Il rumor spreading si rivela un mezzo efficace per diffondere rapidamente le informazioni. Non può garantire, tuttavia, che tutti i nodi saranno aggiornati. Infatti, quando c'è un gran numero di nodi che partecipano a un'epidemia, la frazione s di nodi che rimarranno inconsapevoli di un aggiornamento, cioè suscettibile, soddisfa la seguente equazione: $s = e^{-\left(\frac{1}{p_{stop}}+1\right)(1-s)}$.

Uno dei principali vantaggi degli algoritmi epidemici è la loro scalabilità, poiché il numero di sincronizzazioni tra i processi è relativamente basso rispetto ad altre tecniche di propagazione. Per i sistemi wide-area, ha senso considerare la topologia di rete effettiva per ottenere risultati migliori. In questo caso, la probabilità di contattare nodi connessi solo a pochi altri nodi è relativamente alta. L'ipotesi di base è che questi nodi formino un ponte verso altre parti remote della rete; di conseguenza, dovrebbero essere contattati immediatamente. Questa strategia è nota come gossip direzionale e ha numerose varianti.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Questo problema tocca un presupposto importante fatto dalla maggior parte delle soluzioni epidemiche, vale a dire che un nodo può fare gossip con qualsiasi altro nodo a caso. Ciò implica che, in teoria, ogni membro dovrebbe essere consapevole dell'intero insieme di nodi. Questa ipotesi non può mai essere vera in un grande sistema e saranno necessarie misure speciali per simulare queste proprietà.

Gli algoritmi epidemici sono eccezionalmente efficaci nel diffondere aggiornamenti. Tuttavia, hanno uno strano effetto collaterale: diffondere l'eliminazione di un dato è un problema difficile. L'essenza del problema risiede nel fatto che l'eliminazione di un dato cancella tutte le informazioni associate ad esso. Pertanto, quando un dato viene semplicemente rimosso da un nodo, tale nodo alla fine riceverà vecchie copie del dato e le interpreterà come aggiornamenti di qualcosa che non aveva in precedenza.

Il trucco consiste nel registrare l'eliminazione di un dato come semplice aggiornamento e mantenere un record di questa eliminazione. In questo modo, le vecchie copie non verranno interpretate come nuove, ma piuttosto come versioni che sono state modificate da un'operazione di eliminazione. La cancellazione viene registrata distribuendo "certificati di morte".

Ovviamente, il problema con i "certificati di morte" è che alla fine devono essere ripuliti; In caso contrario, ogni nodo creerà un enorme database locale di informazioni storiche sugli elementi di dati eliminati che non vengono utilizzati. Si possono utilizzare "certificati di morte dormienti", ovvero quando viene creato un "certificato di morte", viene contrassegnato con un timestamp. Se si presume che gli aggiornamenti si propaghino a tutti i nodi entro un tempo finito noto, i "certificati di morte" possono essere rimossi una volta trascorso questo tempo massimo di propagazione.

Per fornire garanzie concrete che le cancellazioni vengano effettivamente propagate a tutti i nodi, solo un piccolo numero di nodi mantiene "certificati di morte" dormienti che non vengono mai scartati. Si supponga che il nodo **P** disponga di tale certificato per l'elemento di dati **x**. Se un aggiornamento obsoleto per **x** raggiunge in qualche modo **P**, **P** distribuirà semplicemente di nuovo il "certificato di morte" per **x**.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).

Bibliografia

- M. van Steen and A.S. Tanenbaum, Distributed Systems, 3rd ed., distributed-systems.net, 2017.
- Janic M. Multicast in Network and Application Layer. Ph.d., Delft University of Technology, 2005.
- Obraczka K. Multicast Transport Protocols: A Survey and Taxonomy. IEEE Communications Magazine, 1998.
- Diot C., Levine B., Lyles B., Kassem H., and Balensiefen D. Deployment Issues for the IP Multicast Service and Architecture. IEEE Network, 2000.
- El-Sayed A., Roca V., and Mathy L. A Survey of Proposals for an Alternative Group Communication Service. IEEE Network, 2003.
- Hosseini M., Ahmed D., Shirmohammadi S., and Georganas N. A Survey of Application-Layer Multicast Protocols. IEEE Communications Surveys & Tutorials, 2007.
- Allani M., Garbinato B., and Pedone F. Application Layer Multicast. In Garbinato B., Mirando H., and Rodrigues L., editors, Middleware for Network Eccentric and Mobile Applications, 2009.
- Chu Y., Rao S. G., Seshan S., and Zhang H. A Case for End System Multicast. IEEE Journal on Selected Areas in Communication, 2002.
- Banaei-Kashani F. and Shahab C. Criticality-based Analysis and Design of Unstructured Peer-to-Peer Networks as “Complex Systems”. In 3rd International Symposium on Cluster Computing and the Grid, May 2003.
- Oikonomou K. and Stavrakakis I. Performance Analysis of Probabilistic Flooding Using Random Graphs. In World of Wireless, Mobile and Multimedia Networks, 2007.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d’autore (L. 22.04.1941/n. 633).

- Demers A., Greene D., Hauser C., Irish W., Larson J., Shenker S., Sturgis H., Swinehart D., and Terry D. Epidemic Algorithms for Replicated Database Maintenance. In 6th Symposium on Principles of Distributed Computing, 1987.
- Eugster P., Guerraoui R., Kermarrec A.-M., and Massoulié L. Epidemic Information Dissemination in Distributed Systems. Computer, 2004.
- Jelasity M. and Babaoglu O. T-Man: Gossip-based Overlay Topology Management. In 3rd International Workshop on Engineering Self-Organising Applications, volume 3910 of Lecture Notes in Computer Science 2006.
- Lin M.-J. and Marzullo K. Directional Gossip: Gossip in a Wide-Area Network. In Proceedings 3rd European Dependable Computing Conf., volume 1667 of Lecture Notes in Computer Science, Sept. 1999.

PEGASO
Università Telematica

Attenzione! Questo materiale didattico è per uso personale dello studente ed è coperto da copyright. Ne è severamente vietata la riproduzione o il riutilizzo anche parziale, ai sensi e per gli effetti della legge sul diritto d'autore (L. 22.04.1941/n. 633).